

UNIVERSIDADE PRESBITERIANA MACKENZIE

ANDERSON ADAIME DE BORBA

**FUSÃO DE EVIDÊNCIAS NOS CANAIS DE INTENSIDADES
PARA A DETECÇÃO DE BORDAS EM IMAGENS PolSAR**

São Paulo
2020

**FUSÃO DE EVIDÊNCIAS NOS CANAIS DE INTENSIDADES
PARA A DETECÇÃO DE BORDAS EM IMAGENS PolSAR**

TESE APRESENTADA AO
PROGRAMA DE PÓS-GRADUAÇÃO EM
ENGENHARIA ELÉTRICA E COMPUTAÇÃO DA
UNIVERSIDADE PRESBITERIANA MACKENZIE
PARA
OBTENÇÃO DO TÍTULO
DE
DOUTOR.

Orientador: Prof. Dr. Mauricio Marengoni

Coorientador: Prof. Dr. Alejandro César Frery Orgambide

Durante o desenvolvimento deste trabalho o autor recebeu auxílio financeiro da CAPES

São Paulo, 06 de novembro de 2020

Resumo

Os radares de abertura sintética polarimétrica (PolSAR) alcançaram uma posição essencial no sensoriamento remoto. As imagens que eles fornecem têm ruído *speckle*, tornando as ações de processamento e de análise tarefas desafiadoras. Neste trabalho foram estudados e comparados seis métodos de fusão provenientes da detecção das evidências de bordas nos canais de intensidade hh, hv e vv de imagens PolSAR múltiplas visadas. O método consiste em detectar pontos de transição em uma faixa de dados, o mais fina possível, fornecendo uma faixa de dados que cobre duas regiões usando o método estimativa máxima verossimilhança sob a distribuição de Wishart. Os métodos de fusão usados são: média simples (MS), transformada *wavelet* discreta multi-resolução (MR-DWT), análise de componente principal (PCA), estatísticas ROC, transformada *wavelet* estacionária multi-resolução (MR-SWT), e um método de multi-resolução baseado na decomposição de valores singulares (MR-SVD). Os resultados obtidos com a análise quantitativa indicam que os métodos PCA e MR-SVD fornecem os melhores resultados.

Palavras-chave: PolSAR. Detecção de bordas. Estimativa de máxima verossimilhança. Métodos de fusão.

Abstract

Polarimetric Synthetic Aperture Radar (PolSAR) sensors have reached an essential position in remote sensing. The images they provide have speckle noise, making their processing and analysis challenging tasks. We discuss an edge detection method based on the fusion of evidences obtained in the intensity channels hh, hv, and vv of PolSAR multi-look images. The method consists of detecting transition points in the thinnest possible range of data that covers two regions using maximum likelihood under the Wishart distribution. The fusion methods used are: simple average, multi-resolution discrete wavelet transform (MR-DWT), principal component analysis (PCA), Receiver operating characteristic (ROC) statistics, multi-resolution stationary (MR-SWT) wavelet transform, and a multi-resolution method based on singular value decomposition (MR-SVD). A quantitative analysis suggests that PCA and MR-SVD provide the best results.

Keywords: PolSAR. Edge detection. Maximum likelihood estimation, Fusion methods.

vi

Sumário

Lista de Abreviaturas	ix
Lista de Símbolos	xi
Lista de Figuras	xiii
Lista de Tabelas	xv
1 Introdução	1
1.1 Objetivos	3
1.2 Contribuições	3
1.3 Plataformas, validação do programas, recursos computacionais	4
1.4 Reprodutibilidade e replicabilidade	5
1.5 Organização do texto	5
2 Aspectos gerais	7
2.1 Imagens SAR e PolSAR	7
2.2 Características gerais dos Radares SAR e PolSAR	8
2.3 Características específicas dos radares SAR e PolSAR	10
2.4 Estrutura de dados para imagens PolSAR	12
3 Metodologia	17
3.1 Modelagem estatística para dados PolSAR	17
3.1.1 Matriz de coerência polarimétrica de Pauli (T_4) e matriz de covariância lexicográfica (C_4)	18
3.1.2 Matriz de coerência polarimétrica de Pauli (T_3) e matriz de covariância lexicográfica (C_3)	20
3.1.3 Estatística do Ruído <i>Speckle</i> no processo de única visada	22
3.1.4 Estatística do ruído <i>Speckle</i> no processo de múltiplas visadas	25
3.2 Matriz de covariância	26
3.3 Função Wishart densidade de probabilidade para os canais de intensidades	28
3.4 Método para detecção das evidências de bordas	30

3.4.1	Estimativa por máxima verossimilhança	32
3.4.2	A máxima verossimilhança usando os parâmetros estimados	33
3.5	O MLE aplicado a pdf Γ em cada canal de intensidade	33
3.6	Métodos de fusão para as evidências de bordas	35
3.6.1	Fusão por média simples	36
3.6.2	Fusão usando o método wavelet discreta multi-resolução – MR-DWT	36
3.6.3	Fusão usando o método wavelet discreta Multi-Resolução – MR-SWT	37
3.6.4	Fusão usando o método análise das componentes principais – PCA	37
3.6.5	Fusão usando a estatística ROC	38
3.6.6	Fusão usando o método decomposição em valores singulares multi-resolução – MR-SVD	43
4	Resultados	45
4.1	Imagen simulada	45
4.1.1	Método estimativa de máxima verossimilhança aplicada a PDF Univariada Gamma	45
4.1.2	Métricas para as evidências de bordas nas imagens simuladas .	47
4.1.3	Fusão de evidências de bordas para os canais de intensidades .	47
4.2	Imagenes adquiridas por sensores PolSAR	50
4.2.1	Imagen de Flevoland	50
5	Discussões e conclusões	65
Referências Bibliográficas		67
Índice Remissivo		70

Lista de Abreviaturas

SAR	Radar de abertura sintética
RAR	Radar de abertura real
PolSAR	Radar de abertura sintética polarimétrica
PDF	Função densidade de probabilidade
ROI	Região de Interesse
LoG	Detector de borda usando o laplaciano da gaussiana
MLE	Método estimativa de máxima verossimilhança
MS	Média simples
MR-DWT	Transformada <i>wavelet</i> discreta com múltiplas resoluções
PCA	Analise das componentes principais
E-ROC	Estatística ROC (<i>Receiver operating characteristic</i>)
MR-SWT	Transformada <i>wavelet</i> estacionária com múltiplas resoluções
MR-SVD	Decomposição em valores singulares com múltiplas resoluções
GenSA	Método Simulated annealing
BFGS	Método Broyden-Fletcher-Goldfarb-Shanno
VHR	<i>Very High Resolution</i>
DLR	Centro espacial da Alemanha
BSA	Sistema de coordenadas <i>Back Scattering Alignment</i>
DOI	<i>Digital Object Identifier</i>
URL	<i>Uniform Resource Locator</i>

X LISTA DE ABREVIATURAS

Lista de Símbolos

L	Número de visadas em uma imagem PolSAR
Σ	Mariz de covariância hermitiana e definida positiva
$E[\cdot]$	Valor esperado
Γ	Função Gamma
Γ_m	Função Gamma multivariada
$W(\Sigma, L)$	Distribuição Wishart
\Re	Parte real de um número complexo
\Im	Parte complexa de um número complexo

Listas de Figuras

2.1	Imagen PolSAR com polarizações hh, hv e vv	13
2.2	Imagen da região de São Francisco capturada por satélite	13
2.3	Baía de São Francisco.	14
2.4	Polarização vv.	14
2.5	Polarização hv.	14
2.6	Polarização hh.	14
2.7	Imagen da região do Rio Grande Valley	14
2.8	Imagen do planeta Vênus capturada pelo satélite Magellan	16
3.1	Distribuições Wishart multiplas visadas com $\sigma = 0.01$	29
3.2	Definições para a ROI na imagem PolSAR.	32
3.3	Fusão por média simples.	36
3.4	Fusão MR-DWT.	37
3.5	Fusão MR-SWT.	38
3.6	Fusão PCA.	38
3.7	Fluxograma para a aplicação dos limiares na fusão de evidência ROC. .	41
3.8	Estrutura para fusão de evidências com j escolhido arbitrariamente. .	42
3.9	Curva ROC para a imagem simulada de duas folhas.	43
4.1	Decomposição de Pauli aplicada aos canais simulados	46
4.2	Funções de verossimilhanças totais para cada canal simulado	46
4.3	Evidências de bordas para os canais de intensidades.	47
4.4	Métricas para a detecção em imagem simulada	48
4.5	Resultados da apliação dos seis métodos de fusão	49
4.6	Métricas para a fusão de evidências de bordas	50
4.7	Imagen da região de Flevoland	51
4.8	Região de interesse da imagem Flevoland (FLEV-ROI-I), e <i>ground truth</i> de referência	51
4.9	Evidências de bordas para os três canais de intensidades na FLEV-ROI-I .	52
4.10	Métricas para a fusão de evidências de bordas na região FLEV-ROI-I .	53

4.11	Métodos de fusão para a região FLEV-ROI-I	54
4.12	Probabilidade de detecção dos métodos de fusão para a FLEV-ROI-I	55
4.13	Região de interesse da imagem Flevoland (FLEV-ROI-II), e <i>ground truth</i> de referência	56
4.14	Evidências de bordas para os três canais de intensidades para FLEV-ROI-II na imagem de Flevoland com folga de 25 pixel	56
4.15	Métricas para a detecção de evidências de bordas na região FLEV-ROI-II	57
4.16	Resultados das aplicações dos métodos de fusão para a FLEV-ROI-II com 25 pixels de folga	58
4.17	Probabilidade de detecção dos métodos de fusão para a FLEV-ROI-II	59
4.18	Imagen da baía de São Francisco	60
4.19	Decomposição de Pauli para imagem de São Francisco, e a Ground Truth - GT	60
4.20	Evidências de bordas para os canais de intensidades na imagem de São Francisco	61
4.21	Métricas para a fusão de evidências de bordas na região SF-ROI	61
4.22	Resultado da aplicação dos método de fusão para a SF-ROI	62
4.23	Probabilidade de detecção dos métodos de fusão para a SF-ROI	63

Lista de Tabelas

2.1	Espectro eletromagnético para a faixa de micro-ondas.	10
2.2	Características do satélite SEASAT (SAR).	10
2.3	Características operacionais dos satélites SAR ou PolSAR.	11
2.4	Informações do sistema PolSAR.	12
2.5	Ordem de armazenamento para os canais da imagem polSAR.	12
2.6	Características do sistema Lynx (SAR).	15
3.1	Coeficientes de variação.	26
3.2	Matriz de confusão.	39
3.3	Matriz de confusão para cada comparação	41
4.1	Tempo de processamento para os métodos de fusão	55

Capítulo 1

Introdução

Os radares de abertura sintética (SAR – *Synthetic Aperture Radar*) e de abertura sintética polarimétricos (PolSAR) alcançaram uma posição essencial na área de sensoriamento remoto. Os dados que esses sensores fornecem requerem técnicas, especificamente adaptadas, para o seu processamento e análise. Entre essas técnicas, a detecção de bordas é uma das operações mais importantes para extrair informações. As bordas estão em um nível mais alto de abstração do que apenas os dados e, como tais, fornecem informações relevantes sobre a cena.

As imagens do tipo SAR e PolSAR possuem características inerentes ao seu processo de aquisição. Como vantagens podemos destacar que a captação das imagens pode ser realizadas dia e noite (pois o sensor é ativo e carrega a própria fonte de iluminação), não dependem das condições do tempo (pois iluminam a cena com micro-ondas, que são pouco afetadas por nuvens, chuva, bruma, fumaça, etc.) e possuem excelente capacidade de penetração da cobertura vegetal. A desvantagem deste tipo de imagem está na presença do ruído *speckle*, que gera um aspecto granular na imagem, dificultando a sua interpretação e análise.

As técnicas de detecção de bordas disponíveis para imagens SAR e PolSAR estão sendo desenvolvidas, e são temas em recentes pesquisas. Entre as técnicas disponíveis para essas imagens, são destacadas: técnicas baseadas em redução do ruído *speckle* Liu *et al.* (2014); Santana-Cedrés *et al.* (2020); Shi *et al.* (2020); Wang *et al.* (2018); campos aleatórios de Markov Baselice e Ferraioli (2012); a abordagem de *deep learning* Zhu *et al.* (2017) aplicada à segmentação e classificação; e técnicas estatísticas Frery *et al.* (2010); Gambini *et al.* (2006); Nascimento *et al.* (2014).

Este trabalho de pesquisa segue a abordagem de modelagem estatística usando as técnicas descritas em Frery *et al.* (2010); Gambini *et al.* (2006); Nascimento *et al.* (2014) para encontrar evidências de bordas em imagens PolSAR. Destacamos que não usaremos técnicas de redução do *speckle*, pois suas características serão usadas para potencializar a detecção de evidências de bordas. Além do que, em vez de lidar com dados totalmente

polarimétricos, trataremos cada canal de intensidade da imagem separadamente, com o objetivo de obter evidências de bordas.

Em seguida, será realizado a fusão das evidências de bordas obtidas, com o objetivo de produzir um único e mais acurado estimador da posição de bordas. Com isso, se pretende qualificar a contribuição fornecida por cada canal de intensidade da imagem PolSAR, na detecção de bordas. A referência [De Borba et al. \(2020\)](#) fornece informações sobre os processos de fusão em imagens PolSAR, assim como o desempenho de cada método para detectar bordas, enquanto a referência [Mitchell \(2010\)](#) mostra os fundamentos da fusão de imagens.

O Algoritmo Gambini, apresentado em [Gambini et al. \(2008\)](#), é uma excelente técnica para detecção de bordas. Com essa técnica é possível encontrar evidências de uma borda sobre uma faixa fina de dados. Esta abordagem funciona com qualquer modelo, o que o torna adequado para dados SAR e PolSAR, e tem demonstrando ter um desempenho melhor do que outras abordagens. Esse algoritmo consiste em traçar raios, para então, encontrar a evidência de borda maximizando uma função que, na proposta original, é a de máxima verossimilhança total.

Neste trabalho usaremos a verossimilhança total de duas amostras: uma para região interna e outra para a região externa da borda. Para não perder de generalidade, optou-se pela distribuição Wishart para as observações totalmente polarimétricas, derivando para as suas distribuições, do tipo Gamma, em cada canal de intensidade. A função de máxima verossimilhança total depende das estimativas que parametrizam as leis Gamma. As estimativas são realizadas pelo método de otimização BFGS (Broyden-Fletcher-Goldfarb-Shanno, ver [Henningsen e Toomet, 2011](#); [Nocedal e Wright, 2006](#)). Neste trabalho estaremos os parâmetros que indexam as distribuições Gamma com o método de máxima verossimilhança (MLE – *Maximum Likelihood Estimator*).

A função de verossimilhança total não é diferenciável em vários pontos, e os métodos clássicos apresentam dificuldade em encontrar os seus máximos. Uma possível abordagem para resolver este problema é usar o método GenSA (*Generalized Simulated Annealing*, [Xiang et al., 2013](#)).

Nesta pesquisa propomos, discutimos, e comparamos o uso de seis métodos de fusão: Média simples (MS, [Mitchell, 2010](#)); Transformada *Wavelet* Discreta de Multi-resolução, (MR–DWT, [Naidu e Raol, 2008](#)); Análise de Componentes Principais, (PCA, [Mitchell, 2010](#); [Naidu e Raol, 2008](#)); Estatísticas baseadas na curva ROC (*Receiver Operating Characteristic*, [Giannarou e Stathaki, 2011](#)), o qual é denominado de E-ROC; Transformada *Wavelet* Estacionária de Multi-resolução, (MR–SWT, [Jiang et al., 2017](#); [Naidu e Raol, 2008](#)); e Decomposição em valores singulares multi-resolução, (MR–SVD, [Demmel, 1997](#); [Naidu, 2011](#)).

1.1 Objetivos

O objetivo deste trabalho é estudar a viabilidade dos métodos para a fusão das evidências de bordas detectadas nos canais de intensidades hh, hv, e vv, de uma imagem PolSAR, como também usar os métodos de fusão para quantificar as contribuições de informações provenientes de cada canal.

Para alcançar tais objetivos deve-se aplicar nas imagens SAR e PolSAR os seguintes procedimentos:

- (i) Especificar manualmente ou automaticamente a região de interesse ROI;
- (ii) Em cada ROI calcular o centro de massa e, a partir desse ponto, traçar retas radiais cruzando duas amostras distintas. Nas radiais serão extraídas informações para o passo (iii);
- (iii) Nos dados extraídos em cada reta radial o método MLE é aplicado para estimar o ponto de transição entre duas amostras, chamado de evidência de borda;
- (iv) Métodos de fusão são aplicados nas evidências de bordas, em cada canal, com o objetivo de detectar as bordas na ROI escolhida.

1.2 Contribuições

As contribuições desta tese são:

- (i) Propor a fusão de evidências de bordas, obtidas em cada canal, aprimorando o método de detecção de bordas;
- (ii) Aplicar e comparar os métodos de fusão: MS, MR-DWT, PCA, E-ROC, MR-SWT, e MR-SVD;
- (iii) Verificação da viabilidade do uso do método GenSA no método MLE com o algoritmo Gambini, aplicado aos canais de intensidades de uma imagem PolSAR, com o objetivo de detectar evidências de bordas, como proposto e analisado nas referências Frery *et al.* (2010); Gambini *et al.* (2006); Nascimento *et al.* (2014);
- (iv) Realizar medidas de qualidade para a detecção em cada canal, e na fusão, usando uma métrica baseada na probabilidade de detecção de bordas, comparando com a imagem definida como referência (*Ground Truth*).
- (v) Identificação de duas características que dificultam a detecção de evidências de bordas: oscilação nas extremidades e não diferenciabilidade em vários pontos do domínio das funções de máxima verossimilhança total. Para contornar o problema

propomos, respectivamente, as seguintes soluções: definir empiricamente constantes de folga nas extremidades, usar o método GenSA para encontrar o ponto de máximo da função.

Os resultados obtidos neste trabalho foram publicados na conferência *IEEE Recent Advances in Geoscience and Remote Sensing : Technologies, Standards and Applications (TENGARSS)* com o seu identificador digital DOI (*Digital Object Identifier*), e seu localizador URL (*Uniform Resource Locator*), respectivamente, <https://doi.org/10.1109/TENGARSS48957.2019.8976040>, e <https://ieeexplore.ieee.org/abstract/document/8976040>. E no periódico *IEEE Geoscience and Remote Sensing Letters* com o seu identificador digital DOI, e seu localizador, respectivamente, <https://doi.org/10.1109/LGRS.2020.3022511>, e <https://ieeexplore.ieee.org/abstract/document/9203845>.

1.3 Plataformas, validação do programas, recursos computacionais

Neste trabalho foram usadas as seguintes plataformas:

- R ([R Core Team, 2020](#)) é uma linguagem de programação com forte viés de manipulação, análise e visualização de dados. Neste trabalho, a detecção de bordas nos canais de intensidades e a visualização dos dados foram programados usando esta linguagem.
- Matlab ([MATLAB, 2014](#)) é uma linguagem de programação que tem seu ponto forte na manipulação de vetores e matrizes. Os programas de fusão para a detecção de bordas e as visualizações das imagens PolSAR, presentes neste trabalho, foram programados nesta linguagem.

Os programas usados neste trabalho foram validados com auxílio de uma imagem de referência que consiste de duas classes, e para a qual é conhecido o posicionamento da borda. Simulamos imagens observadas por um sensor PolSAR atribuindo a cada classe observações independentes oriundas da distribuição Whisart. Os programas foram rodados para a imagem simulada e verificou-se que as bordas foram encontradas com precisão. Desta forma, os programas foram validados e aplicados em imagens PolSAR fornecidas por sensores operacionais.

O recurso computacional disponível consiste em computados Intel© Core i7-9750HQ CPU 2.6 GHz com 16 GB de memória RAM.

1.4 Reprodutibilidade e replicabilidade

A reproduzibilidade e replicabilidade são essenciais para o desenvolvimento da ciência, estes temas não são discutidos neste trabalho, porém realizamos as pesquisas de forma a respeitar esses conceitos.

Os trabalhos de [Balz e Rocca \(2020\)](#) e [Frery et al. \(2020\)](#) mostram pesquisas sobre o tema. Na primeira referência encontramos as seguintes definições:

- A reproduzibilidade é definida como a habilidade dos pesquisadores de obter resultados consistentes usando os mesmos dados de entrada, rotinas computacionais, métodos, programas e condições de análises.
- A replicabilidade é definida como uma situação em que os pesquisadores obtêm resultados consistentes por meio de estudos que visam responder à mesma questão científica, cada um dos quais obteve seus próprios dados.

Os programas e dados usados neste trabalho estão disponíveis no sítio eletrônico https://github.com/anderborba/Code_GRSL_2020_1.

1.5 Organização do texto

Os assuntos estudados para aplicação e análise dos métodos discutidos nesta pesquisa, assim como seus resultados foram distribuídos e organizados da seguinte forma:

- (i) Capítulo 2: Alguns conceitos introdutórios e informações relevantes sobre as imagens SAR e PolSAR e radares.
- (ii) Capítulo 3: São apresentados os aspectos metodológicos, descrevendo o modelo, a detecção de bordas e as abordagens para fusão de evidências de bordas.
- (iii) Capítulo 4: Apresentação, descrição e análise dos resultados.
- (iv) Capítulo 5: Discussões dos resultados obtidos e as direções para pesquisas futuras.

Capítulo 2

Aspectos gerais

Neste capítulo serão apresentadas algumas informações relevantes para situar e contextualizar a área de pesquisa desta tese. Serão abordados alguns assuntos introdutórios, traçando um breve panorama do desenvolvimento e aprimoramento dos radares RAR (*Real Aperture Radar*), SAR e PolSAR. Apresentamos também as características gerais e específicas dos radares, bem como informações de como são gerados e armazenados os dados provenientes da captação das imagens SAR e PolSAR.

2.1 Imagens SAR e PolSAR

O SAR é o desenvolvimento tecnológico do RAR, o qual, de maneira geral, trabalha com sensores que transmitem sinais de micro-ondas e depois registram os sinais de retorno.

Os radares RAR para alcançar altas resoluções necessitam de grandes comprimentos de antenas o que inviabiliza o seu uso em satélites e em aviões. Fato que configurou grande restrição para a área de sensoriamento remoto até os anos 50.

Na década de 50, pesquisadores fizeram avanços significativos para resolver as limitações tecnológicas dos radares e desenvolveram uma técnica capaz de sintetizar o efeito de uma antena muito longa, em uma antena de tamanho viável, denominada SAR. Essa descoberta foi atribuída a Carl Wiley por volta de 1951 e, em 1954, foi registrada a patente do sistema SAR. Além disso, um sistema SAR foi operacionalizado em torno de 1958, impulsionando fortemente essa área de pesquisa.

Os dados provenientes do SAR são gravados como uma faixa de posições para cada tempo avançado na direção da rota (azimute). No início do desenvolvimento dos sistemas SAR, o armazenamento de dados foi um grande problema, a solução foi colocar acoplado aos radares um sistema ótico para armazenar dados em filmes fotográficos. Atualmente, devido ao desenvolvimento da eletrônica, o problema de armazenamento de dados foi atenuado.

Nos sistemas SAR os dados das micro-ondas de retorno armazenados são representadas como imagens. Estas imagens são geradas de forma que em cada ponto da direção azimute, o radar envia um impulso em direção ao alvo, e depois recebe e armazena o sinal de retorno, que depende do espalhamento do sinal pelo alvo. Portanto, durante o tempo de aquisição das imagens são armazenadas as informações em uma linha de dados, gerando um mapeamento azimute *versus* distância lateral das micro-ondas de retorno.

Essa estrutura de dados é típica de armazenamento em matrizes com as dimensões definidas pela resolução característica dos radares. As dimensões das imagens são, respectivamente, as resoluções na direção do azimute, dada pela rota do radar e pela direção perpendicular, definida como distância lateral. Desta forma, os radares geram imagens bidimensionais com resoluções distintas, dependendo do tipo de radar e da tecnologia empregada.

Neste trabalho usamos a generalização do sistema SAR conhecido como sistema polarimétrico SAR (PolSAR). O sistema PolSAR é definido como a ciência de adquirir, processar e analisar o estado da polarização nas imagens de radar de abertura sintética.

As imagens geradas por esses radares são formadas por micro-ondas de retorno, combinando as polarizações. O processo de polarização fornece mais informações sobre o alvo comparados com as imagens SAR. As imagens PolSAR têm o objetivo de melhorar o entendimento do efeito do espalhamento das micro-ondas pelos alvos, considerando as diferentes polarizações.

Os símbolos hh, hv, vh, e vv, representam as polarizações disponíveis nos radares, onde a primeira letra é a maneira como a onda é emitida e, a segunda letra é a maneira como a onda é recebida.

2.2 Características gerais dos Radares SAR e PolSAR

Os radares que têm a característica de emitir as micro-ondas são definidos como radares ativos e, se os radares transmitem e recebem os sinais com a mesma antena, são denominadas mono-estáticas. Importantes informações sobre radares podem ser encontradas na referência [Lee e Pottier \(2009\)](#).

O desenvolvimento dos radares pode ser resumidos pelos princípios a seguir:

- Possibilidade de uma antena transmitir micro-ondas em uma direção precisa;
- Possibilidade de detectar com grande precisão o sinal de retorno. Após a interação das micro-ondas com o alvo acontece o espalhamento das micro-ondas refletidas em todas as direções. Assim o radar pode não captar alguns sinais de retorno;
- Capacidade de medir o tempo entre a transmissão e a recepção das micro-ondas, consequentemente calcular a distância entre o alvo e o radar;

- Habilidade de detectar vários alvos em grandes áreas percorridas.

As micro-ondas podem variar em comprimento e amplitude, dependendo da construção dos sensores para o radar em operação. Uma característica importante dessas ondas é a capacidade de penetração no alvo analisado.

Os radares SAR e PolSAR justificam seu uso por possuírem algumas características operacionais que podem ser resumidas nos seguintes itens:

- Podem estar em plataformas elevadas, aeronaves tripuladas ou não, satélites orbitando a terra ou outros planetas;
- É uma técnica de produção de imagem viável e prática;
- Podem gerar imagens de alta resolução espacial;
- Os radares produzem imagens dia e noite;
- As condições atmosféricas interferem muito pouco na captação de imagens.

Na referência [Lillesand et al. \(2015\)](#) encontramos um amplo espectro de aplicações das imagens SAR e PolSAR na área de sensoriamento remoto. Podemos listar algumas dessas aplicações:

- Mapeamento do solo ou cobertura do solo;
- Mapeamento Geológico;
- Oceanografia;
- Glaciologia;
- Aplicações agrícola;
- Acompanhamento de florestas;
- Monitoramento ambiental;
- Monitoramento de desastres naturais;
- Controle de derramamento de petróleo;
- Aplicações de recursos hídricos;
- Aplicações da ecologia da vida selvagem;
- Aplicações arqueológicas;
- E aplicações conjuntas com sistemas óticos.

2.3 Características específicas dos radares SAR e PolSAR

Os radares SAR e PolSAR trabalham no espectro das micro-ondas. A tabela 2.1 definida no livro Lee e Pottier (2009) mostra na primeira coluna a representação da banda, na segunda coluna das faixas de frequências que os radares são construídos. Na terceira coluna foi fixada uma frequência (f) para encontrar o comprimento de onda (λ) e mostrar na quarta coluna. Lembrando que o produto da frequência pelo comprimento de onda encontra a velocidade.

Tabela 2.1: Espectro eletromagnético para a faixa de micro-ondas.

banda	Frequência - f [GHz]	f fixada	λ [cm].
P	<0.39–0.39	0.3	100.0
L	0.39–1.55	1.0	30.0
S	1.55–3.90	3.0	10.0
C	3.90–5.75	4.0	7.5
X	5.75–10.9	10.0	3.0
K	10.9–36.0	30.0	1.0
Q	36.0–46.0	40.0	0.75
V	46.0–56.0	50.0	0.6
W	56.0–>56.0	100.0	0.3

A descoberta da tecnologia SAR impulsionou um grande desenvolvimento da área, levando à construção do SEASAT, o primeiro SAR comercial projetado. Este projeto foi muito bem sucedido e estabeleceu definitivamente os sistemas SAR e PolSAR como área de pesquisa.

O lançamento do satélite foi em junho de 1978, a Tabela 2.2 mostra algumas características do SEASAT. Para mais informações pode-se consultar o seguinte sítio eletrônico, <https://earth.esa.int/web/eoportal/satellite-missions/s/seasat>.

Tabela 2.2: Características do satélite SEASAT (SAR).

Características específicas	Valores operacionais
Frequência	1.275 GHz
Altitude	780 km
Peso	2300 kg
Ângulo de inclinação	~23°
Distância lateral	100 km
Largura de banda	19 MHz
Banda L	23.5 cm de comprimento de onda
Polarização	hh - Onda emitida e recebida na direção horizontal
Resolução	(25 × 25) m ²

Outros projetos de sistema foram realizados e podem ser vistos na tabela 2.4.

Tabela 2.3: Características operacionais dos satélites SAR ou PolSAR.

Satélites	SEASAT	AIRSAR	SIR-C	Almaz	ERS-2	JERS-1	RADSAT-1	RADSAT-2
Nacionalidade	EUA	EUA	Alamanha-Itália	Rússia	Europa	Japão	Canadá	Canadá
Lançamento	1978	1988	1990	1992	1995	1998	1995	2003
Banda (cm)	L	P-L-C	L-C-X	S	C	L	C	C
Polarização	hh	hh-hv-vv	hh-hv-vv	hh	vv	hh	hh	hh-hv-vv
Ângulo de incidência	23	20–60	15–55	30–60	23	35	20–59	20–60
Distância (km)	100	10–17	15–90	350	100	75	50–500	10–500
Resolução (m ²)	25	2–8	10–60	10–30	30	18	10–100	3–100

2.4 Estrutura de dados para imagens PolSAR

O sistema PolSAR armazena informações de retorno em uma matriz $S_{2 \times 2}$ para cada ponto de sua região de observação, onde as entradas da matriz são números complexos. Se o sistema é mono-estático, a matriz torna-se hermitiana (a matriz é igual a sua transposta conjugada), por esse motivo, podemos representar a matriz na forma de um vetor s de dimensão 3. O produto entre o vetor e seu hermitiano gera uma matriz hermitiana 3×3 com suas entrada mostrada na Tabela 2.4.

Tabela 2.4: Informações do sistema PolSAR.

Polarização	hh	hv	vv
hh	σ_{hh}	$\sigma_{hhv} + \hat{\sigma}_{hhv}\hat{j}$	$\sigma_{hvv} + \hat{\sigma}_{hvv}\hat{j}$
hv	-	σ_{hv}	$\sigma_{hvv} + \hat{\sigma}_{hvv}\hat{j}$
vv	-	-	σ_{vv}

A estrutura de dados para receber as informações da tabela 2.4 pode ser uma matriz tridimensional, onde os dois primeiros índices da matriz localizam o pixel da imagem PolSAR correspondente ao azimute e a distância lateral. A resolução do sistema PolSAR define as dimensões na direção do azimute e da distância lateral. O terceiro índice da matriz tridimensional é definido como canal.

Para cada pixel fixo da imagem, os canais recebem os valores mostrados na Tabela 2.5. O simbolo C_k com $k = 1, \dots, 9$ define os canais da imagem.

Tabela 2.5: Ordem de armazenamento para os canais da imagem polSAR.

C_1	C_2	C_3	C_4	C_5	C_6	C_7	C_8	C_9
σ_{hh}	σ_{hv}	σ_{vv}	σ_{hhv}	$\hat{\sigma}_{hhv}$	σ_{hvv}	$\hat{\sigma}_{hvv}$	σ_{hvv}	$\hat{\sigma}_{hvv}$

Neste trabalho serão usados os três primeiros canais da matriz que armazena os dados da imagem PolSAR, conhecidos como canais de intensidades. Os sensores AIRSAR, SIR-C, e RADSAT-2 fornecem informações deste tipo, mas características desses sensores podem ser encontrados na Tabela .

Um exemplo de dados PolSAR é a imagem da baía de São Francisco (EUA), com suas respectivas polarizações em tons de cinza, mostradas na figura 2.1. A imagem foi captada pelo sensor aerotransportado AIRSAR polarimétrico na banda L. O AIRSAR apresenta resolução de $2\text{--}8 \text{ m}^2$.

A região de São Francisco capturada por um satélite ótico através do sítio eletrônico <https://www.google.com/maps> é mostrada na Figura 2.2.

A visualização da região da baía de São Franscisco, usando a decomposição de Pauli (RBG), que será abordada no próximo capítulo, pode ser vista na figura 2.3. Esta imagem

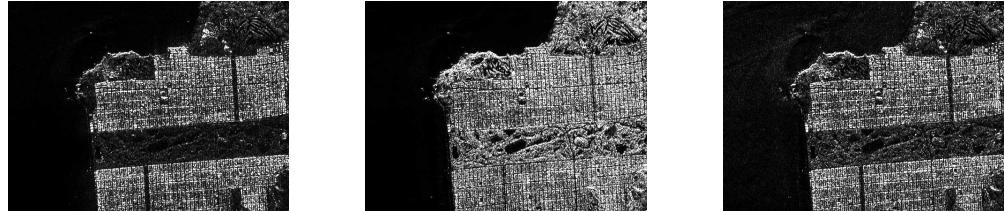


Figura 2.1: Imagem PolSAR com polarizações hh , hv e vv .

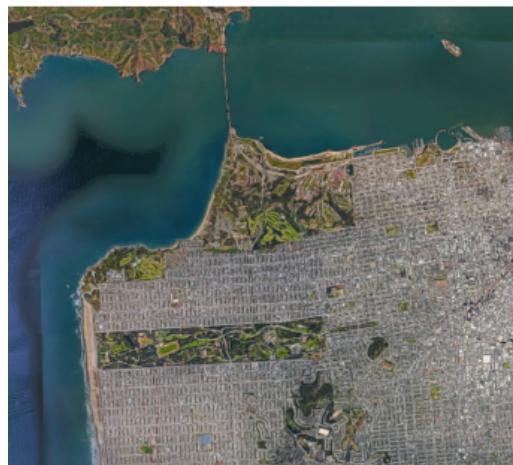


Figura 2.2: Imagem da região de São Francisco capturada por satélite

também será usada para a realização do processamento de dados com o objetivo de testar os métodos propostos neste trabalho.

As Figuras 2.4, 2.5 e 2.6 mostram, respectivamente, a decomposição RBG para cada canal, azul, verde e vermelho das imagens de PolSAR da baía de São Francisco.

Atualmente, os sistemas SAR e PolSAR são uma área de pesquisa muito ativa. Entre os interesses atuais, está o desenvolvimento de sistemas tipo SAR e PolSAR com alta resolução (VHR). Um exemplo disso é o sistema Lynx, projetado pelo laboratório nacional Sandia, o qual alcança resoluções de 10 a 30 centímetros quadrados. O sitio eletrônico <https://www.sandia.gov/media/NewsRel/NR1999/Lynx.htm> fornece as informações da Tabela 2.6 sobre o projeto lynx:

O Lynx pode gerar imagem com alta resolução portanto com grandes dimensões, por exemplo, a imagem da Figura 2.7 mostrando a região de Rio Grande Valley tem dimensão de 1068×2600 pixels e resolução de aproximadamente $(30 \times 30) \text{ cm}^2$.

Outro exemplo, pode ser visto no artigo Reigber *et al.* (2013), que mostra um sistema PolSAR que produzem imagens com resolução de $(25 \times 25) \text{ cm}^2$, conhecido como F-SAR, desenvolvido pelo centro aeroespacial da Alemanha (DLR). Esse sistema pode adquirir, simultaneamente, dados nas bandas X, C, S, L e P, gerando em torno de 20 GB min^{-1}



Figura 2.3: Baía de São Francisco.



Figura 2.4: Polarização vv.

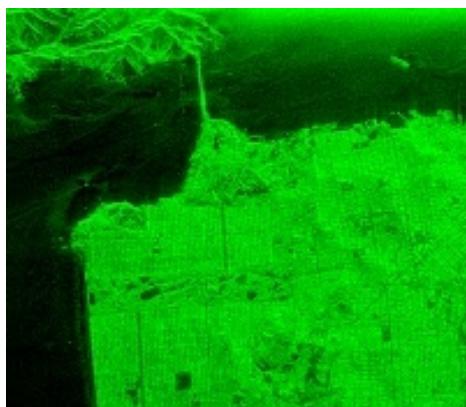


Figura 2.5: Polarização hv.



Figura 2.6: Polarização hh.

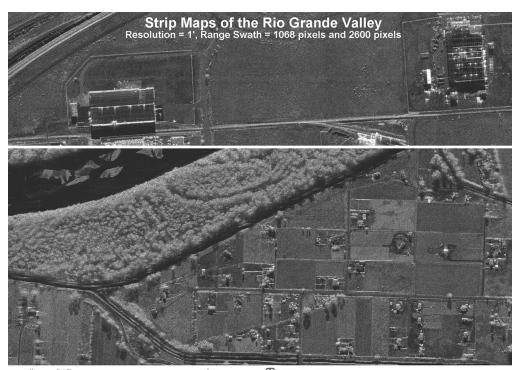


Figura 2.7: Imagem da região do Rio Grande Valley

de dados.

Destacamos ainda o projeto *SAtélite Argentino de Observación CON Microondas* (SAOCOM) pela atualidade e importância para o monitoramento da América Latina, informações podem ser obtidas no sítio web <https://directory.eoportal.org/web/eoportal/satellite-missions/s/saocom>. O SAOCOM-1B segundo satélite produzido pelo projeto foi

Tabela 2.6: Características do sistema Lynx (SAR).

Características específicas	Valores operacionais
Frequência	15.2–18.2 GHz
Altitude	7 km
Peso	57 kg
Ângulo de inclinação	45–135°
Distância lateral	7–30 km
Banda	K _u
Polarização	vv - Onda emitida e recebida na direção vertical
Resolução inferior	(10 × 10) cm ²
Resolução superior	(30 × 30) cm ²

colocado em órbita em 2020 conforme <https://www.space.com/spacex-saocom-1b-launch-rocket-landing-success.html>.

Como curiosidades, podemos citar:

- O projeto de um mini-SAR para uso em veículos aéreos não tripulados que focam na evolução da micro-eletrônica para aumentar a eficiência e diminuir o peso, por exemplo, o projeto Lynx;
- As imagens SAR podem ser captadas por satélites, orbitando outros planetas, como o projeto Magellan SAR que orbita Vênus, o satélite foi lançado em 1989 com duração prevista de 5 anos. A figura 2.8 mostra o planeta Vênus captura pelo satélite Magellan, mais informações sobre o projeto poder ser encontradas no Sítio eletrônico <https://www2.jpl.nasa.gov/magellan/>;
- Outra tecnologia usada para a captação de imagens SAR denominada de interferométrica SAR (InSAR), usa dois ou mais radares de abertura sintética para obter imagens, podendo ser em posições diferentes ou tempos distintos. O sensor InSAR possibilita medir deslocamentos de objetos de interesse em uma região definida da imagem. Um tutorial sobre os sensores InSAR podem ser encontrado no Sítio eletrônico https://www.esa.int/About_Us/ESA_Publications/InSAR_Principles_Guidelines_for_SAR_Interferometry_Processing_and_Interpretation_br_ESA_TM-19.

Os sistemas SAR e PolSAR apresentam algumas características inerentes à física do imageamento e à engenharia da sua implementação. E podemos destacar como desvantagens:

- O sistema requer o conhecimento da rota do radar;
- O sistema é sensível ao movimento do alvo;

- O processamento para a geração de uma imagem é complexo.



Figura 2.8: Imagem do planeta Vênus capturada pelo satélite Magellan

Entretanto, as desvantagens nos sistemas SAR e PolSAR não evitam as mesmas de serem largamente empregadas, o que impulsiona a produção de conhecimento nessa área, gerando um grande interesse, tanto em nível de aplicações, como em pesquisas científicas, como podemos ver na referência Reigber *et al.* (2013) ou no sítio https://www.dlr.de/hr/en/desktopdefault.aspx/tabid-2326/3776_read-5691/.

Capítulo 3

Metodologia

Com o objetivo de apresentar os aspectos metodológicos e teóricos desta tese, optou-se por organizar este capítulo em seções que se inter-relacionam para fornecer a descrição dos modelos, das detecção de bordas e das abordagens para a fusão das evidências de bordas.

3.1 Modelagem estatística para dados PolSAR

Os sistemas PolSAR transmitem pulsos de micro-ondas polarizados ortogonalmente e medem componentes ortogonais do sinal recebido. Para cada pixel, a medida resulta em uma matriz de coeficientes de espalhamento. Esses coeficientes são números complexos que descrevem no sistema SAR a transformação do campo eletromagnético transmitido para o campo eletromagnético recebido.

A transformação pode ser representada como

$$\begin{bmatrix} E_h^r \\ E_v^r \end{bmatrix} = \frac{e^{ikd}}{d} \begin{bmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{bmatrix} \begin{bmatrix} E_h^t \\ E_v^t \end{bmatrix},$$

onde k denota o número de onda, i é um número complexo e d é a distância entre o radar e o alvo. No campo eletromagnético com componentes E_i^j , o índice subscrito denota polarização horizontal (h) ou vertical (v), e o índice sobreescrito indica a onda recebida (r) ou transmitida (t).

A matriz de espalhamento complexa \mathbf{S} é definida por

$$\mathbf{S} = \begin{bmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{bmatrix}, \quad (3.1)$$

onde as entradas da matriz $S_{i,j}$ são os coeficientes de espalhamento complexo, tal que os índices i e j são associados ao recebimento e a transmissão das ondas, por exemplo,

o coeficiente de espalhamento S_{hv} está associado a onda transmitida na direção vertical (v) e recebida na direção horizontal (h).

Definindo a diagonal principal da matriz de espalhamento por co-polarização pois relaciona a polarização das ondas transmitidas e recebidas nas mesmas direções, e os elementos da diagonal secundária da matriz de espalhamento por polarização cruzada relacionando os estados de polarizações ortogonais.

A potência total espalhada no caso de um sistema de radar polarimétrico é o chamado *Span*, sendo definido no caso geral como,

$$Span(\mathbf{S}) = \text{tr}(\mathbf{SS}^H) = |S_{hh}|^2 + |S_{hv}|^2 + |S_{vh}|^2 + |S_{vv}|^2, \quad (3.2)$$

onde o operador $\text{tr}(\cdot)$ é o traço de uma matriz.

3.1.1 Matriz de coerência polarimétrica de Pauli (T_4) e matriz de covariância lexicográfica (C_4)

A matriz de espalhamento \mathbf{S} pode ser representada pela construção do vetor,

$$\mathbf{k} = \frac{1}{2} [\text{tr}(\mathbf{S}\Psi_1) \quad \text{tr}(\mathbf{S}\Psi_2) \quad \text{tr}(\mathbf{S}\Psi_3) \quad \text{tr}(\mathbf{S}\Psi_4)]^T, \quad (3.3)$$

onde $\{\Psi_i\}_{i=1}^4$ é uma base para o espaço das matrizes hermitianas 2×2 .

Diferentes bases para o mesmo espaço das matrizes podem ser definidas, vamos escolher duas bases, a primeira chamada de base de Pauli,

$$\{\Psi_P\} = \left\{ \sqrt{2} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \sqrt{2} \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, \sqrt{2} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \sqrt{2} \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix} \right\}, \quad (3.4)$$

e a segunda chamada de base lexicográfica,

$$\{\Psi_L\} = \left\{ 2 \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, 2 \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, 2 \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}, 2 \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} \right\}. \quad (3.5)$$

Sendo o vetor (3.3), e usando a base (3.4) representamos a matriz de espalhamento pelo vetor característico de Pauli 4-D,

$$\mathbf{k} = \frac{1}{\sqrt{2}} \begin{bmatrix} S_{hh} + S_{vv} & S_{hh} - S_{vv} & S_{hv} + S_{vh} & i(S_{hv} - S_{vh}) \end{bmatrix}^T = \frac{1}{\sqrt{2}} [k_1 \quad k_2 \quad k_3 \quad k_4], \quad (3.6)$$

e usando a base (3.5) representamos a matriz de espalhamento pelo vetor característico lexicográfico 4-D,

$$\boldsymbol{\Omega} = \begin{bmatrix} S_{hh} & S_{hv} & S_{vh} & S_{vv} \end{bmatrix}^T = [\Omega_1 \quad \Omega_2 \quad \Omega_3 \quad \Omega_4]. \quad (3.7)$$

A matriz de espalhamento pode ser relacionada com os vetores (3.6) e (3.7) da seguinte maneira,

$$\mathbf{S} = \begin{bmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{bmatrix} = \begin{bmatrix} \Omega_1 & \Omega_2 \\ \Omega_3 & \Omega_4 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} k_1 + k_2 & k_3 - ik_4 \\ k_3 + ik_4 & k_1 - k_2 \end{bmatrix} \quad (3.8)$$

As constantes 2 e $\sqrt{2}$ nas bases (3.4) e (3.5) ajustam a norma dos vetores de espalhamento para serem iguais, independente da escolha das bases. O produto interno escolhido é o padrão para o espaço vetorial dos vetores complexos de dimensão 4, isto é, se \mathbf{u} e \mathbf{v} são vetores complexos, o produto interno é $\mathbf{u}^H \mathbf{v}$.

Podemos assim garantir a invariância do

$$\begin{aligned} \text{Span}(\mathbf{S}) &= \text{tr}(\mathbf{SS}^H) = |S_{hh}|^2 + |S_{hv}|^2 + |S_{vh}|^2 + |S_{vv}|^2 \\ &= \mathbf{k}^H \mathbf{k} = |\mathbf{k}|^2 \\ &= \boldsymbol{\Omega}^H \boldsymbol{\Omega} = |\boldsymbol{\Omega}|^2. \end{aligned} \quad (3.9)$$

A matriz unitária \mathbf{U}_4 é definida como a representação matricial da transformação linear que aplica o vetor na base lexicográfica em um vetor na base de Pauli. Podemos gerar a matriz unitária colocando nas linhas da matriz os elementos da base de Pauli, portanto

$$\mathbf{U}_4 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & -1 \\ 0 & 1 & 1 & 0 \\ 0 & i & -i & 0 \end{bmatrix}. \quad (3.10)$$

A transformação linear $\mathbf{k} = \mathbf{U}_4 \boldsymbol{\Omega}$, representada na forma matricial,

$$\frac{1}{\sqrt{2}} \begin{bmatrix} S_{hh} + S_{vv} \\ S_{hh} - S_{vv} \\ S_{hv} + S_{vh} \\ i(S_{hv} - S_{vh}) \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & -1 \\ 0 & 1 & 1 & 0 \\ 0 & i & -i & 0 \end{bmatrix} \begin{bmatrix} S_{hh} \\ S_{hv} \\ S_{vh} \\ S_{vv} \end{bmatrix}, \quad (3.11)$$

foi definida para demonstrar a transformação similar entre a matriz de coerência, e a matriz de covariância definidas a seguir.

A matriz de coerência polarimétrica de Pauli é definida por,

$$\mathbf{T}_4 = \mathbf{k} \mathbf{k}^H = \begin{bmatrix} |k_1|^2 & k_1 \bar{k}_2 & k_1 \bar{k}_3 & k_1 \bar{k}_4 \\ k_2 \bar{k}_1 & |k_2|^2 & k_2 \bar{k}_3 & k_2 \bar{k}_4 \\ k_3 \bar{k}_1 & k_3 \bar{k}_2 & |k_3|^2 & k_3 \bar{k}_4 \\ k_4 \bar{k}_1 & k_4 \bar{k}_2 & k_4 \bar{k}_3 & |k_4|^2 \end{bmatrix}, \quad (3.12)$$

e a matriz de covariância lexicográfica

$$\mathbf{C}_4 = \mathbf{\Omega}\mathbf{\Omega}^H = \begin{bmatrix} |\Omega_1|^2 & \Omega_1\bar{\Omega}_2 & \Omega_1\bar{\Omega}_3 & \Omega_1\bar{\Omega}_4 \\ \Omega_2\bar{\Omega}_1 & |\Omega_2|^2 & \Omega_2\bar{\Omega}_3 & \omega_2\bar{\Omega}_4 \\ \Omega_3\bar{\Omega}_1 & \Omega_3\bar{\Omega}_2 & |\Omega_3|^2 & \Omega_3\bar{\Omega}_4 \\ \Omega_4\bar{\Omega}_1 & \Omega_4\bar{\Omega}_2 & \Omega_4\bar{\Omega}_3 & |\Omega_4|^2 \end{bmatrix}. \quad (3.13)$$

As matrizes de coerência polarimétrica de Pauli e covariância lexicográfica são relacionadas usando as definições e a propriedade (3.11), assim teremos

$$\begin{aligned} \mathbf{T}_4 &= \mathbf{k}\mathbf{k}^H = \mathbf{U}_4\mathbf{\Omega}(\mathbf{U}_4\mathbf{\Omega})^H \\ &= \mathbf{U}_4\mathbf{\Omega}\mathbf{\Omega}^H\mathbf{U}_4^H = \mathbf{U}_4\mathbf{C}_4\mathbf{U}_4^H \end{aligned}$$

então, a relação de similaridade entre as matrizes é,

$$\mathbf{T}_4 = \mathbf{U}_4\mathbf{C}_4\mathbf{U}_4^H \quad (3.14)$$

lembrando que \mathbf{U}_4 é unitária, e o traço é a soma dos autovalores de uma matriz, concluímos

$$\text{tr}(\mathbf{T}_4) = \text{tr}(\mathbf{C}_4) = \text{Span}(\mathbf{S}). \quad (3.15)$$

3.1.2 Matriz de coerência polarimétrica de Pauli (\mathbf{T}_3) e matriz de covariância lexicográfica (\mathbf{C}_3)

Podemos entender as interações das ondas eletromagnéticas em alvos naturais sob a ótica do teorema da reciprocidade, o qual considera o meio reciproco. De uma maneira geral as propriedades de transmissão e recebimento de uma antena são idênticos, e mono-estáticos, ou seja, consideramos o sistema de coordenada BSA - *Back Scattering Alignment*. Em meio reciproco podemos definir a igualdade dos termos de polarização cruzada $S_{hv} = S_{vh}$. Veja [Lee e Pottier \(2009\)](#).

A matriz de espalhamento \mathbf{S} pode ser representada pela construção do vetor,

$$\mathbf{k} = \frac{1}{2} [\text{tr}(S\Psi_1) \quad \text{tr}(S\Psi_2) \quad \text{tr}(S\Psi_3)]^T, \quad (3.16)$$

onde $\{\Psi_i\}_{i=1}^3$ é uma base para o espaço das matrizes hermitianas 2×2 .

Diferentes bases para o mesmo espaço das matrizes podem ser definidas, vamos escolher duas bases, a primeira chamada de base de Pauli,

$$\{\Psi_P\} = \left\{ \sqrt{2} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \sqrt{2} \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, \sqrt{2} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \right\}, \quad (3.17)$$

e a segunda chamada de base lexicográfica

$$\{\Psi_L\} = \left\{ 2 \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, 2\sqrt{2} \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, 2 \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} \right\}. \quad (3.18)$$

Sendo o vetor (3.16), e usando a base (3.17) representamos a matriz de espalhamento pelo vetor característico de Pauli 3-D,

$$\mathbf{k} = \frac{1}{\sqrt{2}} \begin{bmatrix} S_{hh} + S_{vv} & S_{hh} - S_{vv} & 2S_{hv} \end{bmatrix}^T = \frac{1}{\sqrt{2}} [k_1 \ k_2 \ k_3], \quad (3.19)$$

e usando a base (3.18) representamos a matriz de espalhamento pelo vetor característico lexicográfico 3-D,

$$\boldsymbol{\Omega} = \frac{1}{\sqrt{2}} \begin{bmatrix} S_{hh} & S_{hv} & S_{vv} \end{bmatrix}^T = [\Omega_1 \ \Omega_2 \ \Omega_3]. \quad (3.20)$$

As constantes 2 e $\sqrt{2}$ nas bases (3.17) e (3.18) servem para manter a norma dos vetores de espalhamento iguais, independente da escolha das bases. O produto interno escolhido é o padrão para o espaço vetorial dos vetores complexos de dimensão 3, isto é, se \mathbf{u} e \mathbf{v} são vetores complexos, o produto interno é $\mathbf{u}^H \mathbf{v}$.

Podemos assim garantir a invariância da potencia total,

$$\begin{aligned} Span(\mathbf{S}) &= \text{tr}(\mathbf{SS}^H) = |S_{hh}|^2 + 2|S_{hv}|^2 + |S_{vv}|^2 \\ &= \mathbf{k}^H \mathbf{k} = |\mathbf{k}|^2 \\ &= \boldsymbol{\Omega}^H \boldsymbol{\Omega} = |\boldsymbol{\Omega}|^2 \end{aligned} \quad (3.21)$$

A matriz unitária \mathbf{U}_3 é definida como a representação matricial da transformação linear que aplica o vetor na base lexicográfica em um vetor na base de Pauli. Podemos gerar a matriz unitária colocando nas linhas da matriz os elementos da base de Pauli, portanto

$$\mathbf{U}_3 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & 1 \\ 1 & 0 & -1 \\ 0 & \sqrt{2} & 0 \end{bmatrix}. \quad (3.22)$$

A transformação linear $\mathbf{k} = \mathbf{U}_3 \boldsymbol{\Omega}$, representado na forma matricial,

$$\frac{1}{\sqrt{2}} \begin{bmatrix} S_{hh} + S_{vv} \\ S_{hh} - S_{vv} \\ 2S_{hv} \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & 1 \\ 1 & 0 & -1 \\ 0 & 2 & 0 \end{bmatrix} \begin{bmatrix} S_{hh} \\ S_{hv} \\ S_{vv} \end{bmatrix} \quad (3.23)$$

foi definida para demonstrar a transformação similar entre a matriz de coerência, e a matriz de covariância definidas a seguir.

A matriz de coerência polarimétrica de Pauli é definida por,

$$\mathbf{T}_3 = \mathbf{kk}^H = \begin{bmatrix} |k_1|^2 & k_1\bar{k}_2 & k_1\bar{k}_3 \\ k_2\bar{k}_1 & |k_2|^2 & k_2\bar{k}_3 \\ k_3\bar{k}_1 & k_3\bar{k}_2 & |k_3|^2 \end{bmatrix}, \quad (3.24)$$

e a matriz de covariância lexicográfica

$$\mathbf{C}_3 = \boldsymbol{\Omega}\boldsymbol{\Omega}^H = \begin{bmatrix} |\Omega_1|^2 & \Omega_1\bar{\Omega}_2 & \Omega_1\bar{\Omega}_3 \\ \Omega_2\bar{\Omega}_1 & |\Omega_2|^2 & \Omega_2\bar{\Omega}_3 \\ \Omega_3\bar{\Omega}_1 & \Omega_3\bar{\Omega}_2 & |\Omega_3|^2 \end{bmatrix}. \quad (3.25)$$

As matrizes de coerência polarimétrica de Pauli e covariância lexicográfica são relacionadas usando as definições e a propriedade (3.11), assim teremos

$$\begin{aligned} \mathbf{T}_3 &= \mathbf{kk}^H = \mathbf{U}_3 \boldsymbol{\Omega} (\mathbf{U}_3 \boldsymbol{\Omega})^H \\ &= \mathbf{U}_3 \boldsymbol{\Omega} \boldsymbol{\Omega}^H \mathbf{U}_3^H = \mathbf{U}_3 \mathbf{C}_3 \mathbf{U}_3^H, \end{aligned}$$

então, a relação de similaridade entre as matrizes é,

$$\mathbf{T}_3 = \mathbf{U}_3 \mathbf{C}_3 \mathbf{U}_3^H, \quad (3.26)$$

lembrando que \mathbf{U}_3 é unitária, e o traço é a soma dos autovalores de uma matriz, concluímos

$$\text{tr}(\mathbf{T}_3) = \text{tr}(\mathbf{C}_3) = \text{Span}(\mathbf{S}). \quad (3.27)$$

Portanto podemos afirmar, se

$$\mathbf{s} = \begin{bmatrix} S_{hh} \\ \sqrt{2}S_{hv} \\ S_{vv} \end{bmatrix}, \quad (3.28)$$

a potência total espalhada no caso de um sistema de radar polarimétrico em meio recíproco pode ser definido por

$$\text{Span} = \text{tr}(\mathbf{SS}^H) = |S_{hh}|^2 + 2|S_{hv}|^2 + |S_{vv}|^2. \quad (3.29)$$

3.1.3 Estatística do Ruído *Speckle* no processo de única visada

As imagens SAR e PolSAR possuem um tipo de ruído multiplicativo chamado *speckle*, conhecido por causar variação de intensidade pixel a pixel, imprimindo um aspecto granular as imagens.

O *speckle* dificulta a interpretação e análise das imagens reduzindo a efetividade

da segmentação, classificação, ou detecção de mudanças de características das imagens SAR e PolSAR. O entendimento do comportamento estatístico do *speckle* é essencial para extrair boas informações das imagens e propor algoritmos efetivos para tratar esse tipo de ruído.

Neste trabalho usaremos as características do ruído *speckle* para auxiliar na detecção de borda, em oposição a trabalhos que tentam mitigar o efeito do ruído.

A formação do *speckle* surge quando o radar ilumina uma superfície rugosa, como florestas, plantações, áreas urbanas, e etc, então o sinal de retorno consiste em ondas refletidas com muitos elementos de espalhamentos. Os elementos de espalhamento têm geometrias complexas e distribuições aleatórias, tornando a modelagem estatística uma tarefa indispensável e desafiadora. Podemos considerar três tipos de processos de espalhamento da onda em alvos (elementos de espalhamento). A dispersão de superfície, a dispersão de volume, e o espalhamento de volume-superfície. O primeiro é o espalhamento que acontece quando a onda eletromagnética atravessa uma mudança de meio de propagação. O segundo, consiste no espalhamento que acontece na profundidade de um meio, por exemplo, o espalhamento no interior de uma floresta. E por último, o espalhamento volume-superfície, que consiste em a onda atingir outra troca de meio de propagação, por exemplo o solo de uma floresta.

As distância entre os elementos de espalhamento e o recebimento no radar varia devido a natureza randômica da disposição desse elemento. A onda recebida de cada elemento espalhador embora coerente em frequência não são coerentes em fase. O sinal é forte se as ondas são construtivas, ou seja em fase, e fraco se as ondas não estão em fase.

Podemos escrever um sinal complexo da seguinte forma.

$$\sum_{i=1}^M (x_i + \hat{y}_i) = \sum_{i=1}^M x_i + \hat{j} \sum_{i=1}^M y_i = x + \hat{y} = r \exp(\hat{j}\theta), \quad (3.30)$$

onde, $x_i + \hat{y}_i$ é o retorno do espalhamento para cada elemento i , se existem M elementos espalhadores então $x + \hat{y}$ é soma destes elementos, e $r \exp(\hat{j}\theta)$ é a decomposição de Euler para o número complexo $x + \hat{y}$.

3.1.3.1 Modelo de Rayleigh para o *speckle*

Definir um modelo para o *speckle* é muito importante na tarefa de obter informação de imagens SAR e PolSAR. Com esse objetivo, podemos determinar as seguintes condições para a modelagem:

- Um número grande de espalhadores em uma região (célula de resolução) considerada um meio homogêneo.

- A distância de alcance é muito maior que o comprimento de onda do radar.
- A superfície tem maior rugosidade na escala do comprimento de onda de um radar.

O *speckle* totalmente desenvolvido é definido utilizando o vetor soma (3.30) para os retornos dos espalhamentos de alvos de forma que a sua fase seja distribuída uniformemente no intervalo $(-\pi, \pi)$.

O teorema do limite central para o *speckle* totalmente desenvolvido garante que as componentes x e y sejam gaussianas independentes e identicamente distribuídas com média zero e variância $\frac{\sigma^2}{2}$. Podemos representar a sua função densidade de probabilidade conjunta por,

$$\begin{aligned} f_{XY}(x, y; \sigma^2) &= f_X(x; \sigma^2) f_Y(y; \sigma^2) \\ &= \frac{1}{\sqrt{\pi}\sigma} \exp\left(-\frac{x^2}{\sigma^2}\right) \frac{1}{\sqrt{\pi}\sigma} \exp\left(-\frac{y^2}{\sigma^2}\right) = \frac{1}{\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{\sigma^2}\right), \end{aligned} \quad (3.31)$$

sendo $x = z_A \cos \theta$, e $y = z_A \sin \theta$ teremos,

$$f_A(z_A; \sigma^2) = \frac{z_A}{\pi\sigma^2} \exp\left(-\frac{z_A^2(\cos^2 \theta + \sin^2 \theta)}{\sigma^2}\right) = \frac{z_A}{\pi\sigma^2} \exp\left(-\frac{z_A^2}{\sigma^2}\right). \quad (3.32)$$

Integrando na variável θ no intervalo de $[-\pi, \pi]$ encontramos a distribuição para a amplitude.

$$f_A(z_A; \sigma^2) = \int_{-\pi}^{\pi} \frac{z_A}{\pi\sigma^2} \exp\left(-\frac{z_A^2}{\sigma^2}\right) d\theta = \frac{z_A}{\pi\sigma^2} \exp\left(-\frac{z_A^2}{\sigma^2}\right) \int_{-\pi}^{\pi} d\theta,$$

definida como a distribuição Rayleigh com PDF

$$f_A(z_A; \sigma^2) = \frac{2z_A}{\sigma^2} \exp\left(-\frac{z_A^2}{\sigma^2}\right).$$

Podemos encontrar o valor esperado

$$E[z_A] = \int_0^\infty z_A f(z_A) dA = \int_0^\infty \frac{2z_A^2}{\sigma^2} \exp\left(-\frac{z_A^2}{\sigma^2}\right) dz_A = \frac{\sqrt{\pi}\sigma}{2},$$

e

$$E[z_A^2] = \int_0^\infty z_A^2 f(z_A) dA = \int_0^\infty \frac{2z_A^3}{\sigma^2} \exp\left(-\frac{z_A^2}{\sigma^2}\right) dz_A = \sigma^2,$$

com o objetivo de calcular a variância

$$\text{var} = E[z_A^2] - E[z_A]^2 = \sigma^2 - \left(\frac{\sqrt{\pi}\sigma}{2}\right)^2 = \sigma^2 - \frac{\pi\sigma^2}{4}.$$

O coeficiente de variação pode ser calculado por

$$\text{CV}(Z_A) = \frac{\sqrt{\text{var}}}{E[A]} = \frac{\sqrt{\sigma^2 - \frac{\pi\sigma^2}{4}}}{\frac{\sqrt{\pi}\sigma}{2}} = \sqrt{\frac{\sigma^2 - \frac{\pi\sigma^2}{4}}{\frac{\pi\sigma^2}{4}}} = \sqrt{\frac{4}{\pi} - 1} = 0,5227. \quad (3.33)$$

A intensidade é definida por $z_I = z_A^2$, então sua função densidade de probabilidade é escrita por,

$$f_I(z_I; \sigma^2) = \frac{1}{\sigma^2} \exp\left(-\frac{z_I}{\sigma^2}\right),$$

calculando $E[I] = \sigma^2$, e $E[I^2] = 2\sigma^2$, teremos a variância $\text{var} = \sigma^4$, e o coeficiente de variação $\text{CV}(Z_I) = \frac{\sqrt{\sigma^2}}{\sigma^2} = 1$.

Comparando os valores $\text{CV}(Z_A)$ e $\text{CV}(Z_I)$ podemos afirmar que o valor do *speckle* é mais pronunciado nas imagens de intensidade em relação com as imagens de amplitude.

3.1.4 Estatística do ruído *Speckle* no processo de múltiplas visadas

O processo de redução do ruído *speckle* consiste em realizar a média aritmética de vários sinais de retorno, processo conhecido por múltiplas visadas. O método pode ser descrito como adquirir L imagens e realizar a média aritmética das mesmas.

Definimos a função densidade de probabilidade para os canais de intensidades com múltiplas visadas por,

$$f_I(z_I; L, \sigma^2) = \frac{L^L z_I^{L-1}}{(L-1)! \sigma^{2L}} \exp\left(-L \frac{z_I}{\sigma^2}\right), z_I \geq 0. \quad (3.34)$$

A média e a variância são respectivamente, $M_L(z_I) = \sigma^2$, $\text{var}_L(z_I) = \frac{\sigma^4}{L}$ implicando que o desvio padrão será $SD_L(z_I) = \frac{\sigma^2}{\sqrt{L}}$. O coeficiente de variação é calculado pela razão entre o desvio padrão e a média, resultando para o caso de múltiplas visadas em $\text{CV}_L(z_I) = \frac{1}{\sqrt{L}}$. Podemos observar que o coeficiente de variação é reduzido por \sqrt{L} com relação ao processo de visada simples.

A função densidade de probabilidade para os canais de amplitude com múltiplas visadas, pode ser definida como,

$$f_A(z_A; L, \sigma^2) = \frac{2L^L z_A^{2L-1}}{(L-1)! \sigma^{2L}} \exp\left(-L \frac{z_A^2}{\sigma^2}\right), z_A \geq 0. \quad (3.35)$$

A média e a variância são $M_L(z_A) = \frac{\Gamma(L+\frac{1}{2})}{\Gamma} \sqrt{\frac{\sigma^2}{L}}$ e $\text{var}_L(z_A) = \left(L - \frac{\Gamma^2(L+\frac{1}{2})}{\Gamma^2(L)}\right) \frac{\sigma^2}{L}$ respectivamente. Assim, o coeficiente de variação $\text{CV}_L(z_A) = \sqrt{\frac{L\Gamma^2(L)}{\Gamma^2(L+\frac{1}{2})}} - 1$ é calculado para os canais de amplitude, sendo que Γ denota a função gamma.

A tabela (3.1) mostra os coeficientes de variações para os canais de intensidades e

amplitudes,

Tabela 3.1: Coeficientes de variação.

Número de visadas (L)	CV (intensidade)	CV (amplitude)
1	1	0.5227
2	0.7071	0.3629
3	0.5773	0.2941
4	0.5000	0.2536
5	0.4472	0.2262
6	0.4082	0.2061
7	0.3779	0.1906
8	0.3535	0.1781

3.2 Matriz de covariância

A matriz de espalhamento hermitiana em meio recíproco \mathbf{S} definida em (3.1),

$$\mathbf{S} = \begin{bmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{bmatrix},$$

que respeita o teorema da reciprocidade para meios recíprocos pode ser representada por um vetor da seguinte forma

$$\mathbf{s} = \begin{bmatrix} S_{hh} \\ \sqrt{2}S_{hv} \\ S_{vv} \end{bmatrix}. \quad (3.36)$$

Nas imagens PolSAR serão consideradas três componentes para o vetor

$$\mathbf{s} = [S_{hh}, S_{vh}, S_{vv}]^H$$

e a multiplicação de \mathbf{s} pelo seu conjugado transposto \mathbf{s}^H é,

$$\mathbf{s}\mathbf{s}^H = \begin{bmatrix} S_{hh} \\ S_{vh} \\ S_{vv} \end{bmatrix} \begin{bmatrix} S_{hh} & S_{vh} & S_{vv} \end{bmatrix}^H = \begin{bmatrix} S_{hh}\overline{S_{hh}} & S_{hh}\overline{S_{vh}} & S_{hh}\overline{S_{vv}} \\ S_{vh}\overline{S_{hh}} & S_{vh}\overline{S_{vh}} & S_{vh}\overline{S_{vv}} \\ S_{vv}\overline{S_{hh}} & S_{vv}\overline{S_{vh}} & S_{vv}\overline{S_{vv}} \end{bmatrix}. \quad (3.37)$$

Definindo $S_j = R_j + \hat{i}I_j$, onde $j = \{\text{hh}, \text{hv}, \text{vv}\}$

$$\begin{aligned} S_j \bar{S}_j &= (R_j + \hat{i}I_j)(\overline{R_j + \hat{i}I_j}), \\ &= (R_j + \hat{i}I_j)(R_j - \hat{i}I_j), \\ &= R_j^2 - \hat{i}R_j I_j + \hat{i}I_j R_j + I_j^2, \\ &= R_j^2 + I_j^2, \end{aligned}$$

portanto,

$$S_j \bar{S}_j = R_j^2 + I_j^2,$$

é um numero real, assim o seu conjugado é próprio número real.

Considerando $j \neq k$, onde j, k variam no conjunto de polarizações $\{\text{hh}, \text{hv}, \text{vv}\}$

$$\begin{aligned} S_j \bar{S}_k &= (R_j + \hat{i}I_j)(\overline{R_k + \hat{i}I_k}), \\ &= (R_j + \hat{i}I_j)(R_k - \hat{i}I_k), \\ &= (R_j R_k + I_j I_k) + \hat{i}(R_k I_j - R_j I_k), \end{aligned}$$

portanto,

$$S_j \bar{S}_k = (R_j R_k + I_j I_k) + \hat{i}(R_k I_j - R_j I_k),$$

ainda,

$$\begin{aligned} \bar{S}_k \bar{S}_j &= \overline{(R_k + \hat{i}I_k)(R_j + \hat{i}I_j)}, \\ &= \overline{(R_k + \hat{i}I_k)(R_j - \hat{i}I_j)}, \\ &= \overline{(R_k R_j + I_k I_j) + \hat{i}(R_j I_k - R_k I_j)}, \\ &= (R_k R_j + I_k I_j) - \hat{i}(R_j I_k - R_k I_j), \\ &= (R_k R_j + I_k I_j) + \hat{i}(R_k I_j - R_j I_k), \end{aligned}$$

assim

$$\bar{S}_k \bar{S}_j = (R_k R_j + I_k I_j) + \hat{i}(R_k I_j - R_j I_k),$$

com as igualdade,

$$\begin{aligned} S_j \bar{S}_j &= \bar{S}_j \bar{S}_j, \\ S_j \bar{S}_k &= \bar{S}_k \bar{S}_j, \end{aligned} \tag{3.38}$$

para cada j e k no conjunto das polarizações, concluímos que $\mathbf{s}\mathbf{s}^H$ é simétrica, portanto podemos afirmar que a matriz $\mathbf{athbf{\Sigma}}$ definida por,

$$\boldsymbol{\Sigma} = E[\mathbf{s}\mathbf{s}^H] = \begin{bmatrix} E[S_{\text{hh}} \bar{S}_{\text{hh}}] & E[S_{\text{hh}} \bar{S}_{\text{hv}}] & E[S_{\text{hh}} \bar{S}_{\text{vv}}] \\ E[S_{\text{vh}} \bar{S}_{\text{hh}}] & E[S_{\text{vh}} \bar{S}_{\text{hv}}] & E[S_{\text{vh}} \bar{S}_{\text{vv}}] \\ E[S_{\text{vv}} \bar{S}_{\text{hh}}] & E[S_{\text{vv}} \bar{S}_{\text{hv}}] & E[S_{\text{vv}} \bar{S}_{\text{vv}}] \end{bmatrix}, \tag{3.39}$$

é uma matriz simétrica, onde $E[\cdot]$ denota o valor esperado.

Neste trabalho é necessário considerar a distribuição gaussiana circular complexa multivariada com média zero. Definida de acordo com [Goodman \(1985\)](#) ou [Goodman](#)

(1963) por:

- $E[R_j] = E[I_j] = 0$,
- $E[R_j^2] = E[I_j^2]$,
- $E[R_j I_j] = 0$,
- $E[R_j R_k] = E[I_j I_k]$, e
- $E[I_j R_k] = -E[R_j I_k]$.

onde, $E[\cdot]$ denota o valor esperado, e j, k são índices no conjunto das polarizações.

3.3 Função Wishart densidade de probabilidade para os canais de intensidades

Dados polarimétricos são usualmente sujeitados a um processo de múltiplas visadas com o objetivo de melhorar a relação entre o sinal e o ruído. Para esse fim, matrizes positivas definidas hermitianas estimadas são obtidas computando a média de L visadas independentes de uma mesma cena. Resultando na matriz de covariância amostral estimada \mathbf{Z} conforme a referências Anfinsen *et al.* (2009); Goodman (1963),

$$\mathbf{Z} = \frac{1}{L} \sum_{i=1}^L \mathbf{s}_i \mathbf{s}_i^H, \quad (3.40)$$

onde \mathbf{s}_i com $i = 1, \dots, L$ é uma amostra de L vetores complexos distribuídos como \mathbf{s} . Desta maneira, a matriz de covariância amostral associada a \mathbf{s}_i , com $i = 1, \dots, L$ denotam o espalhamento para cada visada L seguindo uma distribuição complexas de Wishart.

De acordo com Goodman (1963) para definir a distribuição Wishart é necessário a hipótese da distribuição ser gaussiana circular complexa multivariada com média zero como definimos acima.

Nas referências Goodman (1963) e Lee *et al.* (1994) foi mostrado que a distribuição Wishart pode modelar adequadamente o comportamento estatístico de \mathbf{s} . A hipótese de ser gaussiana e circular foi comprovada para dados SAR polarimétricos no artigo Sarabandi (1992).

Sendo Σ e L parâmetros conhecidos, a função densidade de probabilidade para a distribuição Wishart é definida por,

$$f_{\mathbf{Z}}(\mathbf{z}; \Sigma, L) = \frac{L^{mL} |\mathbf{z}|^{L-m}}{|\Sigma|^L \Gamma_m(L)} \exp(-L \text{tr}(\Sigma^{-1} \mathbf{z})), \quad (3.41)$$

onde, $\text{tr}(\cdot)$ é o operador traço de uma matriz, $\Gamma_m(L)$ é uma função Gamma multivariada definida por

$$\Gamma_m(L) = \pi^{\frac{1}{2}m(m-1)} \prod_{i=0}^{m-1} \Gamma(L-i) \quad (3.42)$$

e $\Gamma(\cdot)$ é a função Gamma. Podemos afirmar que \mathbf{Z} é distribuído como uma distribuição Wishart representado por $\mathbf{Z} \sim W(\Sigma, L)$, e satisfazendo $E[\mathbf{Z}] = \Sigma$. Neste trabalho vamos considerar os três canais de intensidades, $m = 3$.

A figura (3.1) mostra a distribuição wishart com os parâmetros fixos $\sigma = 0.01$ e o número de visadas $L = 2, 3, 4, 8$.

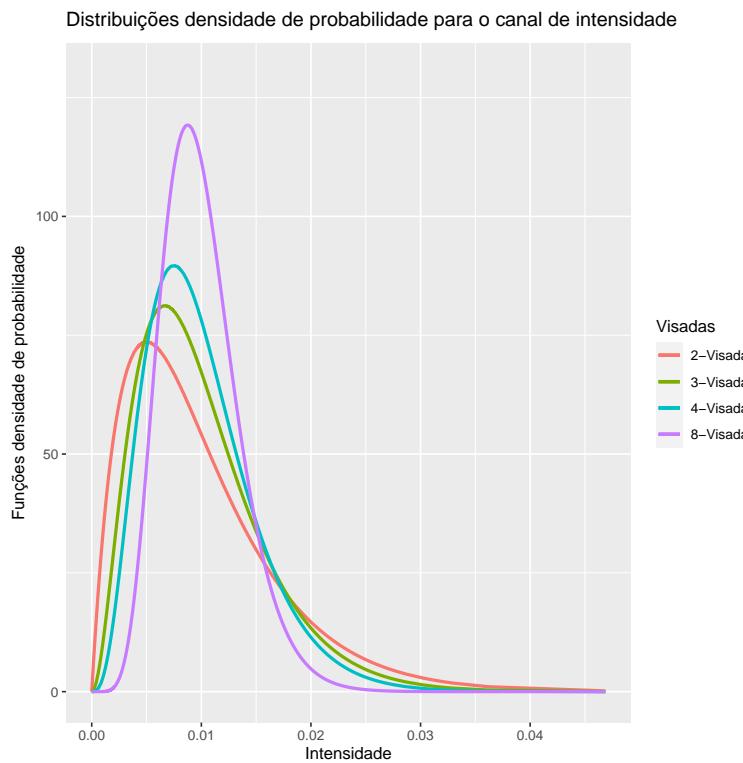


Figura 3.1: Distribuições Wishart multiplas visadas com $\sigma = 0.01$.

Considerando a função densidade de probabilidade da distribuição complexa Wishart (3.41) vamos usar o logaritmo natural e suas propriedades para reescrever a função na

forma adequada para aplicações ao longo do texto,

$$\begin{aligned}
 \ln f_{\mathbf{Z}}(\mathbf{z}; \Sigma, L) &= \ln \left(\frac{L^{mL} |\mathbf{z}|^{L-m}}{|\Sigma|^L \Gamma_m(L)} \exp(-L \operatorname{tr}(\Sigma^{-1} \mathbf{z})) \right), \\
 &= \ln \left(\frac{L^{mL} |\mathbf{z}|^{L-m}}{|\Sigma|^L \Gamma_m(L)} \right) + \ln (\exp(-L \operatorname{tr}(\Sigma^{-1} \mathbf{z}))), \\
 &= \ln (L^{mL} |\mathbf{z}|^{L-m}) - \ln (|\Sigma|^L \Gamma_m(L)) - L \operatorname{tr}(\Sigma^{-1} \mathbf{z}), \\
 &= mL \ln L + (L-m) \ln |\mathbf{z}| - \ln |\Sigma|^L \\
 &\quad - \ln \Gamma_m(L) - L \operatorname{tr}(\Sigma^{-1} \mathbf{z}), \\
 &= mL \ln L + L \ln |\mathbf{z}| - m \ln |\mathbf{z}| - L \ln |\Sigma| \\
 &\quad - \ln \Gamma_m(L) - L \operatorname{tr}(\Sigma^{-1} \mathbf{z}),
 \end{aligned}$$

substituindo a função Gamma multivariada definida na equação (3.42),

$$\begin{aligned}
 \ln f_{\mathbf{Z}}(\mathbf{Z}; \Sigma, L) &= mL \ln L + L \ln |\mathbf{z}| - m \ln |\mathbf{z}| - L \ln |\Sigma| \\
 &\quad - \ln \Gamma_m(L) - L \operatorname{tr}(\Sigma^{-1} \mathbf{z}), \\
 &= mL \ln L + L \ln |\mathbf{z}| - m \ln |\mathbf{z}| - L \ln |\Sigma| \\
 &\quad - \ln \left(\pi^{\frac{1}{2}m(m-1)} \prod_{i=0}^{m-1} \Gamma(L-i) \right) - L \operatorname{tr}(\Sigma^{-1} \mathbf{z}), \\
 &= mL \ln L + L \ln |\mathbf{z}| - m \ln |\mathbf{z}| - L \ln |\Sigma| \\
 &\quad - \ln \pi^{\frac{1}{2}m(m-1)} - \ln \prod_{i=0}^{m-1} \Gamma(L-i) - L \operatorname{tr}(\Sigma^{-1} \mathbf{z}), \\
 &= mL \ln L + L \ln |\mathbf{z}| - m \ln |\mathbf{z}| - L \ln |\Sigma| \\
 &\quad - \frac{1}{2}m(m-1) \ln \pi - \sum_{i=0}^{m-1} \ln \Gamma(L-i) - L \operatorname{tr}(\Sigma^{-1} \mathbf{z}),
 \end{aligned}$$

podemos rescrever a equação da seguinte forma

$$\begin{aligned}
 \ln f_{\mathbf{Z}}(\mathbf{Z}; \Sigma, L) &= mL \ln L + L \ln |\mathbf{z}| - m \ln |\mathbf{z}| - L \ln |\Sigma| \\
 &\quad - \frac{1}{2}m(m-1) \ln \pi - \sum_{i=0}^{m-1} \ln \Gamma(L-i) - L \operatorname{tr}(\Sigma^{-1} \mathbf{z}),
 \end{aligned} \tag{3.43}$$

equação equivalente pode ser encontrada em Frery *et al.* (2011).

3.4 Método para detecção das evidências de bordas

Os métodos Sobel, Canny, Laplaciano da Gaussiana(LoG) e LoG piramidal são eficientes na detecção de bordas e largamente aplicados em imagens onde o ruído é aditivo. As imagens adquiridas com sensores PolSAR apresentam ruídos do tipo *speckle* tornando esses métodos inefficientes para aplicação nestas imagens.

É necessário construir um ferramental apropriado para esse tipo de imagem, esta seção introduz conceitos baseados nos artigos Gambini *et al.* (2006); Nascimento *et al.* (2014) para delinear os métodos de detecção de borda em imagens PolSAR com múltiplas visadas. A ideia principal é detectar o ponto de transição em uma faixa tão fina quanto possível entre duas regiões da imagem. O ponto de transição é definido como uma evidência de borda. Os ruídos presentes nestas imagens são do tipo *speckle*, os

mesmos têm natureza multiplicativa, tornando a detecção de bordas em imagens SAR uma tarefa desafiadora.

Nesta seção vamos propor o método *simulated annealing* para detectar o ponto de transição, ou evidência de bordas para os canais de intensidades. Sem perda de generalidade vamos usar o termo evidências de bordas ao longo do texto.

O problema de detecção de evidências de bordas em cada canal pode ser resumido em três importantes aspectos:

1. A escolha da região de interesse;
2. O método para detecção de evidências de bordas;
3. A determinação de uma posição acurada das evidências de bordas.

O tamanho da região de interesse é um fator importante, pois, a região pode não conter informações para identificar a presença de evidências de bordas em regiões pequenas, ou em regiões maiores podem obter informações para mais de uma evidência de borda. Assim o tamanho de janela ideal é aquele que contém as informações para detecção de uma borda.

Em linhas gerais seguiremos as seguintes diretrizes:

- Tentar encontrar faixas finas de dados, idealmente do tamanho de um pixel;
- Será usado o método MLE, juntamente com o método *simulated annealing*;
- Detectar evidências de bordas em diferentes canais da imagem PolSAR.

Para isso vamos definir uma rotina para o método detecção de evidências de bordas nos canais de intensidades:

1. Identificar o centroide de uma região de interesse (ROI) de maneira automática, semiautomática ou manual;
2. Construir raios do centroide para fora da área de interesse;
3. Coletar dados nos pixels definidos como raios;
4. Detectar pontos na faixa de dados os quais fornecem evidências de mudanças de propriedades estatística, ou seja, uma transição que define uma evidência de borda;

A figura (3.2) mostra a região de interesse ROI-R com centroide C , de onde traçamos raios até um ponto de controle P_i , com $i = 1, 2, \dots, S$, estes pontos de controle estão na região externa da ROI-R. Teremos S raios resultantes representados por $s^i = \overline{CP}_i$ com ângulos $\epsilon_i = \angle(s^i, s^{i+1})$. O algoritmo *Bresenham's midpoint line* é usado para definir a radial e extrair informação de cada pixel correspondente da imagem.

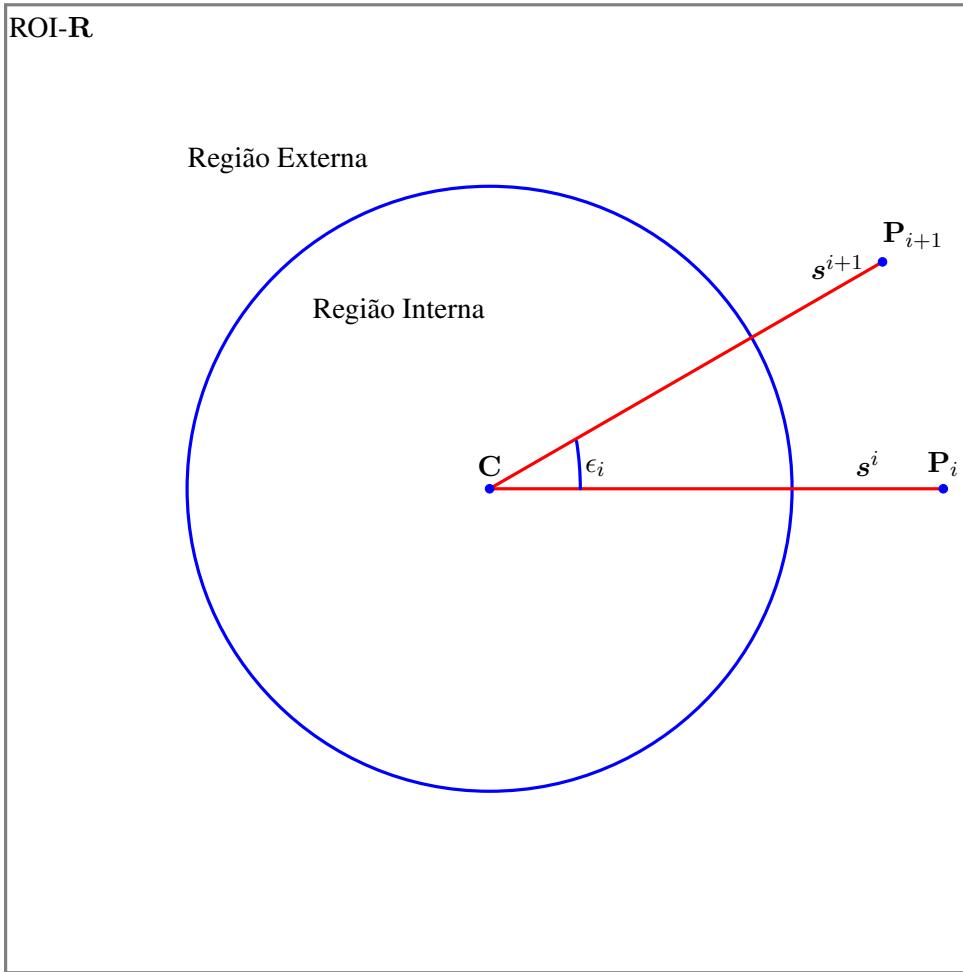


Figura 3.2: Definições para a ROI na imagem PolSAR.

3.4.1 Estimativa por máxima verossimilhança

A estimativa por máxima verossimilhança (MLE) estima os parâmetros do modelo estatístico para uma amostra de dados observados.

Suponha $\mathbf{z} = (z_1, \dots, z_n)$ um vetor randômico distribuído de acordo com função densidade de probabilidade $f(\mathbf{z}, \theta)$ com parâmetros $\theta = (\theta_1, \dots, \theta_d)^T$ pertencente ao espaço dos parâmetros Θ . Definimos, então a função de verossimilhança

$$L(\theta; \mathbf{z}) = \prod_{k=1}^n f(z_k; \theta), \quad (3.44)$$

e a função log-verossimilhança

$$\mathcal{L}(\theta; \mathbf{z}) = \ln L(\theta; \mathbf{z}) = \sum_{k=1}^n \ln f(z_k; \theta). \quad (3.45)$$

O vetor de parâmetros θ é estimado pelo vetor $\hat{\theta}$ tal que $\mathcal{L}(\hat{\theta}; \mathbf{z}) \geq \mathcal{L}(\theta; \mathbf{z})$ para todo θ no espaço dos parâmetros Θ . A estimativa de máxima verossimilhança pode ser representada por

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \mathcal{L}(\theta; \mathbf{z}). \quad (3.46)$$

3.4.2 A máxima verossimilhança usando os parâmetros estimados

Cada linha radial $\mathbf{z} = (z_1, z_2, \dots, z_n)$ é particionada em duas amostras disjuntas na posição j ,

$$\mathbf{z} = (\underbrace{z_1, z_2, \dots, z_j}_{\mathbf{z}_I}, \underbrace{z_{j+1}, z_{j+2}, \dots, z_n}_{\mathbf{z}_E}),$$

para as quais são definidos modelos estatísticos diferentes, um modelo para $Z_I \sim W(\Sigma_I, L_I)$, e outro modelo para $Z_E \sim W(\Sigma_E, L_E)$.

O método MLE, descrito na seção (3.4.1), é aplicado nas amostras internas \mathbf{z}_I e externas \mathbf{z}_E para estimar (Σ_I, L_I) e (Σ_E, L_E) maximizando (3.45), e obtendo $(\hat{\Sigma}_I, \hat{L}_I)$ e $(\hat{\Sigma}_E, \hat{L}_E)$.

A função de verossimilhança é definida no ponto j de acordo com a função

$$L(j) = \prod_{k=1}^j f_{\mathbf{Z}}(\mathbf{z}_k; \Sigma_k, L_k) \prod_{k=j+1}^n f_{\mathbf{Z}}(\mathbf{z}_k; \Sigma_k, L_k). \quad (3.47)$$

Usando propriedades de logaritmos naturais para cada termo do produtório (3.47) é definido a função log-verossimilhança total dependendo de j ,

$$\mathcal{L}(j) = \ln L(j) = \sum_{k=1}^j \ln f_{\mathbf{Z}}(\mathbf{z}_k; \Sigma_k, L_k) + \sum_{k=j+1}^n \ln f_{\mathbf{Z}}(\mathbf{z}_k; \Sigma_k, L_k). \quad (3.48)$$

O estimador de máxima verossimilhança \hat{j}_{ML} é uma evidência de borda, pois representa uma aproximação da transição entre regiões, sendo

$$\hat{j}_{ML} = \arg \max_j \mathcal{L}(j) \quad (3.49)$$

a evidência de borda é encontrada aplicando-se o método GenSA (Xiang *et al.*, 2013).

3.5 O MLE aplicado a pdf Γ em cada canal de intensidade

Na função distribuição de densidade univariada gaussiana

$$f_Z(z; \mu, L) = \frac{L^L}{\Gamma(L)\mu^L} z^{L-1} \exp\left\{-\frac{L}{\mu}z\right\}, \quad (3.50)$$

onde, $\mu > 0$ e $L > 0$, aplicamos o logaritmo natural e suas propriedades,

$$\begin{aligned}\ln f_Z(z; \mu, L) &= \ln \left(\frac{L^L}{\Gamma(L)\mu^L} z^{L-1} \exp \left\{ -\frac{L}{\mu}z \right\} \right), \\ &= \ln \left(\frac{L}{\mu} \right)^L - \ln \Gamma(L) + \ln z^{L-1} + \ln \exp \left\{ -L \frac{z}{\mu} \right\},\end{aligned}$$

obtendo a função,

$$\ln f_Z(z; \mu, L) = L \ln \frac{L}{\mu} - \ln \Gamma(L) + (L-1) \ln z - \frac{L}{\mu} z. \quad (3.51)$$

Dado a amostra $\mathbf{z} = (z_1, \dots, z_n)$ extraída dos canais de intensidades hh, hv, e vv, é definida a função log-verossimilhança, como

$$\begin{aligned}\mathcal{L}(\mathbf{z}; \mu, L) &= \ln \prod_{k=1}^n f_Z(z_k; \mu, L) \\ \mathcal{L}(\mathbf{z}; \mu, L) &= \sum_{k=1}^n \ln f_Z(z_k; \mu, L).\end{aligned}$$

Com o uso da função logarítmica (3.51), teremos

$$\begin{aligned}\mathcal{L}(\mathbf{z}; \mu, L) &= \sum_{k=1}^n \ln f_Z(z_k; \mu, L) \\ &= \sum_{k=1}^n \left[L \ln \frac{L}{\mu} - \ln \Gamma(L) + (L-1) \ln z_k - \frac{L}{\mu} z_k \right] \\ &= \sum_{k=1}^n L \ln \frac{L}{\mu} - \sum_{k=1}^n \ln \Gamma(L) + (L-1) \sum_{k=1}^n \ln z_k - \frac{L}{\mu} \sum_{k=1}^n z_k \\ &= L \ln \frac{L}{\mu} \sum_{k=1}^n 1 - \ln \Gamma(L) \sum_{k=1}^n 1 + (L-1) \sum_{k=1}^n \ln z_k - \frac{L}{\mu} \sum_{k=1}^n z_k \\ &= L \ln \frac{L}{\mu} n - \ln \Gamma(L) n + (L-1) \sum_{k=1}^n \ln z_k - \frac{L}{\mu} \sum_{k=1}^n z_k.\end{aligned}$$

A função log-verossimilhança para a PDF univariada (3.50) pode ser reescrita por

$$\mathcal{L}(\mathbf{z}; \mu, L) = n \left[L \ln \frac{L}{\mu} - \ln \Gamma(L) \right] + (L-1) \sum_{k=1}^n \ln z_k - \frac{L}{\mu} \sum_{k=1}^n z_k,$$

e a sua forma reduzida por

$$\mathcal{L}(\mathbf{z}; \mu, L) = n \left[L \ln \frac{L}{\mu} - \ln \Gamma(L) \right] + L \sum_{k=1}^n \ln z_k - \frac{L}{\mu} \sum_{k=1}^n z_k. \quad (3.52)$$

A função (3.52) é usada para estimar os parâmetros $(\hat{\mu}, \hat{L})$ com o método MLE de (μ, L) baseado na amostra \mathbf{z} . O valor máximo da função (3.52) é encontrado com o método BFGS, implementado no pacote `maxLik` (Henningsen e Toomet, 2011). Para alcançar uma melhor estabilidade numérica, optou-se por realizar o processo de otimização resolvendo $\nabla \mathcal{L} = 0$.

De acordo com a seção (3.4.2) é extraído de cada canal de intensidade da imagem PolSAR uma faixa de dados $\mathbf{z} = (z_1, z_2, \dots, z_n)$ de forma que seja particionada em duas amostras, disjuntas na posição j :

$$\mathbf{z} = (\underbrace{z_1, z_2, \dots, z_j}_{\mathbf{z}_I}, \underbrace{z_{j+1}, z_{j+2}, \dots, z_n}_{\mathbf{z}_E}),$$

para as quais são definidos modelos estatísticos diferentes, um modelo para $Z_I \sim \Gamma(\mu_I, L_I)$, e outro modelo para $Z_E \sim \Gamma(\mu_E, L_E)$.

As funções log-verossimilhança reduzidas aplicadas nas amostras internas \mathbf{z}_I e externas \mathbf{z}_E são usadas para estimar os parâmetros (μ_I, L_I) e (μ_E, L_E) maximizando (3.52), e obtendo $(\hat{\mu}_I, \hat{L}_I)$ e $(\hat{\mu}_E, \hat{L}_E)$.

A log-verossimilhança total é definida no ponto j pela seguinte função

$$\begin{aligned} \ell(j; \hat{\mu}_I, \hat{L}_I, \hat{\mu}_E, \hat{L}_E) = & \\ j[\hat{L}_I \ln(\hat{L}_I/\hat{\mu}_I) - \ln \Gamma(\hat{L}_I)] + \hat{L}_I \sum_{k=1}^j \ln z_k - \frac{\hat{L}_I}{\hat{\mu}_I} \sum_{k=1}^j z_k + & \\ (n-j)[\hat{L}_E \ln(\hat{L}_E/\hat{\mu}_E) - \ln \Gamma(\hat{L}_E)] + \hat{L}_E \sum_{k=j+1}^n \ln z_k - \frac{\hat{L}_E}{\hat{\mu}_E} \sum_{k=j+1}^n z_k, & \end{aligned} \quad (3.53)$$

e aplicando o método GenSA (Xiang *et al.*, 2013) encontramos a evidência de borda

$$\hat{j} = \arg \max_{j \in [\min_s, N - \min_s]} \ell(j; \hat{\mu}_I, \hat{L}_I, \hat{\mu}_E, \hat{L}_E),$$

onde \min_s é uma folga mínima definida empiricamente para as extremidades da amostra. A escolha do número de pixels da amostra pode variar de acordo com a ROI, com o canal, ou com o tipo de sensor para aquisição de imagem.

3.6 Métodos de fusão para as evidências de bordas

As evidências de bordas estão armazenadas em n_c imagens binárias $\{\hat{j}_c\}_{1 \leq c \leq n_c}$, onde o pixel de valor 1 denota uma estimativa de borda e o pixel de valor 0 denota um elemento, onde não foi detectado borda. As imagens (matrizes) têm tamanho $m \times n$, onde podemos definir $\ell = mn$. Essas imagens foram usadas para a fusão resultando na imagem I_F com as bordas detectadas.

Seis técnicas de fusão foram propostos:

- Média simples;
- Transformada wavelet discreta multi-resolução (MR-DWT);
- Transformada wavelet estacionária multi-resolução (MR-SWT);
- Análise de componentes principais (PCA);
- Estatísticas ROC (E-ROC);
- Decomposição em valores singulares com multi-resolução (MR-SVD).

As técnicas de fusão de evidência de bordas serão descritas nesta seção, com especial atenção para a estatística ROC.

3.6.1 Fusão por média simples

A fusão por média simples realiza a média aritmética das evidências de bordas para cada canal, $I_F(x, y) = (n_c)^{-1} \sum_{c=1}^{n_c} \hat{J}_c(x, y)$, onde n_c é o número de canais a serem utilizados na fusão.

A figura (3.3) apresenta o fluxograma para a fusão por média simples, para obter mais detalhes conferir [Mitchell \(2010\)](#).

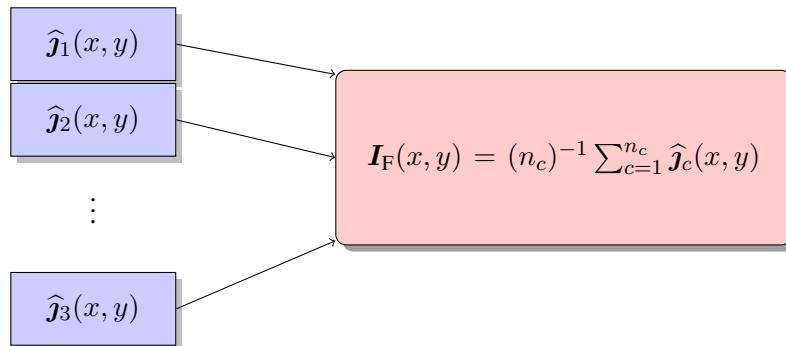


Figura 3.3: Fusão por média simples.

3.6.2 Fusão usando o método wavelet discreta multi-resolução – MR-DWT

Este método de fusão é baseado em [Naidu e Raol \(2008\)](#). Para cada imagem binária \hat{J}_c foram aplicado filtros DWT, sendo um filtro de passa baixa **L** na direção vertical e um filtro de passa alta **H** na direção horizontal, ambos são *down-sampled* para formar as matrizes de coeficientes \hat{J}_{cL} e \hat{J}_{cH} . As operações são repetidas nas matrizes de coeficientes \hat{J}_{cL} e \hat{J}_{cH} resultando em \hat{J}_{cLL} , \hat{J}_{cLH} , \hat{J}_{cHL} , e \hat{J}_{cHH} .

A fusão de evidências de bordas tem os seguintes passos para cada nível de resolução:

1. Calcular a decomposição DWT \hat{J}_{cLL} , \hat{J}_{cLH} , \hat{J}_{cHL} , and \hat{J}_{cHH} , para cada canal.
2. Computar \bar{J}_{cHH} , a média pixel a pixel para todas as \hat{J}_{cHH} decomposições.
3. Encontrar o máximo pixel a pixel de \hat{J}_{cLL} , \hat{J}_{cLH} , \hat{J}_{cHL} resultando em \bar{J}_{cLL} , \bar{J}_{cLH} , e \bar{J}_{cHL} .
4. O resultado da fusão I_F é a transformação inversa DWT para os coeficientes das matrizes \bar{J}_{cHH} , \bar{J}_{cLL} , \bar{J}_{cLH} , e \bar{J}_{cHL} .

O fluxograma para o método de fusão MR-DWT pode ser visto na figura (3.4). Na figura abaixo W e W^{-1} representam a transformação para obter a decomposição wavelet e a transformação inversa, respectivamente.

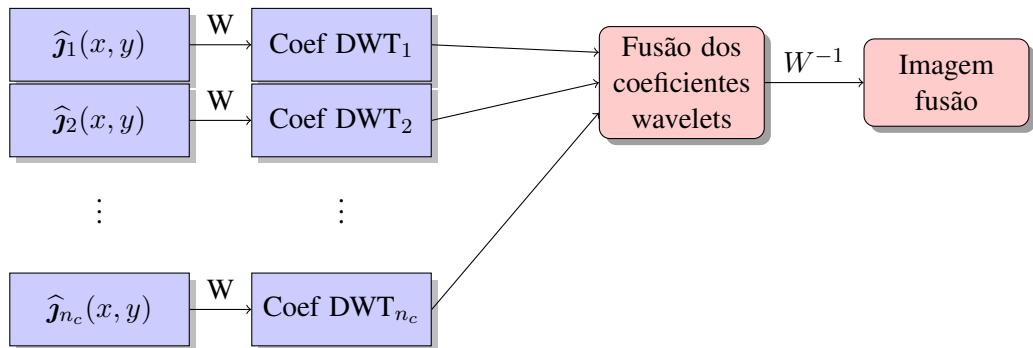


Figura 3.4: Fusão MR-DWT.

3.6.3 Fusão usando o método wavelet discreta Multi-Resolução – MR-SWT

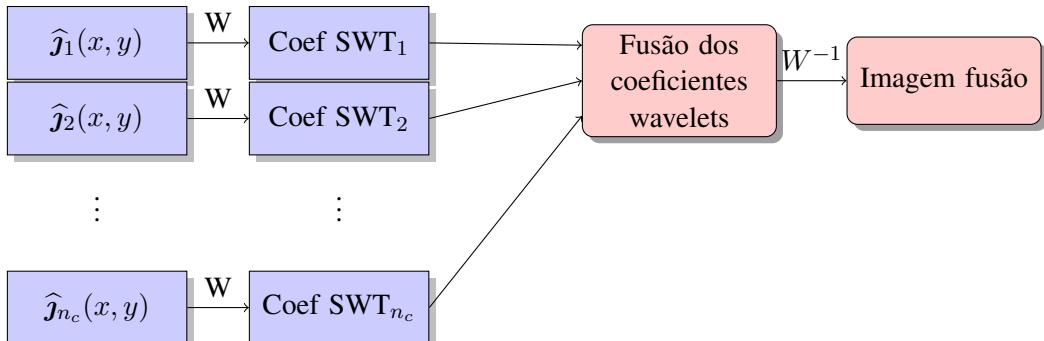
Este método de fusão é baseado em Jiang *et al.* (2017); Naidu e Raol (2008). A diferença entre os métodos MR-DWT e MR-SWT é a substituição do operador transformada discreta wavelet (DWT) pelo operador transformada estacionária wavelet (SWT).

O fluxograma para o método de fusão MR-SWT pode ser visto na figura (3.5). Na figura abaixo W e W^{-1} representam a transformação para obter a decomposição wavelet e a transformação inversa, respectivamente.

3.6.4 Fusão usando o método análise das componentes principais – PCA

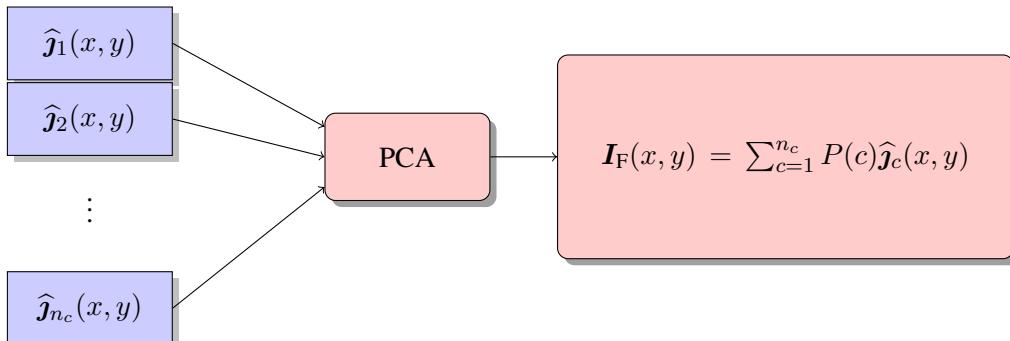
O método PCA é baseada em Mitchell (2010); Naidu e Raol (2008), e pode ser resumido nos seguinte passos:

1. Armazenar as imagens binárias \hat{J}_c em colunas para obter a matriz $X_{\ell \times n_c}$;
2. Calcular a matriz de covariância $C_{n_c \times n_c}$ de $X_{\ell \times n_c}$;

**Figura 3.5:** Fusão MR-SWT.

3. Calcular as matrizes de autovalores (Λ) e autovetores (\mathbf{V}) da matriz de covariância, ordene os autovalores e seus respectivos autovetores de maneira decrescente;
4. Encontrar o vetor $\mathbf{P} = (P(1), \dots, P(n_c)) = (\sum_{c=1}^{n_c} V(c))^{-1} \mathbf{V}$, onde \mathbf{V} é o autovetor associado com o maior autovalor de \mathbf{X} ; note que $\sum_{c=1}^{n_c} P_c = 1$;
5. Realizar a fusão $I_F(x, y) = \sum_{c=1}^{n_c} P(c) \hat{j}_c(x, y)$.

O fluxograma para a fusão usando o método PCA pode ser visto na figura (3.6).

**Figura 3.6:** Fusão PCA.

3.6.5 Fusão usando a estatística ROC

O método estatística *Receiver Operating Characteristics* (E-ROC) descrito em Fawcett (2006); Giannarou e Stathaki (2011) segue os seguintes passos:

1. Adicionar as imagens binárias \hat{j}_c para produzir a matriz de frequência V ;
2. Aplicar os limiares $t = 1, \dots, n_c$ em V para gerar as matrizes \hat{i}_t ;
3. Comparar cada \hat{i}_t com todos \hat{j}_c , ache a matriz de confusão para gerar a curva ROC. O limiar ótimo corresponde ao ponto da curva ROC mais perto (no sentido da distância euclidiana) da linha de diagnóstico;

4. A fusão I_F é a matriz \hat{i}_t que corresponde ao limiar ótimo.

Nas próximas subseções serão abordados os aspectos teóricos do método E-ROC.

3.6.5.1 A estatística ROC

Conforme Giannarou e Stathaki (2011) e Fawcett (2006) as curvas ROC são técnicas para visualizar, organizar e selecionar classificadores aplicados em aprendizado de máquina, visão computacional, inteligência artificial entre outras áreas similares, demonstrando a capacidade do método para efetuar avaliações e comparações de algoritmos. Essa maleabilidade comprova que é possível aplicar o método para a fusão de evidências de bordas.

A construção da curva ROC consiste em um problema de classificação com duas classes rotuladas como instâncias do conjunto $\{p, n\}$, onde p representa a classe positiva e n representa a classe negativa. Estabelecendo as instâncias e o classificador, podemos definir a matriz de confusão 2×2 .

A tabela (3.2) mostra a matriz de confusão.

Tabela 3.2: Matriz de confusão.

		Classes definidas como verdadeiras	
		p	n
Classes preditas	p	Positivos verdadeiros (TP)	Positivos falsos (FP)
	n	Negativos falsos (FN)	Negativos verdadeiros (TN)

Seguindo a regra de formação,

- Se a instância é positiva e classificada como positiva, então é definida como positivo verdadeiro TP.
- Se a instância é positiva e classificada como negativa, então é definida como negativo falso FN.
- Se a instância é negativa e classificada como negativa, então é definida como negativo verdadeiro TN.
- Se a instância é negativa e classificada como positiva, então é definida como positivo falso FP.

Os valores da diagonal principal da matriz de confusão representam as classificações realizadas corretamente, enquanto os elementos da diagonal secundária, representam as classificações incorretas. A soma de todas as possibilidades dos resultados em uma classificação retorna o valor $TP+FN+FP+TN=1$.

Definimos a prevalência como a soma dos positivos verdadeiros com os negativos falsos, $P=TP+FN$, portanto, podemos afirmar que idealmente, a prevalência deveria aproximar-se de TP. Definindo-se o Nível-Q como a soma dos positivos verdadeiros com os positivos falsos, $Q=TP+FP$, o qual deveria aproximar-se de TP em situações ideais.

De acordo com as definições acima, no detector de bordas otimizado, a prevalência e o Nível-Q deveriam ser iguais, isto é, $P=Nível-Q$. Além disso, se definir $N=FP+TN$, e recorrer ao fato $TP+FN+FP+TN=1$, garantimos que $P+N=1$.

A matriz de confusão serve de base para a construção da curva ROC, com as seguintes métricas,

$$tp_{rate} = \frac{TP}{P}, \quad (3.54)$$

$$fp_{rate} = \frac{FP}{N}. \quad (3.55)$$

Na métrica conhecida por razão de positivos verdadeiros, taxa de acerto, *recall* ou sensibilidade, $tp_{rate} = \frac{TP}{P} = \frac{TP}{TP+FN}$, se o número de negativos falsos tenderem a zero, o valor da métrica aproxima-se do valor unitário. Assim como, na métrica conhecida como razão de positivos falsos, $fp_{rate} = \frac{FP}{N} = \frac{FP}{FP+TN}$, se o número de verdadeiros positivos tenderem a zero, o valor da métrica aproxima-se do valor unitário.

3.6.5.2 Estatística ROC para a fusão das evidências de bordas

O método de fusão de evidências baseado na estatística ROC, consiste em aplicar o método MLE em cada canal da imagem PolSAR, gerando imagens binárias com as evidências de bordas \hat{j}_c , sendo $c = 1, \dots, n_c$, onde n_c é o número de canais. Após construir a matriz de frequência V de mesmo tamanho de \hat{j}_c , tal que em cada pixel é armazenado um valor, correspondente a frequência de ocorrências de evidências de bordas em cada canal \hat{j}_c , ou seja, a matriz V é a soma pixel a pixel de todas as imagens de evidências de bordas \hat{j}_c . Sendo assim, podemos afirmar que quanto maior o valor de um pixel, maior sua probabilidade de ser uma evidência de borda.

Na matriz de frequência V são aplicados limiares CT_t , onde $t = 1, \dots, n_c$, gerando matrizes chamadas mapas de evidências de bordas \hat{i}_t . O objetivo do método é estimar automaticamente o limiar correspondente CT ótimo, proveniente do conjunto de limiares parciais CT_t .

Resumindo, somando-se as matrizes \hat{j}_c temos a matriz de frequência $V = \sum_{c=1}^{n_c} \hat{j}_c$. Na matriz V é aplicado os limiares CT_t com $t = 1, \dots, n_c$, gerando os mapas de evidências de bordas \hat{i}_t . Na figura (3.7) pode-se visualizar o fluxograma correspondente a esse processo.

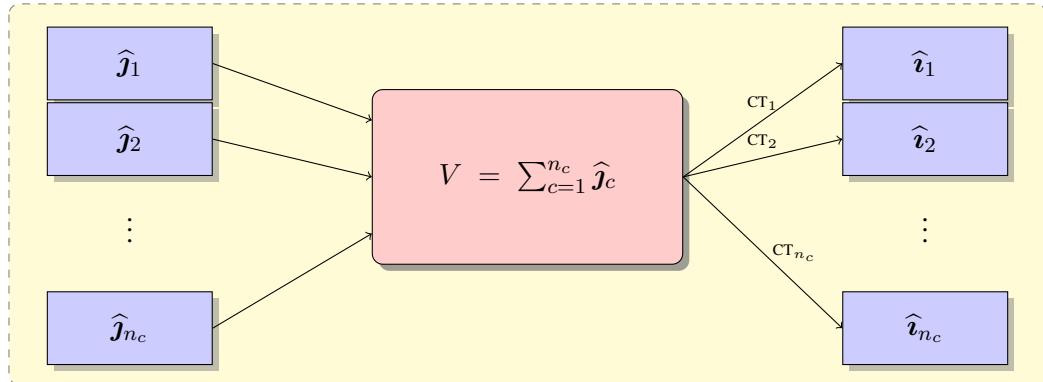


Figura 3.7: Fluxograma para a aplicação dos limiares na fusão de evidência ROC.

As entradas para cada matriz de confusão são definidas como:

$$TP_t^c = \frac{1}{m \cdot n} \sum_{k=1}^m \sum_{l=1}^n \hat{i}_{E_t} \cap \hat{j}_{E_c}, \quad (3.56)$$

$$FP_t^c = \frac{1}{m \cdot n} \sum_{k=1}^m \sum_{l=1}^n \hat{i}_{E_t} \cap \hat{j}_{NE_c}, \quad (3.57)$$

$$TN_t^c = \frac{1}{m \cdot n} \sum_{k=1}^m \sum_{l=1}^n \hat{i}_{NE_t} \cap \hat{j}_{NE_c}, \quad (3.58)$$

$$FN_t^c = \frac{1}{m \cdot n} \sum_{k=1}^m \sum_{l=1}^n \hat{i}_{NE_t} \cap \hat{j}_{E_c}, \quad (3.59)$$

os índices E e NE, significam bordas detectadas e bordas não detectadas respectivamente.

Para cada matriz \hat{i}_t , com t fixado arbitrariamente, foram comparadas a todas as matrizes \hat{j}_c , e foi construído para cada comparação uma matriz de confusão, desta forma gerou-se n_c matrizes de confusão, mostrado na tabela (3.3).

Tabela 3.3: Matriz de confusão para cada comparação

	\hat{j}_{E_c}	\hat{j}_{NE_c}
\hat{i}_{E_t}	TP_t^c	FP_t^c
\hat{i}_{NE_t}	FN_t^c	TN_t^c

As médias com $c = 1, \dots, n_c$ são:

$$\overline{TP}_t = \frac{1}{n_c} \sum_{c=1}^{n_c} TP_t^c; \quad (3.60)$$

$$\overline{FP}_t = \frac{1}{n_c} \sum_{c=1}^{n_c} TN_t^c; \quad (3.61)$$

$$\overline{TN}_t = \frac{1}{n_c} \sum_{c=1}^{n_c} FP_t^c; \quad (3.62)$$

$$\overline{FN}_t = \frac{1}{n_c} \sum_{c=1}^{n_c} FN_t^c. \quad (3.63)$$

A figura (3.8) mostra a comparação entre a imagem \hat{i}_t fixada arbitrariamente com todos as imagens \hat{j}_c , gerando a métrica TP_t . A notação $\cap \hat{j}_c$ significa que a comparação realizada é a intersecção pixel a pixel, entre \hat{i}_t e \hat{j}_c , fazendo a média de acordo com as equações as (3.60), (3.61), (3.62) e (3.63). A notação + refere-se à média de todos os TP_t , ou demais probabilidades FP_t , FN_t e TN_t .

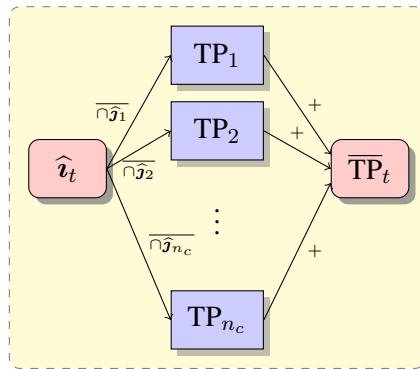


Figura 3.8: Estrutura para fusão de evidências com j escolhido arbitrariamente.

A curva ROC é encontrada calculando as razões de positivos verdadeiros, e a razão de positivos falsos para cada mapa de bordas \hat{i}_t , definidas, respectivamente, como:

$$TP_{rate_t} = \frac{\overline{TP}_t}{\overline{TP}_t + \overline{FN}_t}, \quad (3.64)$$

e

$$FP_{rate_t} = \frac{\overline{FP}_t}{\overline{FP}_t + \overline{TN}_t}, \quad (3.65)$$

onde a soma de $\overline{TP}_t + \overline{FN}_t$, representa o número médio de bordas verdadeiras para cada \hat{i}_t .

O gráfico para a curva ROC é bidimensional no qual os valores das razões de positivos falsos, FP_{rate_t} , são medidos no eixo horizontal, e as razões de positivos verdadeiros, TP_{rate_t} , são medidos no eixo vertical. Assim, cada mapa de borda \hat{i}_t produz um ponto no gráfico (FP_{rate_t} , TP_{rate_t}) gerando a curva ROC.

A referência Fawcett (2006) mostra que o limiar ótimo ocorre na intersecção, ou perto da mesma, da curva ROC com a linha diagnóstico. Essa linha é formada conec-

tando os pontos (P, P) e $(0, 1)$ representada pela linha vermelha na figura (3.9).

O limiar ótimo CT, correspondendo ao parâmetro t que gera o ponto $(FP_{rate_t}, TP_{rate_t})$ mais próximo (métrica euclidiana) da reta diagnóstico determina a imagem \hat{I}_t com maior acurácia de bordas detectadas.

A figura (3.9) mostra a fusão dos canais hh, hv, e vv, para a imagem simulada, processo descrito no próximo capítulo. Para a imagem simulada o limiar ótimo encontrado $t = 2$, resultou na imagem com melhor acurácia \hat{I}_2 , por ser o ponto com menor distância euclidiana para a linha diagnóstico.

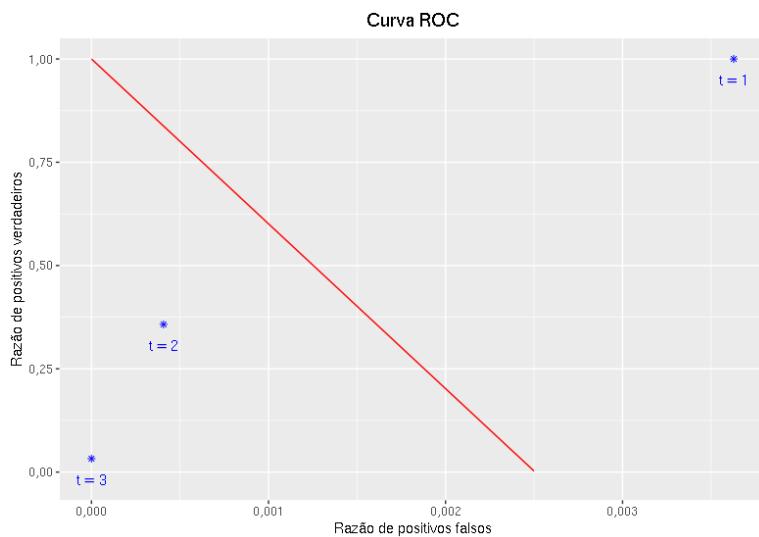


Figura 3.9: Curva ROC para a imagem simulada de duas folhas.

3.6.6 Fusão usando o método decomposição em valores singulares multi-resolução – MR-SVD

O método fusão MR-SVD, veja Naidu (2011), trabalha de maneira similar ao MR-DWT. A diferença consiste em mudar os filtros DWT por filtros SVD. O método pode ser resumido nos seguinte passos:

1. Organizar as imagens binárias \hat{J}_c , com a extração de blocos 2×2 não sobrepostos, onde cada bloco é colocado como um vetor 4×1 , ordenado em colunas para formar a matriz de dados X_1 com dimensão $4 \times \ell/4$;
2. Calcular a decomposição SVD de $X_1 = U_1 S_1 V_1^T$, onde U_1 e V_1 são unitárias e têm dimensões 4×4 e $\ell/4 \times \ell/4$, respectivamente. Os valores singulares são ordenados de maneira decrescente e são colocados na diagonal principal da matriz S_1 , as demais entradas da matriz são zeros;
3. Transformar as linhas de $\hat{X}_1 = U_1^T X_1 = S_1 V_1^T$, sobre novas matrizes com dimensões $m/2 \times n/2$: $\{\Phi_1, \Psi_{1V}, \Psi_{1H}, \Psi_{1D}\}$;

4. Recomecar o procedimento em (1) para Φ_r com $r = 2$, até o menor nível de resolução R ;

5. A MR-SVD decomposição em cada canal é

$$\widehat{\mathbf{X}}_c \rightarrow \left\{ \Phi_R^c, \{\Psi_{rV}^c, \Psi_{rH}^c, \Psi_{rD}^c\}_{r=1}^R, \{\mathbf{U}_r^c\}_{r=1}^R \right\};$$

6. Depois da decomposição ser aplicada em todos os canais, computar a média dos Φ_R^c (Φ_R^f) no menor nível de resolução, e a média \mathbf{U}_r^c (\mathbf{U}_r^f), para cada r , onde f denota a fusão entre os canais;

7. Achar o máximo pixel a pixel de Ψ_{rV}^c , Ψ_{rH}^c e Ψ_{rD}^c : Ψ_{rV}^f , Ψ_{rH}^f , Ψ_{rD}^f ;

8. A fusão \mathbf{I}_F é a transformação SVD para cada nível $r = R, \dots, 1$,

$$\mathbf{I}_F \leftarrow \left\{ \Phi_R^f, \{\Psi_{rV}^f, \Psi_{rH}^f, \Psi_{rD}^f\}_{r=R}^1, \{\mathbf{U}_r^f\}_{r=R}^1 \right\}.$$

Capítulo 4

Resultados

4.1 Imagem simulada

A metodologia para a detecção de bordas baseadas em [Gambini et al. \(2006\)](#), [Gomez et al. \(2017\)](#); [Nascimento et al. \(2014\)](#) foi aplicada em uma imagem simulada particionada em duas metades. Essa imagem tem dimensão de 400×400 pixeis e foi gerada por duas amostras, obedecendo a distribuição Wishart. Na metade da esquerda foi usado a matriz de covariâncias Σ_{k_1} , e na metade da direita a matriz de covariâncias Σ_{k_2} , respectivamente definidas por,

$$\Sigma_{k_1} = \begin{bmatrix} 0.042811 & 0.000072 - 0.003180i & 0.010435 + 0.005022i \\ 0.000072 + 0.003180i & 0.035977 & 0.000784 + 0.004886i \\ 0.010435 - 0.005022i & 0.000784 - 0.004886i & 0.066498 \end{bmatrix},$$
$$\Sigma_{k_2} = \begin{bmatrix} 0.014380 & 0.001333 - 0.000076i & -0.000755 + 0.001570i \\ 0.001333 + 0.000076i & 0.002789 & -0.001044 + 0.001101i \\ -0.000755 - 0.001570i & -0.001044 - 0.001101i & 0.015387 \end{bmatrix}.$$

As entradas das diagonais principais foram as intensidades usadas para gerar os canais \mathbf{I}_{hh} , \mathbf{I}_{hv} e \mathbf{I}_{vv} simulados. A decomposição de Pauli definida como sendo a combinação linear dos canais de intensidades, $(\mathbf{I}_{hh} + \mathbf{I}_{vv}, \mathbf{I}_{hh} - \mathbf{I}_{vv}, \mathbf{I}_{hv})$ foram usadas para compor a imagem. Veja a figura (4.1).

Nesta imagem simulada definimos a borda como linha vertical que divide a imagem em duas metades.

4.1.1 Método estimativa de máxima verossimilhança aplicada a PDF Univariada Gamma

O método MLE foi usado para detectar evidências de bordas em cada canal de intensidades, conforme descrito na seção (3.5).

As figuras (4.2)(a), (4.2)(b), (4.2)(c) mostram os gráficos das funções de verossimilhanças totais (3.53), indicando as evidências de bordas para os canais de intensidades.

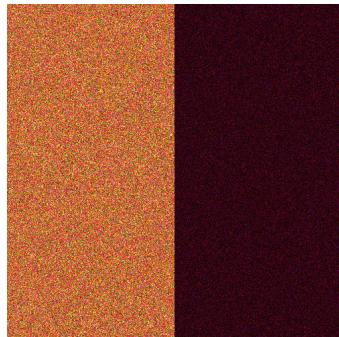


Figura 4.1: Decomposição de Pauli aplicada aos canais simulados

A linha 150 da imagem simulada foi escolhida arbitrariamente, sendo que para cada extremidade foi definido o coeficiente de folga igual a 14 pixels.

A característica comum dessas funções é não ser diferenciável, o que dificulta o uso de métodos de otimização que calculam a derivada da função. O problema foi resolvido usando o método *Simulated Annealing* generalizado (GenSA) Xiang *et al.* (2013), adequado para funções não diferenciáveis.

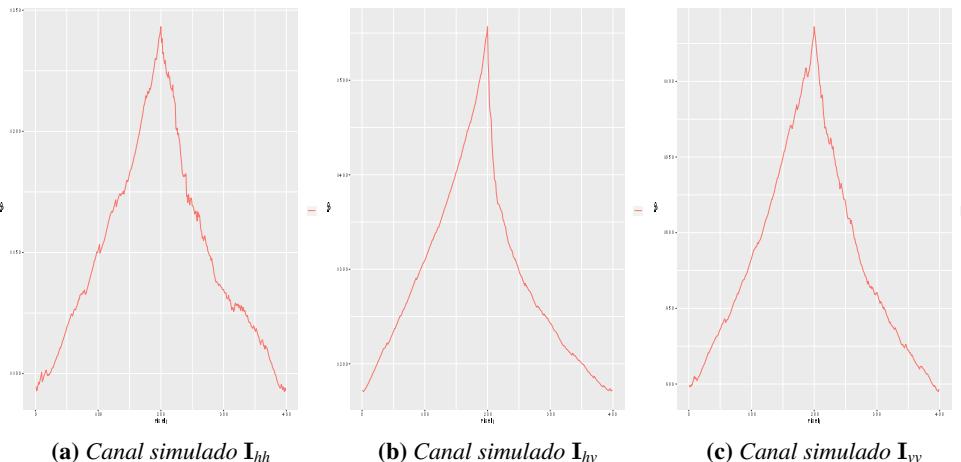


Figura 4.2: Funções de verossimilhanças totais para cada canal simulado

Assim, para cada linha dos canais de intensidades da imagem simulada. As evidências de bordas detectadas podem ser visualizadas na figura (4.3).

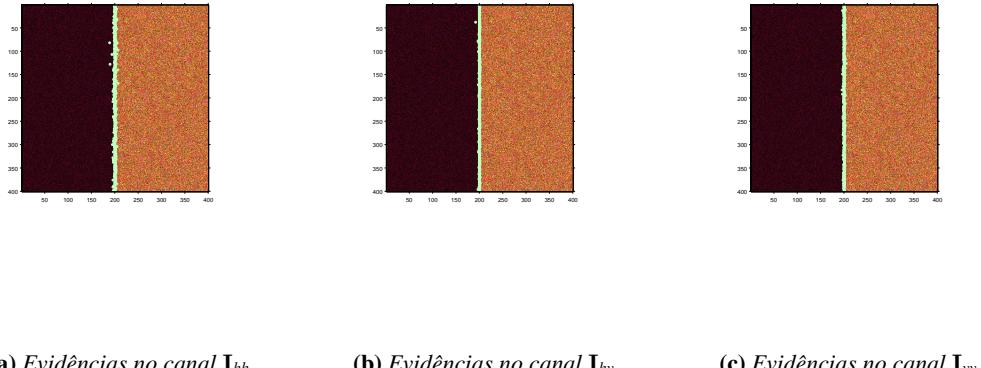


Figura 4.3: Evidências de bordas para os canais de intensidades.

4.1.2 Métricas para as evidências de bordas nas imagens simuladas

O erro de probabilidade de detecção é medido calculando a menor distância euclidiana do pixel de referência, em cada radial (linha) na imagem Ground Truth (GT), para todos os pixels detectados na mesma radial. As menores distâncias são armazenadas em um vetor de frequência $H(k)$ definindo o número de replicações para qual o erro é menor que um número de pixel fixado k_s .

A estimativa de probabilidade é encontrada por $f(k) = H(k)/n_r$, onde n_r é o número de radiais, e o índice k varia entre 1 e k_s . O algoritmo é descrito em Frery *et al.* (2010), sendo que para encontrar as probabilidades para o erro k_s foi definido igual a 10.

A figura (4.4) mostra o gráfico do erro de probabilidade de detecção para cada canal simulado.

O gráfico mostra acurado desempenho do algoritmo no canal hv. Nos canais hh e vv o desempenho é inferior em relação ao canal hv, fato que já poderia ser inferido pela inspeção visual da figura (4.3).

4.1.3 Fusão de evidências de bordas para os canais de intensidades

Os resultados dos métodos para a fusão de evidências de bordas detectadas nos canais simulados são mostrados nas figuras 4.5(a), (b), (c), (d), (e), e (f).

A inspeção visual fornece elementos para as seguintes conclusões:

- O método de fusão PCA e a fusão por média obtém o mesmo resultado pixel a pixel, a vantagem do método de fusão PCA está na ponderação dos canais que contribuem na fusão, fornecendo subsídios para o descarte ou a valorização de um devido canal;

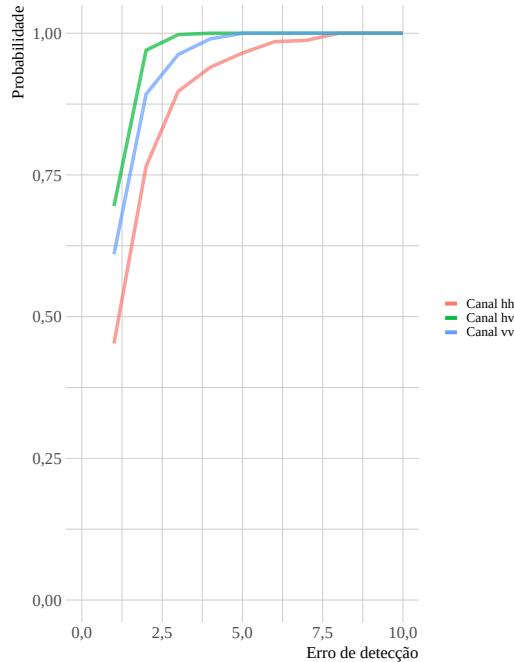


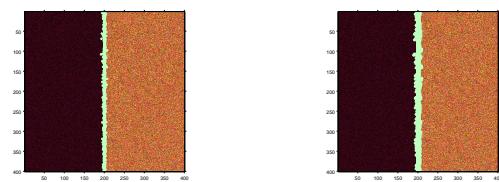
Figura 4.4: Métricas para a detecção em imagem simulada

- Os métodos de fusão baseados nas transformadas wavelets mapeiam de forma acurada as bordas, porém ocorre a geração de *outliers*.
- O método E-ROC mostra um bom desempenho na fusão de evidências de bordas, principalmente com relação a geração de outliers, lembrando que é o único método que foram aplicados limiares.
- O método de fusão baseado em decomposição de valores singulares apresenta bom desempenho na fusão e gera pouco *outliers*.

A figura (4.6) mostra o gráfico de probabilidade do erro para os métodos de fusão de evidências de bordas.

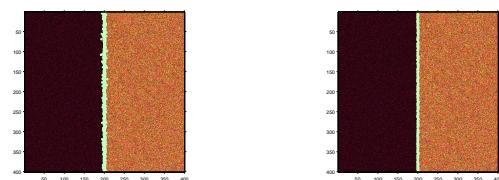
O método de fusão para a curva ROC mostra um desempenho abaixo dos outros métodos em relação a probabilidade de indicar se o pixel é borda ou não. Esse método tem potencial para melhorar seu desempenho a medida que inserirmos outros canais para a detecção de evidências de bordas.

Os resultados obtidos com a aplicação desses métodos validaram os algoritmos usados, essa etapa foi crucial para o desenvolvimento deste trabalho, viabilizando a realização dos testes em imagens adquiridas de sensores PolSAR.



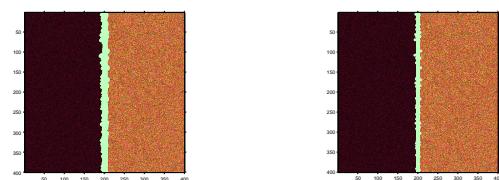
(a) Fusão por média

(b) Fusão DWT



(c) Fusão PCA

(d) Fusão E-ROC



(e) Fusão MR-SWT

(f) Fusão MR-SVD

Figura 4.5: Resultados da aplicação dos seis métodos de fusão

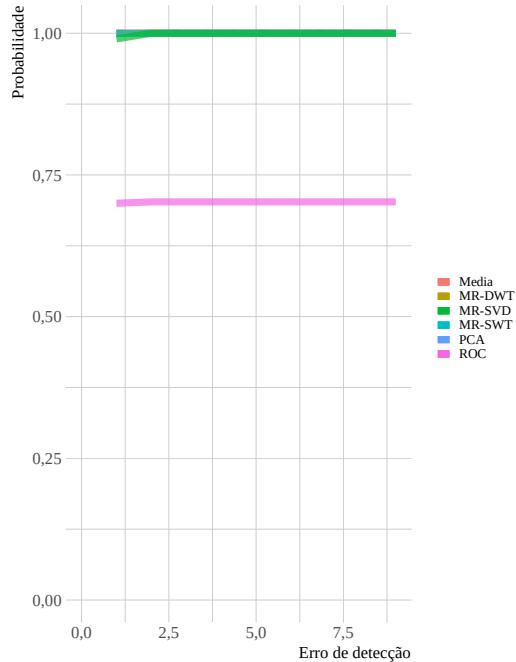


Figura 4.6: Métricas para a fusão de evidências de bordas

4.2 Imagens adquiridas por sensores PolSAR

Os métodos apresentados neste trabalho foram executados com um computador Intel® Core i7-9750HQ CPU 2.6 GHz 16 GB. O erro foi medido com o mesmo método da imagem simulada.

4.2.1 Imagem de Flevoland

A imagem da região de Flevoland com dimensão 750×1024 pixels é uma imagem PolSAR capturada pelo sensor aerotransportado AIRSAR com banda-L. A imagem tem 4 visadas, 9 canais, e uma resolução de aproximadamente 12,10 metros na direção azimutal e 6,6 metros na direção lateral do sensor. A decomposição de Pauli da imagem capturada no sensor é mostrada na figura (4.7).

4.2.1.1 FLEV-ROI-I

Os métodos desenvolvidos neste trabalho foram aplicados na região de interesse destacada na imagem. Detalhes da região de interesse, e das radiais usadas para extrair informações podem ser vista na figura (4.8)(a). A figura (4.8)(b) mostra em pixels vermelhos, as bordas que são usadas como referência, conhecida por imagem *Ground Truth* (GT). Região de interesse é denominada FLEV-ROI-I.

As figuras (4.9)(a), (4.9)(b), e (4.9)(c) mostram, respectivamente, as evidências de bordas nos canais hh, hv, e vv, obtidas pelo método MLE. Para a FLEV-ROI-I foi es-

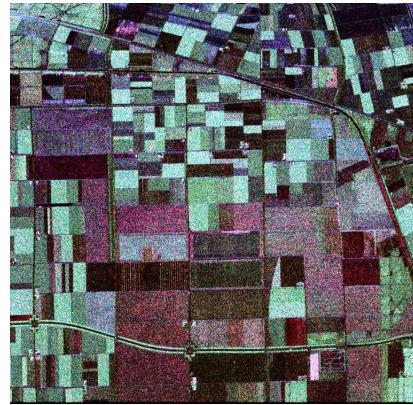
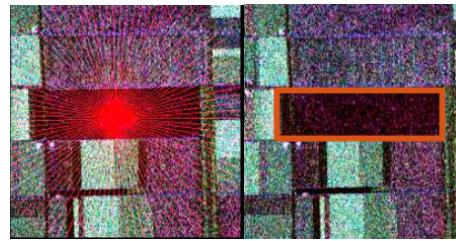


Figura 4.7: Imagem da região de Flevoland



(a) Imagem, ROI, e radiais. **(b)** Ground truth de referência.

Figura 4.8: Região de interesse da imagem Flevoland (FLEV-ROI-I), e ground truth de referência

tabelecidoo 100 radiais com comprimento de 120 pixels, onde foi constatado uma forte oscilação da função de máxima verossimilhança total nos pixels dos extremos das radiais, para evitar a oscilação nesta região foi definida uma folga com 14 pixels. Esse valor foi escolhido empiricamente e pode variar de acordo com a região de interesse da imagem, o canal, o sensor e a imagem. Na FLEV-ROI-I os 14 pixels, escolhidos para cada extremidade, foram suficientes para contornar o problema da oscilação.

O método proposto no qual as estimativas de parâmetros para as funções de máxima verossimilhança reduzidas foram realizada pelo programa MaxLik, e o posterior uso dessas estimativas nas funções de máxima verossimilhança total, onde encontramos seu máximo usando o programa GenSA, que obteve as evidências de bordas com precisão.

A inspeção visual mostra a melhor acurácia dos métodos no canal hv, e presença de *outliers* no canal vv.

A figura (4.10) mostra o gráfico de probabilidade do erro para os métodos de fusão de evidências de bordas na região FLEV-ROI-I. O canal hv apresenta o melhor desempenho,

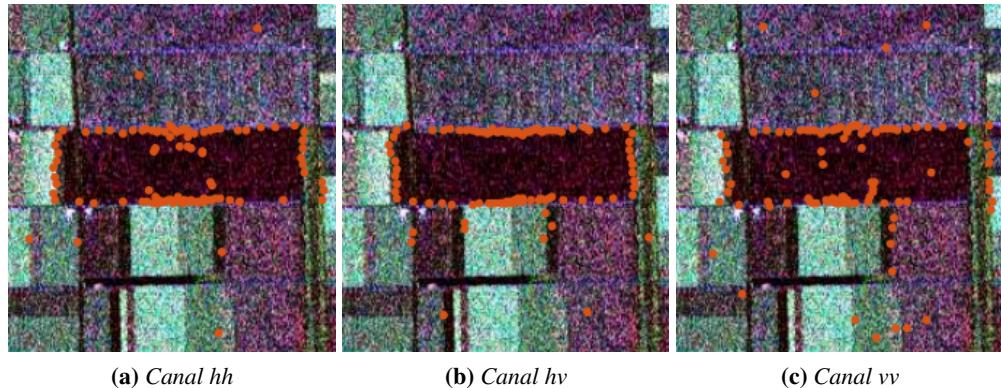


Figura 4.9: Evidências de bordas para os três canais de intensidades na FLEV-ROI-I

comprovando a inspeção visual.

Figuras 4.11(a), (b), (c), (d), (e), e (f) mostram os resultados numéricos para os métodos propostos de fusão de evidência de bordas.

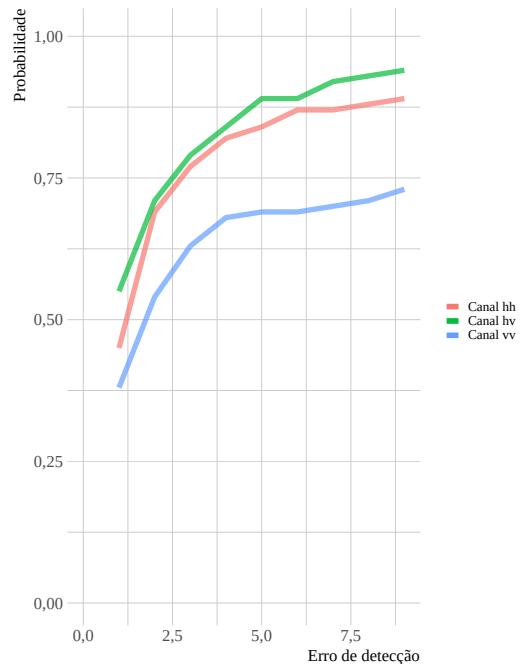


Figura 4.10: Métricas para a fusão de evidências de bordas na região FLEV-ROI-I

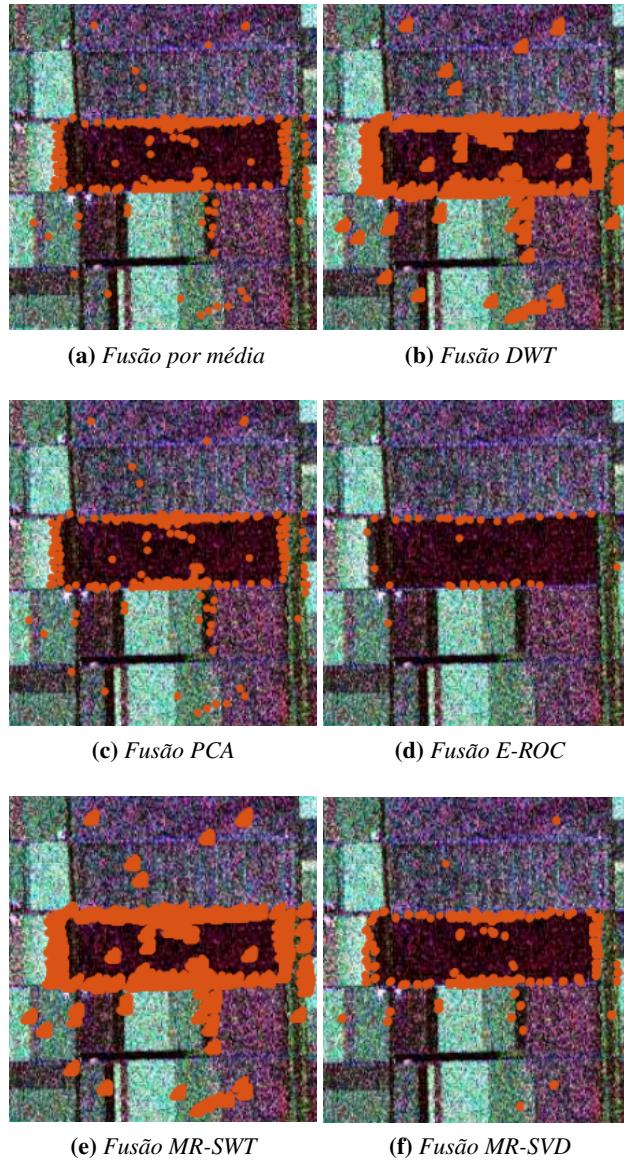


Figura 4.11: Métodos de fusão para a região FLEV-ROI-I

A figura (4.12) mostra o erro dos métodos de fusão para a FLEV-ROI-I com o número de radiais igual a 100.

Os métodos de fusão por média e fusão PCA produzem resultados similares, veja figura (4.12). A vantagem do método PCA está em realizar a média ponderada das evidências de bordas nos diferentes canais, possibilitando a quantificação da importância de cada canal no processo de fusão.

O MR-SVD produz uma considerável vantagem em descartar outliers, porém o tempo de processamento é maior em comparação com os demais métodos.

O método usando a estatística ROC produz bordas acuradas, com poucos outliers, porém de forma esparsa. Acreditamos que este método tem potencial na medida em que

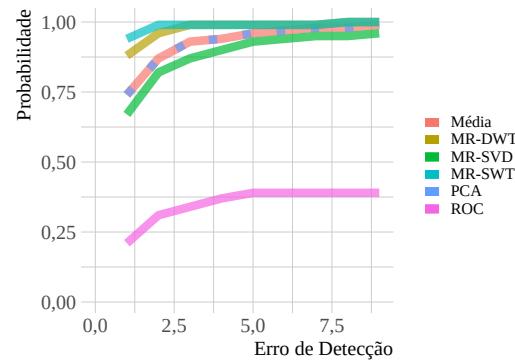


Figura 4.12: Probabilidade de detecção dos métodos de fusão para a FLEV-ROI-I

mais canais forem considerados, ou ao ser aplicado outras funções de densidades de probabilidades para obter evidências de bordas.

Os métodos baseados em *wavelets* produzem densas bordas, mesmo mostrando sempre melhores em probabilidade de detectar bordas, os métodos produzem outliers. Destacamos que a detecção pode ser melhorada com o uso de pós-processamento, cf (Frery *et al.*, 2010), podendo ser aplicado em todos os métodos, inclusive em cada canal onde as evidências forem detectadas.

Os dados apresentados na primeira linha da tabela (4.1) indicam o tempo de processamento para cada método de fusão. Na segunda linha contém os tempos de cada métodos relativo com a fusão por média, por ser o mais rápido.

Tabela 4.1: Tempo de processamento para os métodos de fusão

Método	Média	PCA	MR-DWT	MR-SWT	ROC	MR-SVD
Tempo (s)	0.01	0.02	0.08	0.18	0.40	1.11
Time Rel.	1.00	2.19	9.25	21.05	46.59	129.57

4.2.1.2 FLEV-ROI-II

Uma segunda região na imagem de Flevoland foi selecionada para os testes a qual denominamos de região de interesse FLEV-ROI-II. A imagem com as radiais é mostrada na figura (4.13)(a). A figura (4.13)(b) mostra as bordas em pixels vermelhos usadas de referência a qual chamaremos de *Ground Truth* (GT).

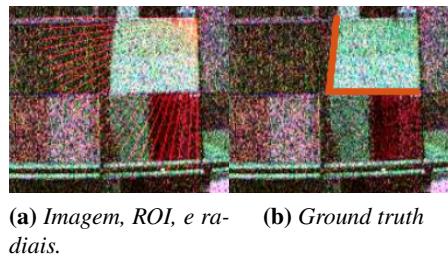


Figura 4.13: Região de interesse da imagem Flevoland (FLEV-ROI-II), e ground truth de referência

As Figuras (4.14a)(a) (4.14)(b) e (4.14)(c) mostram, respectivamente, as evidências de bordas nos canais hh, hv e vv, obtidas pelo método MLE. Para a FLEV-ROI-II foi estabelecido 25 radiais com comprimento de 120 pixels. Nas extremidades em cada radial foi utilizado uma folga de 25 pixels, pois foi constatado forte oscilação da função de máxima verossimilhança total. Esse valor foi escolhido empiricamente e pode variar de acordo com a região, o canal e a figura.

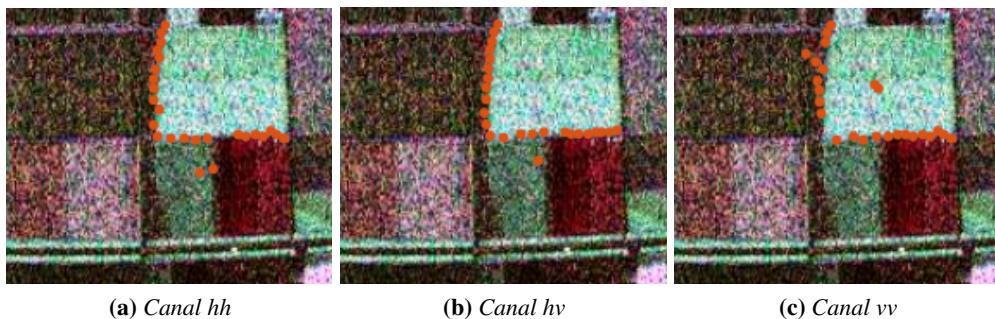


Figura 4.14: Evidências de bordas para os três canais de intensidades para FLEV-ROI-II na imagem de Flevoland com folga de 25 pixel

A figura (4.15) mostra o gráfico de probabilidade do erro para os método de fusão de evidências de bordas na região FLEV-ROI-II. Ao observá-lo pode-se constatar que o canal hv apresenta maior probabilidade de detectar bordas acuradas, confirmando a inspeção visual. Na FLEV-ROI-II, a escolha de 25 pixels, em cada extremidade, foi suficiente para contornar o problema da oscilação.

Os resultados das aplicações dos métodos de fusão estudados estão expostos nas figuras 4.16(a), (b), (c), (d), (e), e (f).

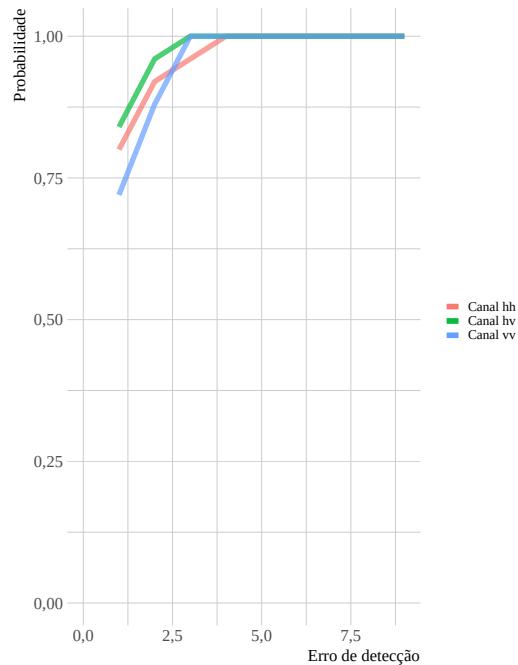


Figura 4.15: Métricas para a detecção de evidências de bordas na região FLEV-ROI-II

A figura 4.17 mostra o erro de probabilidade de detecção dos métodos de fusão para a FLEV-ROI-II.

Os resultados dos métodos de fusão não tiveram mudanças significativas quando as fusões foram aplicadas na região FLEV-ROI-I ou na região FLEV-ROI-II.

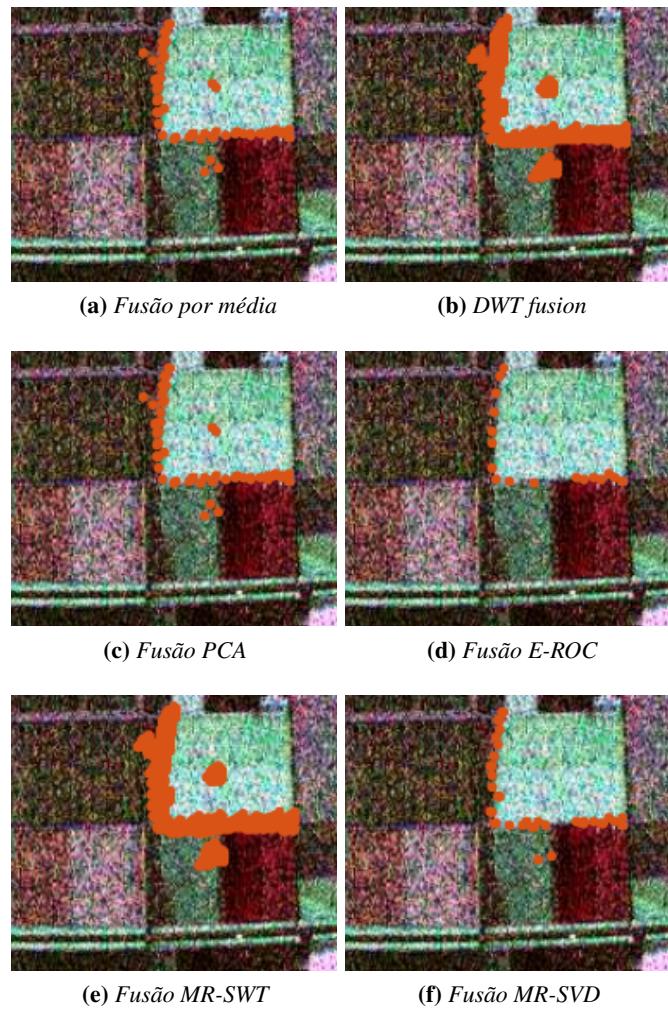


Figura 4.16: Resultados das aplicações dos métodos de fusão para a FLEV-ROI-II com 25 pixels de folga

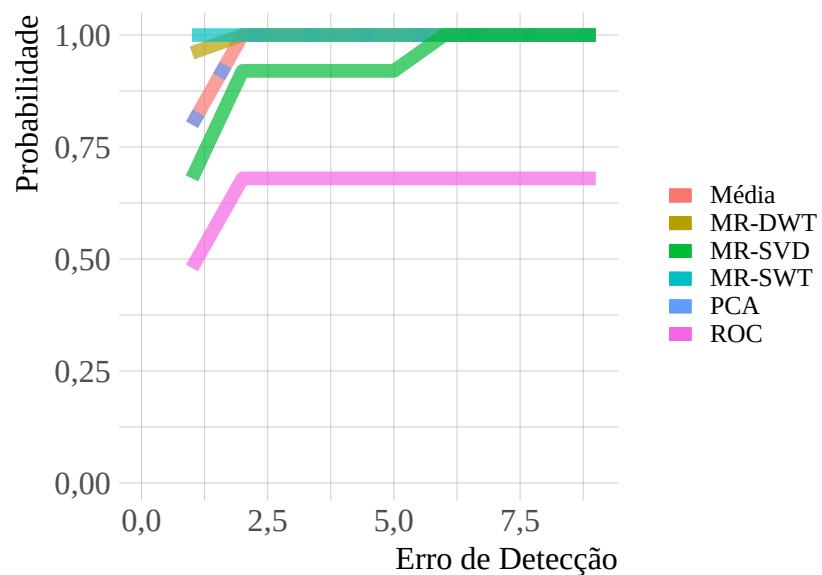


Figura 4.17: Probabilidade de detecção dos métodos de fusão para a FLEV-ROI-II

4.2.1.3 Imagem de San Francisco

A imagem da baía de São Francisco de dimensão 450×600 pixels é uma imagem PolSAR aerotransportada, capturada pelo sensor AIRSAR com banda-L, exposta na figura (4.18)

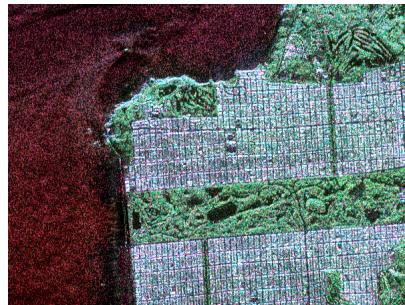


Figura 4.18: Imagem da baía de São Francisco

Na figura (4.19)(a) é destacado a região de interesse (SF-ROI) com 25 radiais. Em cada radial foi extraído os dados para obter as informações sobre as localizações das evidências de bordas. A figura (4.19)(b) mostra a imagem *Ground Truth* (GT) que foi gerada para validar os resultados.

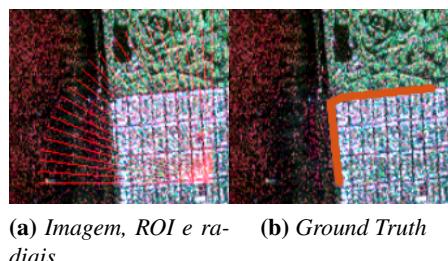


Figura 4.19: Decomposição de Pauli para imagem de São Francisco, e a Ground Truth - GT

As Figuras. (4.20)(a), (4.20)(b), e (4.20)(c) mostram, respectivamente, as evidências de bordas nos canais hh, hv e vv, obtidos pelo método MLE. Para a SF-ROI foram estabelecidos 25 radiais com comprimento de 120 pixels. Nas extremidades de cada radial foi estabelecido uma folga de 25 pixels, pois foi constatado forte oscilação da função de máxima verossimilhança total. Esse valor foi escolhido empiricamente e pode variar de acordo com a região, o canal e a figura. Na SF-ROI os 25 pixels escolhidos em cada extremidade foram suficientes para contornar o problema da oscilação.

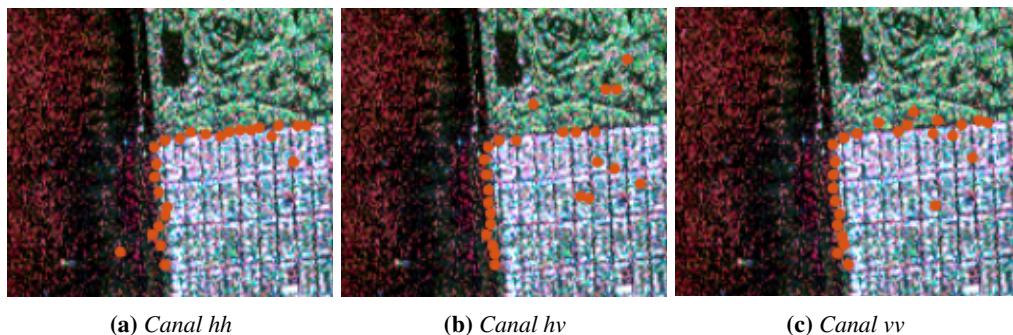


Figura 4.20: Evidências de bordas para os canais de intensidades na imagem de São Francisco

A inspeção visual mostra bordas com melhor acurácia no canal hh.

A figura (4.21) mostra o gráfico de probabilidade do erro para os métodos de fusão de evidências de bordas na região SF-ROI. O canal hh apresenta o melhor desempenho

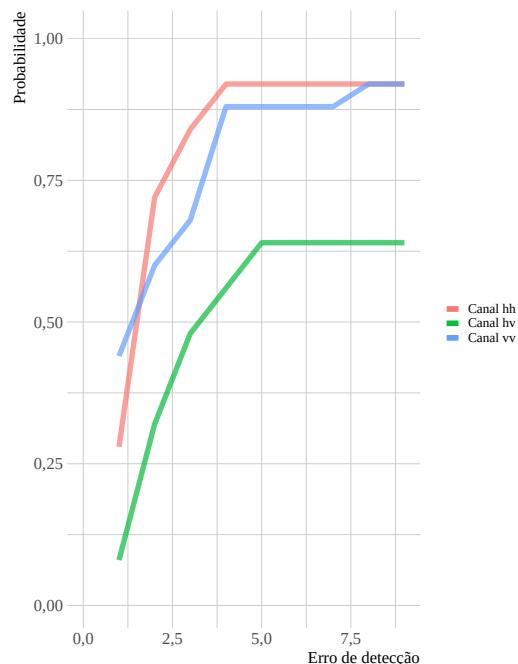


Figura 4.21: Métricas para a fusão de evidências de bordas na região SF-ROI

comprovando a inspeção visual.

Nas figuras 4.22(a), (b), (c), (d), (e), e (f) são apresentados os resultados numéricos obtidos com a aplicação dos métodos de fusão das evidências de bordas propostos neste trabalho.

A figura (4.23) mostra o erro para SF-ROI com o número de radiais igual a 25.

Realizando a inspeção visual das fusões e análise do gráfico de probabilidade em detectar bordas dos métodos, foi verificado que os resultados para a região SF-ROI geram resultados similares ao resultados da imagem de Flevoland (FLEV-ROI-I e FLEV-ROI-

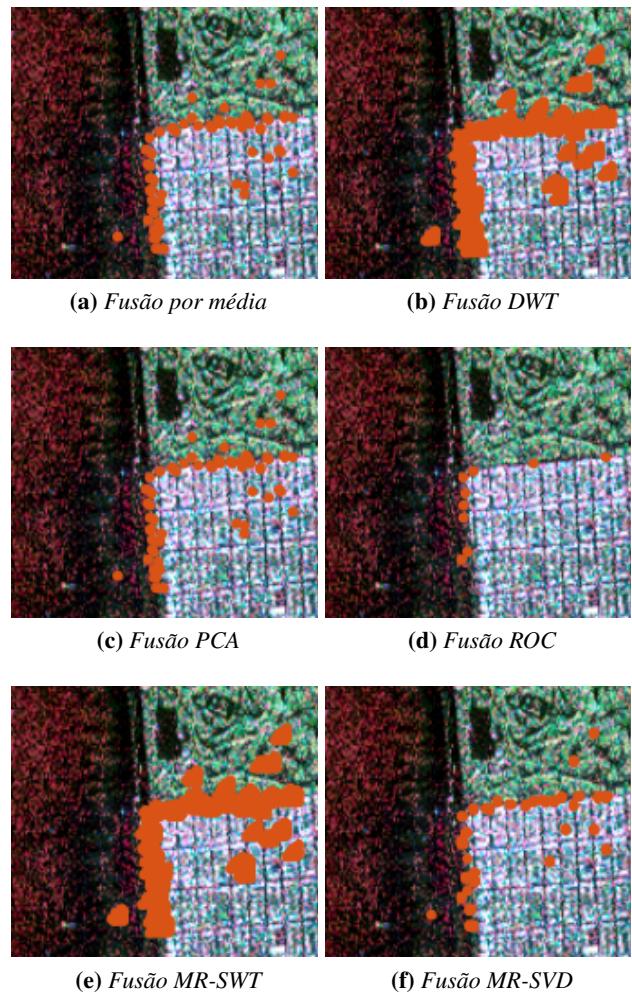


Figura 4.22: Resultado da aplicação dos método de fusão para a SF-ROI

II). Usar o método de fusão para quantificar as contribuições de informações provenientes de cada canal

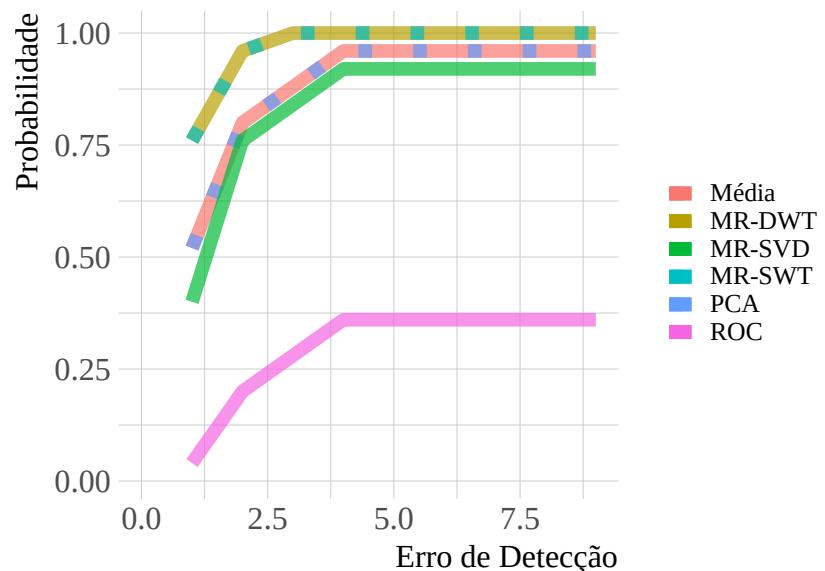


Figura 4.23: Probabilidade de detecção dos métodos de fusão para a SF-ROI

Capítulo 5

Discussões e conclusões

Esta tese estudou e comparou seis métodos de fusão provenientes da detecção das evidências de bordas, nos canais de intensidade hh, hv e vv de imagens PolSAR múltiplas visadas. O método consiste em detectar pontos de transição em uma faixa de dados, o mais fina possível, fornecendo dados que cobrem duas regiões usando o método MLE sob a distribuição de Wishart. Os métodos em questão são: média simples (MS), transformada *wavelet* discreta multi-resolução (MR-DWT), análise de componente principal (PCA), estatísticas ROC, transformada *wavelet* estacionária multi-resolução (MR-SWT), e um método de multi-resolução baseado na decomposição de valores singulares (MR-SVD).

Uma etapa crucial para o desenvolvimento desta pesquisa foi a validação dos algoritmos usados, viabilizando assim, a realização dos testes em imagens adquiridas de sensores PolSAR, dando condições para que as etapas subsequentes pudessem ser realizadas.

Os dados das linhas radiais fornecidos imagens selecionadas foram modelados e posteriormente foi aplicado o MLE. Nesse processo ao ser usado a função de máxima verossimilhança total foi constatado oscilações nas extremidades. Para contornar esse problema foram definidos, conforme a região de interesse, valores de folgas empiricamente. Essa alternativa mostrou-se suficiente para resolver o problema.

Outro problema apresentado na aplicação da função de máxima verossimilhança total, se refere a sua característica de não ser diferenciável, fato que dificulta o uso de métodos de otimização que calculam a derivada da função. O problema foi resolvido usando o método GenSA.

Com os testes realizados, em que se aplicou os métodos citados, foram encontradas bordas nas imagens de banda L, do sensor aerotransportado AIRSAR sobre Flevoland e São Francisco, comprovando a viabilidade dos métodos de fusão de evidências de bordas.

Sobre os campos agrícolas de Flevoland, a melhor evidência de borda foi observada

no canal hv. O canal hh forneceu as melhores estimativas de bordas entre as áreas urbanas e as áreas, de mar e vegetação, de São Francisco. Essa diversidade de conteúdo de informação justifica a necessidade de fusão das evidências de bordas.

Aplicamos métodos de fusão para reunir as evidências de bordas, obtidas nos três canais de intensidade. Ao comparar o desempenho dos métodos, os melhores resultados foram produzidos pelo método PCA e pelo método de múltipla resolução com decomposição em valores singulares, MR-SVD. Essa análise leva em conta o custo computacional em termos de tempo de processamento.

O método E-ROC mostrou desempenho inferior aos outros métodos, entretanto, seu desempenho pode melhorar a medida que outros canais são inseridos para a detecção de evidências de bordas.

Os resultados foram avaliados quantitativamente, verificando a proximidade dos pontos fundidos com a borda real e pela presença de *outliers*. Embora a fusão por média e a fusão com PCA sejam semelhantes, com relação à probabilidade de detectar corretamente a borda, o última fornece uma ponderação mais eficaz das evidências de bordas. A partir desse fato, a fusão com PCA é capaz de descartar completamente as evidências enganosas, enquanto a fusão por média não.

No decorrer da pesquisa alguns caminhos foram se apresentando como possíveis trabalhos futuros:

- 1- Aumentar o número de evidências de bordas. Isso é possível, pois dados totalmente polarimétricos são mais ricos do que os canais de intensidades;
- 2- Propor novas técnicas de fusão para evidências de bordas;
- 3- Melhorar a medidas para apriveitamento ou descarte de canais no método de fusão;
- 2- Pós-processamento, tanto para os métodos de detecção de evidências de bordas parciais, como também para os métodos de fusão das evidências de bordas.

Referências Bibliográficas

- Anfinsen et al.(2009)** Stian Normann Anfinsen, Anthony P Doulgeris e Torbjón Eltoft. Estimation of the equivalent number of looks in polarimetric synthetic aperture radar imagery. *IEEE Transactions on Geoscience and Remote Sensing*, 47(11):3795–3809. Citado na pág. 28
- Balz e Rocca(2020)** T. Balz e F. Rocca. Reproducibility and replicability in sar remote sensing. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 13:3834–3843. doi: 10.1109/JSTARS.2020.3005912. Citado na pág. 5
- Baselice e Ferraioli(2012)** F. Baselice e G. Ferraioli. Statistical edge detection in urban areas exploiting SAR complex data. *IEEE Geoscience and Remote Sensing Letters*, 9(2):185–189. ISSN 1545-598X. doi: 10.1109/LGRS.2011.2163295. Citado na pág. 1
- De Borba et al.(2020)** A. A. De Borba, M. Marengoni e A. C. Frery. Fusion of evidences in intensity channels for edge detection in polsar images. *IEEE Geoscience and Remote Sensing Letters*, páginas 1–5. doi: 10.1109/LGRS.2020.3022511. Citado na pág. 2
- Demmel(1997)** James Demmel. *Applied Numerical Linear Algebra*. SIAM. ISBN 978-0-898713-89-3. URL <http://bookstore.siam.org/ot56/>. Citado na pág. 2
- Fawcett(2006)** Tom Fawcett. An introduction to ROC analysis. *Pattern Recogn. Lett.*, 27(8):861–874. ISSN 0167-8655. doi: 10.1016/j.patrec.2005.10.010. Citado na pág. 38, 39, 42
- Frery et al.(2010)** A. C. Frery, J. Jacobo-Berlles, J. Gambini e M. Mejail. Polarimetric SAR image segmentation with B-Splines and a new statistical model. *Multidimensional Systems and Signal Processing*, 21:319–342. doi: 10.1007/s11045-010-0113-4. Citado na pág. 1, 3, 47, 55
- Frery et al.(2011)** Alejandro C Frery, Abraao DC Nascimento e Renato J Cintra. Information theory and image understanding: An application to polarimetric SAR imagery. *Chilean Journal of Statistics*, 2(2):81–100. Citado na pág. 30
- Frery et al.(2020)** Alejandro C. Frery, Luis Gomez e Antonio C. Medeiros. A badging system for reproducibility and replicability in remote sensing research. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 13. doi: 10.1109/JSTARS.2020.3019418. Citado na pág. 5
- Gambini et al.(2006)** J. Gambini, M. Mejail, J. Jacobo-Berlles e A. C. Frery. Feature extraction in speckled imagery using dynamic B-spline deformable contours under

- the G0 model. *International Journal of Remote Sensing*, 27(22):5037–5059. doi: 10.1080/01431160600702616. Citado na pág. 1, 3, 30, 45
- Gambini et al.(2008)** Juliana Gambini, Marta Mejail, Julio Jacobo-Berlles e Alejandro César Frery. Accuracy of edge detection methods with local information in speckled imagery. *Statistics and Computing*, 18(1):15–26. Citado na pág. 2
- Giannarou e Stathaki(2011)** Stamatia Giannarou e Tania Stathaki. Optimal edge detection using multiple operators for image understanding. *EURASIP Journal on Advances in Signal Processing*, 2011(1):28. ISSN 1687-6180. doi: 10.1186/1687-6180-2011-28. Citado na pág. 2, 38, 39
- Gomez et al.(2017)** Luis Gomez, Luis Alvarez, Luis Mazorra e Alejandro C Frery. Fully PolSAR image classification using machine learning techniques and reaction-diffusion systems. *Neurocomputing*, 255:52–60. Citado na pág. 45
- Goodman(1985)** J.W. Goodman. *Statistical Optics*. A Wiley-Interscience publication. Wiley. ISBN 9780471015024. URL <https://books.google.com.br/books?id=2VTwAAAAMAAJ>. Citado na pág. 27
- Goodman(1963)** N. R. Goodman. The distribution of the determinant of a complex Wishart distributed matrix. *Ann. Math. Statist.*, 34(1):178–180. doi: 10.1214/aoms/1177704251. URL <http://dx.doi.org/10.1214/aoms/1177704251>. Citado na pág. 27, 28
- Henningsen e Toomet(2011)** Arne Henningsen e Ott Toomet. maxlik: A package for maximum likelihood estimation in R. *Computational Statistics*, 26(3):443–458. doi: 10.1007/s00180-010-0217-1. Citado na pág. 2, 35
- Jiang et al.(2017)** Q. Jiang, X. Jin, S. Lee e S. Yao. A novel multi-focus image fusion method based on stationary wavelet transform and local features of fuzzy sets. *IEEE Access*, 5:20286–20302. ISSN 2169-3536. doi: 10.1109/ACCESS.2017.2758644. Citado na pág. 2, 37
- Lee et al.(1994)** J. S. Lee, K. W. Hoppel, S. A. Mango e A. R. Miller. Intensity and phase statistics of multilook polarimetric and interferometric SAR imagery. *IEEE Transactions on Geoscience and Remote Sensing*, 32(5):1017–1028. doi: 10.1109/36.312890. Citado na pág. 28
- Lee e Pottier(2009)** Jong-Sen Lee e Eric Pottier. *Polarimetric radar imaging: from basics to applications*. CRC press. Citado na pág. 8, 10, 20
- Lillesand et al.(2015)** T. Lillesand, R.W. Kiefer e J. Chipman. *Remote Sensing and Image Interpretation, 7th Edition*. Wiley. ISBN 9781118919453. URL <https://books.google.com.br/books?id=eQXYBgaAQBAJ>. Citado na pág. 9
- Liu et al.(2014)** B. Liu, Z. Zhang, X. Liu e W. Yu. Edge extraction for polarimetric SAR images using degenerate filter with weighted maximum likelihood estimation. *IEEE Geoscience and Remote Sensing Letters*, 11(12):2140–2144. ISSN 1558-0571. doi: 10.1109/LGRS.2014.2321629. Citado na pág. 1
- MATLAB(2014)** MATLAB. *version 8.3.0.532 (R2014a)*. The MathWorks Inc., Natick, Massachusetts. Citado na pág. 4

- Mitchell(2010)** H.B. Mitchell. *Image Fusion: Theories, Techniques and Applications*. Springer Berlin Heidelberg. ISBN 9783642112164. Citado na pág. 2, 36, 37
- Naidu(2011)** V.P.S. Naidu. Image fusion technique using multi-resolution singular value decomposition. *Defence Science Journal*, 61(5):479–484. doi: 10.14429/dsj.61.705. Citado na pág. 2, 43
- Naidu e Raol(2008)** V.P.S. Naidu e J.R. Raol. Pixel-level image fusion using wavelets and principal component analysis. *Defence Science Journal*, 58:338–352. Citado na pág. 2, 36, 37
- Nascimento et al.(2014)** Abraão Nascimento, Michelle Horta, Alejandro Frery e Renato Cintra. Comparing edge detection methods based on stochastic entropies and distances for PolSAR imagery. *Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 7(2):648–663. Citado na pág. 1, 3, 30, 45
- Nocedal e Wright(2006)** Jorge Nocedal e Stephen J. Wright. *Numerical Optimization*. Springer, New York, NY, USA, second edição. Citado na pág. 2
- R Core Team(2020)** R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2020. URL <https://www.R-project.org/>. Citado na pág. 4
- Reigber et al.(2013)** A. Reigber, R. Scheiber, M. Jager, P. Prats-Iraola, I. Hajnsek, T. Jagdhuber, K. P. Papathanassiou, M. Nannini, E. Aguilera, S. Baumgartner, R. Horn, A. Nottensteiner e A. Moreira. Very-high-resolution airborne synthetic aperture radar imaging: Signal processing and applications. *Proceedings of the IEEE*, 101(3):759–783. doi: 10.1109/JPROC.2012.2220511. Citado na pág. 13, 16
- Santana-Cedrés et al.(2020)** D. Santana-Cedrés, L. Gomez, L. Alvarez e A. C. Frery. Despeckling PolSAR images with a structure tensor filter. *IEEE Geoscience and Remote Sensing Letters*, 17(2):357–361. ISSN 1558-0571. doi: 10.1109/LGRS.2019.2919452. Citado na pág. 1
- Sarabandi(1992)** K Sarabandi. Derivation of phase statistics from the mueller matrix. *Radio Science*, 27. doi: 10.1029/92RS00195. Citado na pág. 28
- Shi et al.(2020)** J. Shi, H. Jin e Z. Xiao. A novel hybrid edge detection method for polarimetric SAR images. *IEEE Access*, 8:8974–8991. ISSN 2169-3536. doi: 10.1109/ACCESS.2020.2963989. Citado na pág. 1
- Wang et al.(2018)** Wei Wang, Deliang Xiang, Yifang Ban, Jun Zhang e Jianwei Wan. Enhanced edge detection for polarimetric SAR images using a directional span-driven adaptive window. *International Journal of Remote Sensing*, 39(19):6340–6357. doi: 10.1080/01431161.2018.1460501. Citado na pág. 1
- Xiang et al.(2013)** Y. Xiang, S. Gubian, B. Suomela e J. Hoeng. Generalized Simulated Annealing for Global Optimization: The GenSA Package. *The R Journal*, 5(1):13–28. Citado na pág. 2, 33, 35, 46

- Zhu et al.(2017)** X. X. Zhu, D. Tuia, L. Mou, G. Xia, L. Zhang, F. Xu e F. Fraundorfer. Deep learning in remote sensing: A comprehensive review and list of resources. *IEEE Geoscience and Remote Sensing Magazine*, 5(4):8–36. ISSN 2168-6831. doi: 10.1109/MGRS.2017.2762307. Citado na pág. 1

Índice Remissivo

- Base de Pauli de dimensão 3, [21](#)
- Base de Pauli de dimensão 4, [18](#)
- Base lexicográfica de dimensão 3, [21](#)
- Base Lexicográfica de dimensão 4, [18](#)
- Espectro Eletromagnético, [10](#)
- Evidências de bordas, [3](#)
- Ground Truth, [3](#)
- Matriz de covariância lexicográfica 4×4 ,
[20](#)
- Matriz de covariância polarimétrica 3×3 ,
[22](#)
- Matriz de Espalhamento, [17](#)
- Matriz polarimétrica de Pauli 3×3 , [22](#)
- Matriz polarimétrica de Pauli 4×4 , [20](#)
- O ruído *Speckle*, [22](#)
- Replicabilidade, [4](#)
- Reprodutibilidade, [4](#)
- ROI, [3](#)
- Span, [18](#)