



Mackenzie

# Fusão de evidências na detecção de bordas em imagens PolSAR

---

Anderson Adaime de Borba

Orientador: Dr. Mauricio Marengoni - UPM

Coorientador: Dr. Alejandro Frery - UFAL

15 de dezembro de 2018

Exame de Qualificação - 2018

PPGEEC - Programa de Pós graduação em Engenharia Elétrica e Computação

UPM - Universidade Presbiteriana Mackenzie

# Cronograma

1. Introdução
2. Metodologia
3. Resultados numéricos
4. Conclusão e trabalhos futuros

# Introdução

---

# Imagens PolSAR

*Polarimetric Synthetic Aperture Radar - PolSAR*

## Características das imagens PolSAR

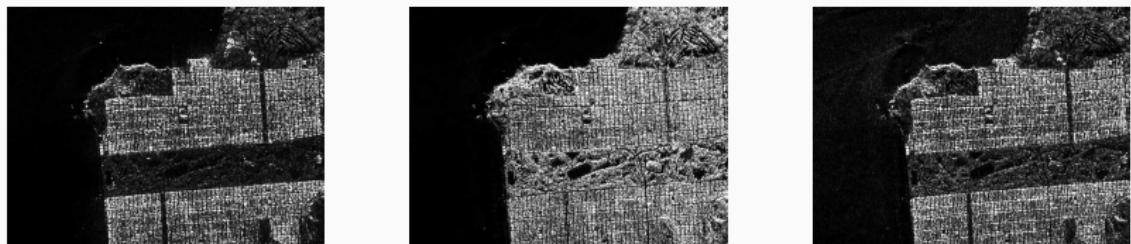
- Podem estar em plataformas elevadas, aeronaves tripuladas ou não, satélites orbitando a terra ou outros planetas;
- É uma técnica de produção de imagem viável e prática;
- Possui alta resolução;
- Os radares produzem imagens dia e noite;
- O clima não interfere na captação de imagens.

# Imagens PolSAR

## Aplicações das imagens PolSAR

- Sensoriamento remoto;
- Topografia;
- Oceanografia;
- Glaciologia;
- Agricultura;
- Geologia;
- Florestas;
- Alvos fixos ou em movimento;
- Monitoramento ambiental;
- Controle de derramamento de petróleo;
- E no auxílio de sistemas óticos.

# Imagen da baía de San Francisco



**Figura 1:** Imagem PolSAR com polarizações ( $hh$ ,  $hv$  e  $vv$ ).

## Imagen da baía de San Francisco



**Figura 2:** Baía de São Francisco.

## Metodología

---

# Modelagem estatística para dados PolSAR

## Equação de espalhamento

$$\begin{bmatrix} E_h^r \\ E_v^r \end{bmatrix} = \frac{e^{ikr}}{r} \begin{bmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{bmatrix} \begin{bmatrix} E_h^t \\ E_v^t \end{bmatrix} \quad (1)$$

- $E_i^j$  - onda eletromagnética;
- $h$  - subíndice indicando polarização na direção horizontal;
- $v$  - subíndice indicando polarização na direção vertical;
- $t$  - superíndice indicando onda transmitida;
- $r$  - superíndice indicando onda recebida;
- $k$  - número de onda;
- $r$  - distância entre radar e alvo.

# Modelagem estatística para dados PolSAR

## Matriz Hermitiana

- Matriz de espalhamento

$$\mathbf{S} = \begin{bmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{bmatrix}, \quad (2)$$

$S_{ij}$  - Coeficiente de espalhamento,  $i$  representa o índice do recebimento, e  $j$  representa o índice da transmissão da onda.

- Teorema da reciprocidade: As propriedades de transmissão e recebimento de uma antena são idênticas, então  $S_{hv} = S_{vh}$ ,

$$\mathbf{s} = \begin{bmatrix} S_{hh} \\ S_{vh} \\ S_{vv} \end{bmatrix}. \quad (3)$$

# Modelagem estatística para dados PolSAR

Função de probabilidade para distribuição Wishart

$$f_{\mathbf{Z}}(\mathbf{Z}; \Sigma, L) = \frac{L^{mL} |\mathbf{Z}|^{L-m}}{|\Sigma|^L \Gamma_m(L)} \exp(-L \operatorname{tr}(\Sigma^{-1} \mathbf{Z})), \quad (4)$$

$\Gamma_m(L)$  - Função Gamma multivariada

$$\Gamma_m(L) = \pi^{\frac{1}{2}m(m-1)} \prod_{i=0}^{m-1} \Gamma(L-i). \quad (5)$$

# Modelagem estatística para dados PolSAR

## Aplicações das imagens PolSAR, [Odell and Feiveson, 1966]

- seja a matriz de covariância  $\Sigma_{3 \times 3}$ ;
- fatoração de Cholesky (Fatoração de Crout)  $\Sigma = CC^H$ ;
- gerar um vetor  $s_{i3 \times 1} = CW_i 3 \times 1$ ;
- onde  $W_i$  é distribuído como uma distribuição normal multivariada com média zero;
- definindo ;

$$B = \sum_{i=1}^{NA} W_i W_i^H, \quad (6)$$

- no caso  $NA = 800 * 800$ ;
- o número de visadas  $L$  é usado na multiplicação  $W_i W_i^H$ .

# Modelagem estatística para dados PolSAR

## Aplicações das imagens PolSAR

- Portanto;

$$B = \sum_{i=1}^{NA} \mathbf{W}_i \mathbf{W}_i^H, \quad (7)$$

$$CBC^H = \sum_{i=1}^{NA} C\mathbf{W}_i \mathbf{W}_i^H C^H, \quad (8)$$

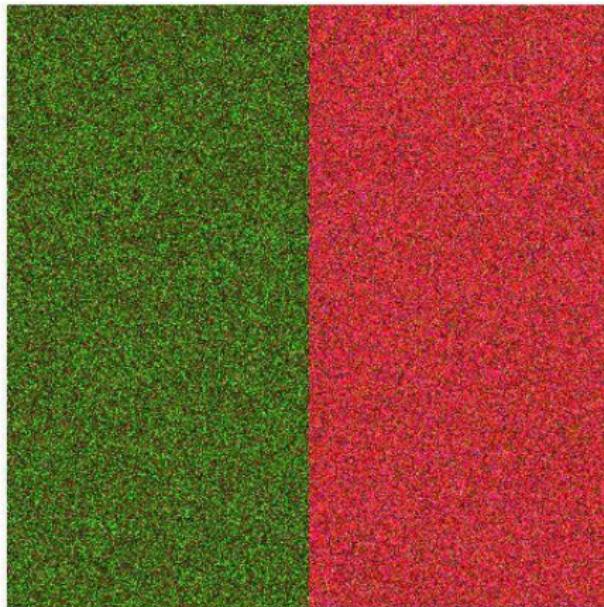
$$CBC^H = \sum_{i=1}^{NA} C\mathbf{W}_i (C\mathbf{W}_i)^H. \quad (9)$$

- logo;

## Matriz de covariância amostral estimada $\mathbf{Z}$

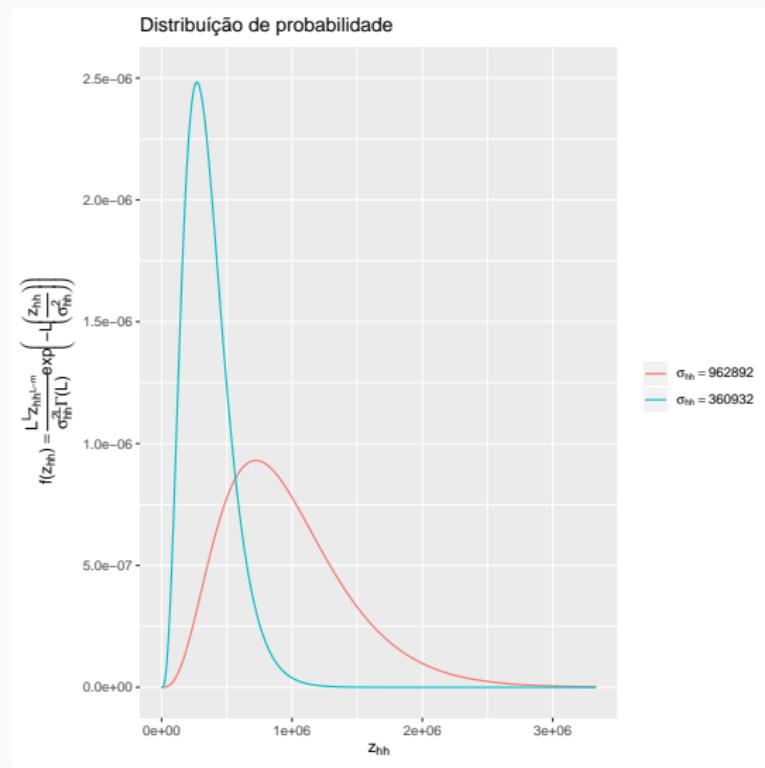
$$\mathbf{Z} = \sum_{i=1}^{NA} \mathbf{s}_i \mathbf{s}_i^H. \quad (10)$$

## Detectção de bordas em imagens PolSAR



**Figura 3:** Decomposição de Pauli para a phantom.

# Detectção de bordas em imagens PolSAR



**Figura 4:** Funções de densidade para dados simulados.

# Detectção de bordas em imagens PolSAR

## Estimativa de máxima verossimilhança - MLE

- Função de verossimilhança

$$L(\theta; \mathbf{X}) = \prod_{i=1}^n f(x_i; \theta), \quad (11)$$

- Função de log-verossimilhança

$$l(\theta; \mathbf{X}) = \ln(L(\theta; \mathbf{X})) = \sum_{i=1}^n \ln(f(x_i; \theta)), \quad (12)$$

- 

$$\hat{\theta} = \arg \max_{\theta \in \Theta} L(\theta; \mathbf{X}), \quad (13)$$

- 

$$\hat{\theta} = \arg \max_{\theta \in \Theta} l(\theta; \mathbf{X}). \quad (14)$$

# Detectção de bordas em imagens PolSAR

Estimativa de máxima verossimilhança,

[Nascimento et al., 2014, Gomez et al., 2017, Gambini et al., 2006]

$$L(j) = \prod_{k=1}^j f_{\mathbf{Z}}(\mathbf{Z}'_k; \Sigma_A, L) \prod_{k=j+1}^N f_{\mathbf{Z}}(\mathbf{Z}'_k; \Sigma_B, L), \quad (15)$$

$$I(j) = \ln L(j) = \sum_{k=1}^j \ln f_{\mathbf{Z}}(\mathbf{Z}'_k; \Sigma_A, L) + \sum_{k=j+1}^N \ln f_{\mathbf{Z}}(\mathbf{Z}'_k; \Sigma_B, L), \quad (16)$$

$$\begin{aligned} I(j) &= N[mL \ln(L) - \ln(\Gamma_m(L))] - L[j \ln(|\Sigma_A|) + (N-j) \ln(|\Sigma_B|)] \\ &+ (L-m) \sum_{k=1}^N \ln(|\mathbf{Z}'_k|) \\ &- L \left[ \sum_{k=1}^j \text{tr}(\Sigma_A^{-1} \mathbf{Z}'_k) + \sum_{k=j+1}^N \text{tr}(\Sigma_B^{-1} \mathbf{Z}'_k) \right]. \end{aligned}$$

# Detectção de bordas em imagens PolSAR

## Estimativa de máxima verossimilhança - MLE

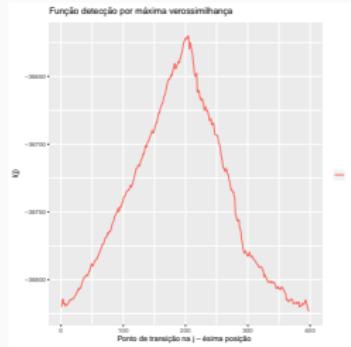
- $$\widehat{\Sigma}_I(j) = \begin{cases} j^{-1} \sum_{k=1}^j \mathbf{Z}_k & \text{se } I = A, \\ (N-j)^{-1} \sum_{k=j+1}^N \mathbf{Z}_k & \text{se } I = B, \end{cases} \quad (17)$$

- $$\begin{aligned} l(j) &= N[-mL(1 - \ln(L)) - \ln(\Gamma_m(L))] - L \left[ j \ln \left( |\widehat{\Sigma}_A(j)| \right) \right. \\ &\quad + \left. (N-j) \ln \left( |\widehat{\Sigma}_B(j)| \right) \right] \\ &\quad + (L-m) \sum_{k=1}^N \ln \left( |\mathbf{Z}'_k| \right), \end{aligned} \quad (18)$$

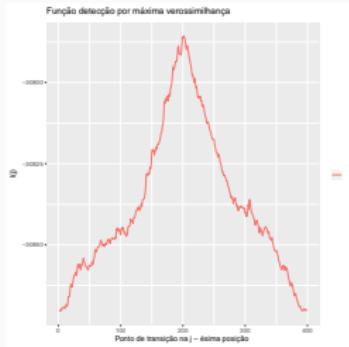
- $$l(j) = -L \left[ j \ln \left( |\widehat{\Sigma}_A(j)| \right) + (N-j) \ln \left( |\widehat{\Sigma}_B(j)| \right) \right], \quad (19)$$

- $$\widehat{j}_{ML} = \arg \max_j l(j). \quad (20)$$

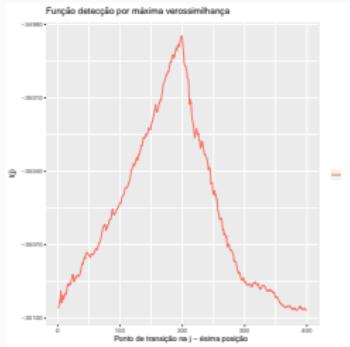
# Detectção de bordas em imagens PolSAR



**Figura 5:** Função  $I(j)$  para o canal  $I_{HH}$ .



**Figura 6:** Função  $I(j)$  para o canal  $I_{HV}$ .



**Figura 7:** Função  $I(j)$  para o canal  $I_{VV}$ .

# Detectção de bordas em imagens PolSAR

## Metodologia de detecção de bordas (para cada canal)

1. Definir uma região de interesse (ROI) de maneira automática, semiautomática ou manual;
2. calcular o centróide da (ROI);
3. construir raios partindo do centróide e indo para fora da área de interesse (Bresenham's line algorithm);
4. coletar dados em uma vizinhança em torno dos raios, construir  $I(j)$  ;
5. detectar pontos na faixa de dados, os quais fornecem evidências de mudanças de propriedades estatísticas, para isso, usamos o método GenSA.

# Detectção de bordas em imagens PolSAR

## Metodologia de detecção de bordas com fusão de evidências

1. Aplicar o método de fusão de evidências;
2. definir o contorno usando um método de interpolação entre os pontos provenientes da fusão de evidências, por exemplo, as B-Splines, ou o método dos quadrados mínimos **MMQ**.

## **Resultados numéricos**

---

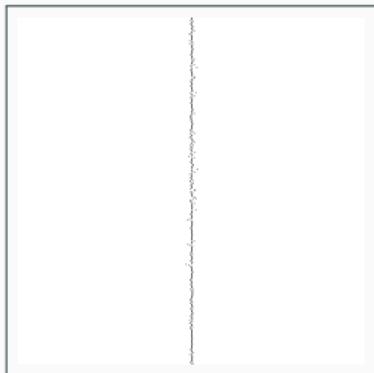
# Resultados numéricos

## Otimização

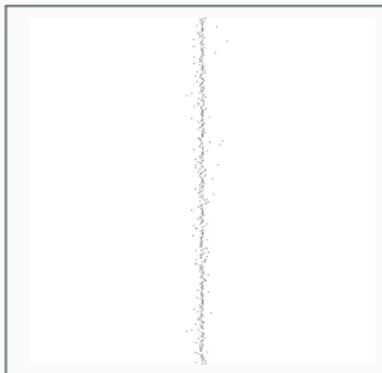
- MaxLik
  - Métodos de otimização - Gradiente - Hessiano;
  - NR - Newton-Raphson (diferenças finitas ou analítico);
  - BHHH - Berndt-Hall-Hall-Hausman (diferenças finitas ou analítico);
  - BFGS - Broyden-Fletcher-Goldfarb-Shanno (diferenças finitas ou analítico);
  - NM - Nelder-Mead (não calcula);
  - SANN - simulated annealing (não calcula).
- GenSA;
- Generalized Simulated Annealing.

# Resultados numéricos

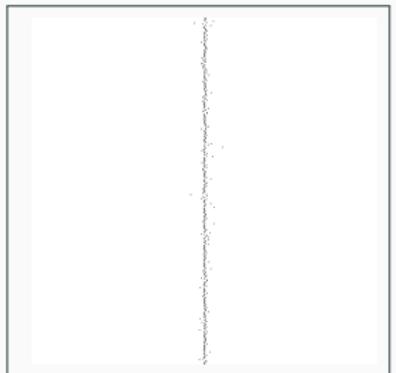
GenSA aplicado em  $I(j)$  nos respectivos canais.



**Figura 8:** Evidências de bordas no canal  $I_{HH}$ .



**Figura 9:** Evidências de bordas no canal  $I_{HV}$ .



**Figura 10:** Evidências de bordas no canal  $I_{VV}$ .

## Resultado numéricos

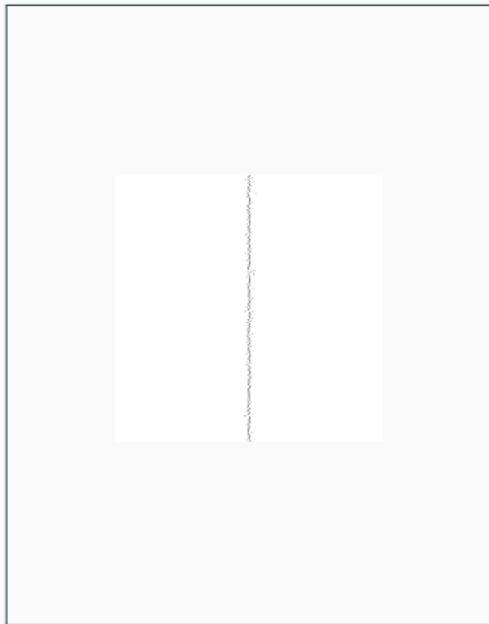
Fusão de evidências de bordas, [Mitchell, 2010]

$$F_m^{ev} = \frac{1}{K} \sum_{k=1}^K ev_k. \quad (21)$$

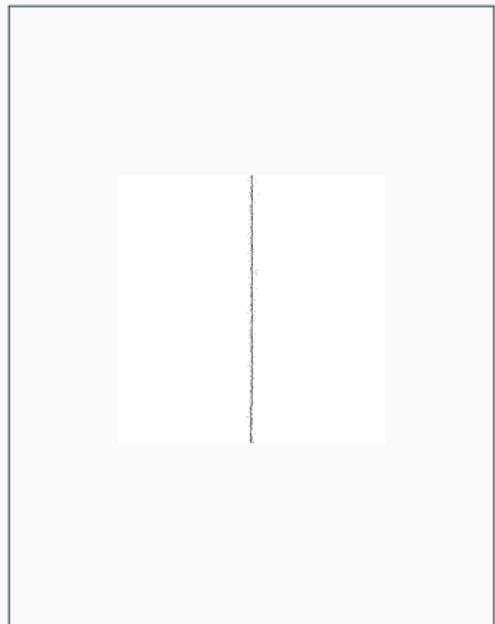
- $m$  - dimensão do vetor de evidências de bordas;
- $K$  - Número de canais.

# Resultados numéricos

## Fusão de evidências e Quadrados mínimos



**Figura 11:** Fusão de evidências para os canais ( $I_{hh}$ ,  $I_{hv}$ ,  $I_{vv}$ ).



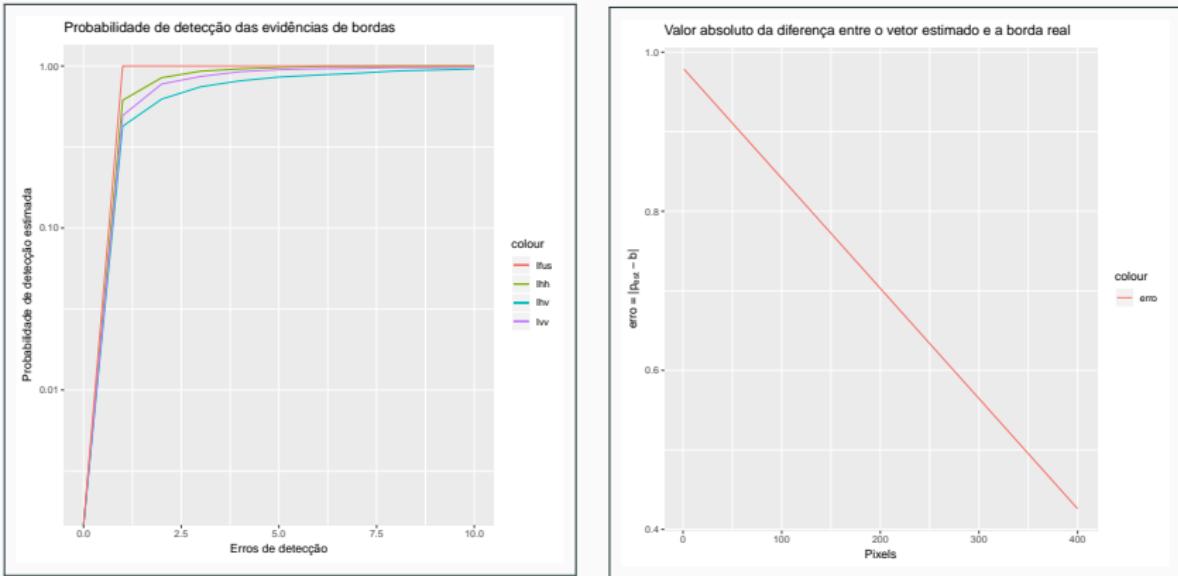
**Figura 12:** Método dos quadrados mínimos.

## Resultados numéricos

**Probabilidade de detecção, [Gambini et al., 2006].**

1. Foi replicado o método de detecção de bordas  $r = 400$  vezes e calculado o erro  $E(r) = |b - pt(r)|$ , onde  $b = 200$  e  $pt(r)$  é o vetor com as  $r$  replicações;
2. vamos usar frequências relativas com objetivo de estimar a probabilidade de ter um erro menor que um certo número de pixeis;
3. sendo  $H(k)$  o número de replicações tal que o erro é menor que  $k$  pixeis, então a probabilidade é  $f(k) = \frac{H(k)}{400}$ , com  $k = 1, \dots, 10$ .

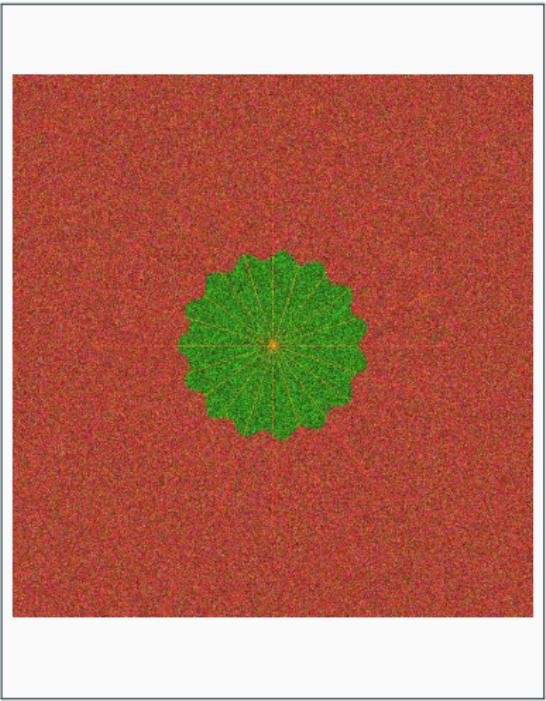
# Resultados numéricos



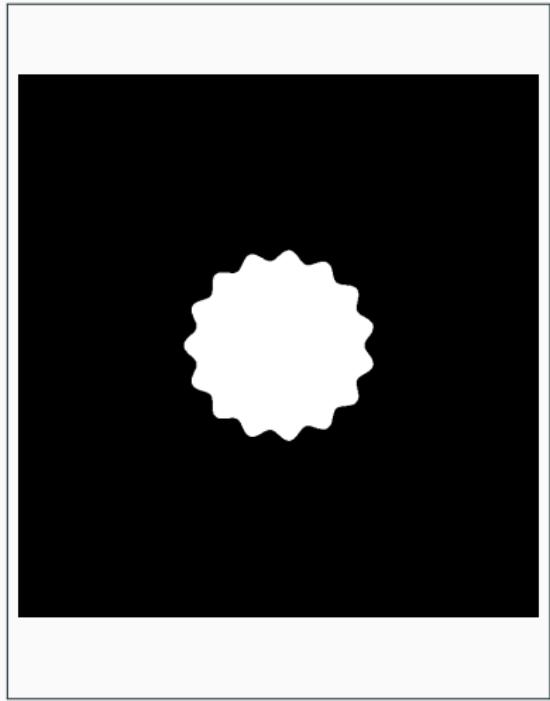
**Figura 13:** Probabilidade de detecção de borda com fusão de evidências nos respectivos canais.

**Figura 14:** Valor absoluto da diferença entre o vetor estimado da fusão de evidências e a borda real.

## Resultados numéricos

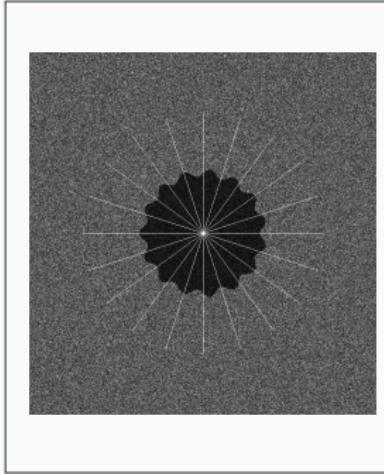


**Figura 15:** Imagem flor simulada com parâmetros  $\beta = 15$ ,  $\delta = 133$  e  $\nu = 8$ .

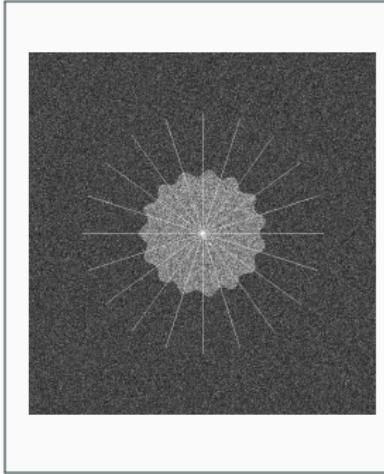


**Figura 16:** Imagem flor simulada binária com  $\beta = 15$ ,  $\delta = 133$  e  $\nu = 8$ .

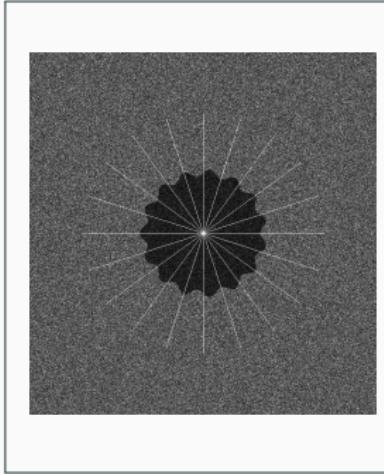
## Resultados numéricos



**Figura 17:** Imagem flor simulada canal  $I_{hh}$  com  $\beta = 15$ ,  $\delta = 133$  e  $\nu = 8$ .

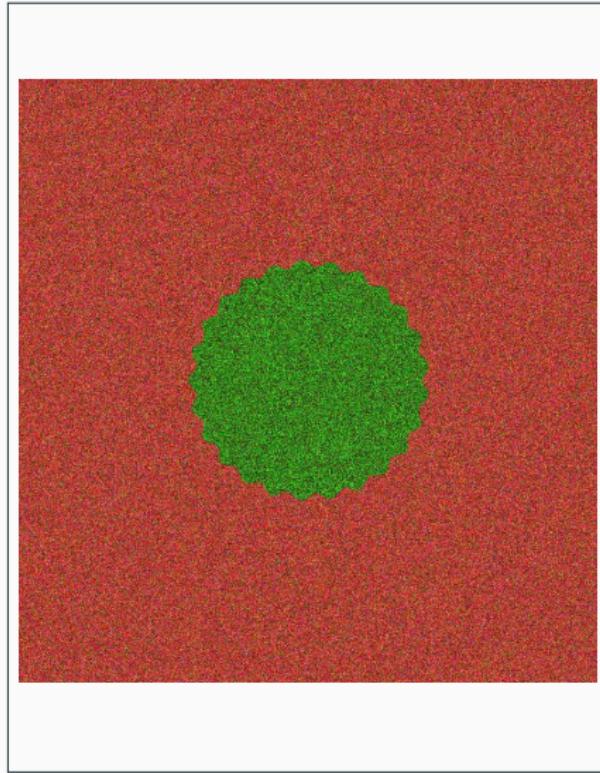


**Figura 18:** Imagem flor simulada canal  $I_{hv}$  com  $\beta = 15$ ,  $\delta = 133$  e  $\nu = 8$ .



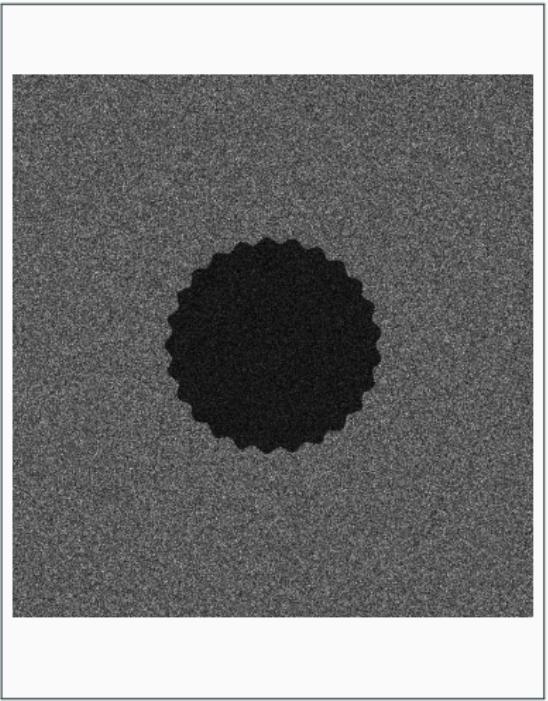
**Figura 19:** Imagem flor simulada canal  $I_{vv}$  com  $\beta = 15$ ,  $\delta = 133$  e  $\nu = 8$ .

## Resultados numéricos

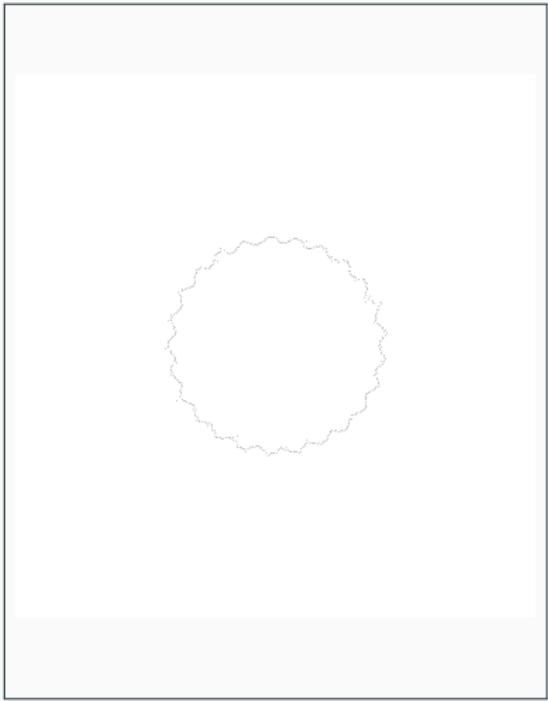


**Figura 20:** Imagem flor simulada com  $\beta = 25$ ,  $\delta = 155$  e  $\nu = 5$ .

## Resultados numéricos

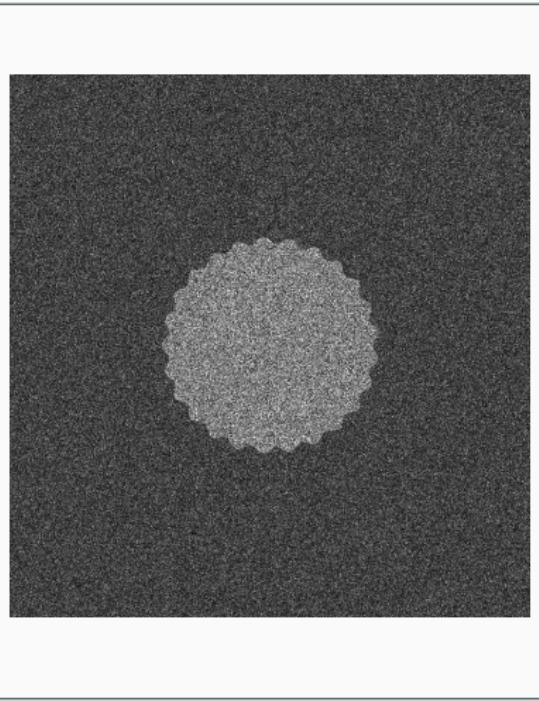


**Figura 21:** Imagem flor simulada canal  $hh$  com  $\beta = 25$ ,  $\delta = 155$  e  $\nu = 5$ .

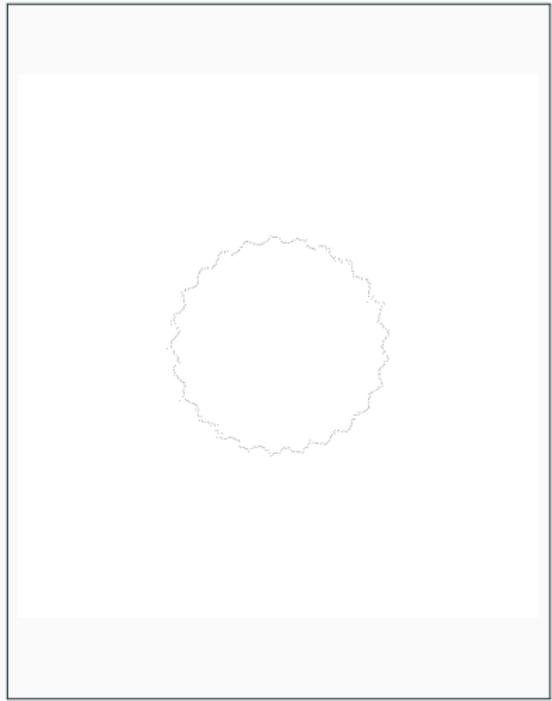


**Figura 22:** Evidências de bordas canal  $hh$  com  $\beta = 25$ ,  $\delta = 155$  e  $\nu = 5$ .

## Resultados numéricos

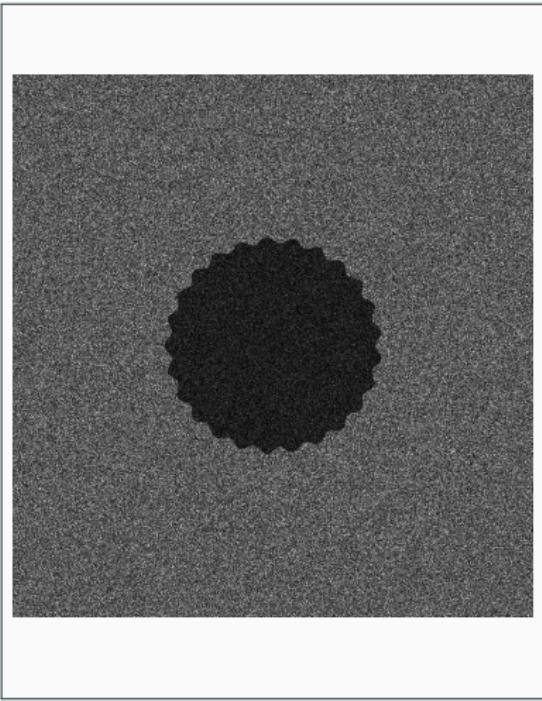


**Figura 23:** Imagem flor simulada canal  $hv$  com  $\beta = 25$ ,  $\delta = 155$  e  $\nu = 5$ .

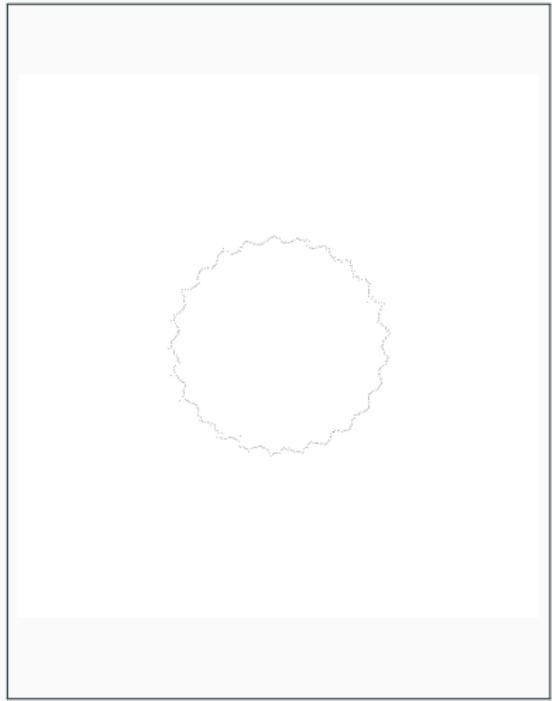


**Figura 24:** Evidências de bordas canal  $hv$  com  $\beta = 25$ ,  $\delta = 155$  e  $\nu = 5$ .

## Resultados numéricos



**Figura 25:** Imagem flor simulada canal  $vv$  com  $\beta = 25$ ,  $\delta = 155$  e  $\nu = 5$ .



**Figura 26:** Evidencias de bordas canal  $vv$  com  $\beta = 25$ ,  $\delta = 155$  e  $\nu = 5$ .

## **Conclusão e trabalhos futuros**

---

# Conclusão e trabalhos futuros

## Conclusão e trabalhos futuros

- O método proposto mostrou ser eficiente na detecção de bordas com fusão de evidências;
- Aplicar o método nas imagens simuladas;
- Melhorar o método de fusão de evidências de bordas;
  - Fusão baseada em histograma, [Frery et al., 2012];
  - SVM, Gradient Boosting [Georganos et al., 2018];
  - Randon Forest, [Samat et al., 2018];
  - PCA, [Mitchell, 2010];
  - Análises estatísticas, [Giannarou and Stathaki, 2011];
  - Cadeia de Markov com razão de falso alarme constante (CFAR), [Fei et al., 2012];
  - Holistically-Nested Edge Detection [Xie and Tu, 2017].
- Aplicar em imagens reais.

**email: [anderborba@gmail.com](mailto:anderborba@gmail.com)**  
**Obrigado!!!!**

- ❑ Fei, C., Liu, T., Lampropoulos, G. A., and Anastassopoulos, V. (2012).  
**Markov chain CFAR detection for polarimetric data using data fusion.**  
*IEEE Trans. Geoscience and Remote Sensing*, 50(2):397–408.
- ❑ Frery, A. C., Jacobo-Berlles, J., Gambini, J., and Mejail, M. (2012).  
**Polarimetric SAR image segmentation with b-splines and a new statistical model.**  
*CoRR*, abs/1207.3944.
- ❑ Gambini, J., Mejail, M., Jacobo-Berlles, J., and Frery, A. C. (2006).  
**Feature extraction in speckled imagery using dynamic B-spline deformable contours under the G0 model.**  
*International Journal of Remote Sensing*, 27(22):5037–5059.

 Georganos, S., Grippa, T., Vanhuysse, S., Lennert, M., Shimoni, M., and Wolff, E. (2018).

**Very high resolution object-based land use-land cover urban classification using extreme gradient boosting.**

*IEEE Geosci. Remote Sensing Lett.*, 15(4):607–611.

 Giannarou, S. and Stathaki, T. (2011).

**Optimal edge detection using multiple operators for image understanding.**

*EURASIP Journal on Advances in Signal Processing*, 2011(1):28.

 Gomez, L., Alvarez, L., Mazorra, L., and Frery, A. C. (2017).

**Fully polsar image classification using machine learning techniques and reaction-diffusion systems.**

*Neurocomputing*, 255:52–60.

 Mitchell, H. (2010).

***Image Fusion: Theories, Techniques and Applications.***

Springer Berlin Heidelberg.

-  Nascimento, A., Horta, M., Frery, A., and Cintra, R. (2014).  
**Comparing edge detection methods based on stochastic entropies and distances for polsar imagery.**  
*Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 7(2):648–663.
-  Odell, P. L. and Feiveson, A. H. (1966).  
**A numerical procedure to generate a sample covariance matrix.**  
*Journal of the American Statistical Association*, 61:199–203.
-  Samat, A., Gamba, P., Liu, S., Miao, Z., Li, E., and Abuduwaili, J. (2018).  
**Quad-polsar data classification using modified random forest algorithms to map halophytic plants in arid areas.**  
*Int. J. Applied Earth Observation and Geoinformation*, 73:503–521.

 Xie, S. and Tu, Z. (2017).

**Holistically-nested edge detection.**

*Int. J. Comput. Vision*, 125(1-3):3–18.